


'24 SW Architect 인증 사례

슈퍼컴퓨터 향 AI 모델 학습/평가 관리 시스템

AI센터 윤종훈

Core Algorithm Lab



- 발표의 큰 흐름을 자연스럽게 연계 (과제 배경 – 품질속성 – 설계)

- DP 1,2 에 올인

- 일정관리 (Feat. 리뷰)

- 할 수 있다

- Check Points
- 면접 자료 소개
- Tips

과정 Check Points

■ 양성과정?

- AA처럼 양성을 위한 **교육**을 해 주지 않음
- 입과자 → A 지식과 능력을 이미 보유하고 있음
- 현업 과제를 통해 내가 Architect 임을 **증명**하는 인증과정
(But, 다 지나고 보면 이 또한 양성)

■ 어떻게 증명?

- 발표자료를 갖고 80분 동안 심사위원을 설득
- "어려운 문제를 **잘** 풀어냈음을 **논리적**으로 설명"

■ 어디서부터 시작 할까?

- 문서가 작성이 없음 → 절대적인 시간 절약, 체계적인 과정 부재, 나태함
- 배경은 기존 과제 자료 활용
- 요구사항 정리 → 설계 안 + Measurement

■ AA 와 A 는 무엇이 다를까?

- AA: 주어진 주제에 일반적/형식적인 패턴과택틱을 활용한 설계
- A: 과제 도메인 특화/최적화 설계 및 검증

자료 작성 Check Points

■ 과제 소개

- 과제 배경 → 과제 필요성 → 과제 개요의 흐름
- 과제가 **무엇이고, 왜 중요한지, 무엇을 해결** 하려는 것인지 명확히 설명

■ 요구사항 분석

- 과제 배경에서 이야기한 문제점을 해결하기 위해 SW 설계 시 만족해야 하는 요구사항으로 연결
- 품질 속성의 우선순위는 **중요도/난이도**에 의해 선별
- **정량 지표**로 평가할 수 있어야 하며 동일한 기준을 유지

■ 설계

- 설계는 전부 **요구사항을 만족하기 위함**인 것을 명심
- 설계 후보 군은 모두 **유의미한 설계** 이어야 함 (채택 안을 위한 들러리 후보 지양)
- 설계 안 채택은 **주요 품질 속성의 Trade-off** 평가에 의해 결정
- 품질 속성과 설계 안의 **연관성**이 무너지지 않도록 경계

■ 구현 및 검증

- 정량 지표 기반의 **객관적 검증**을 통한 달성 여부 검증

■ 성과 및 교훈

- 어필할 수 있는 추가 사항 기술

자료 작성 Check Points

■ 발표의 큰 흐름

Why?

What?

How?


과제 배경

요구사항
(품질속성)

설계

검증

과제 배경



Why?

What? How?


품질 요구 사항

Quality Attribute	Refinement	Scenario	중요도	난이도	우선 순위	ID
Performance	데이터 조회 속도 향상	데이터 조회를 빠르게 수행할 수 있어야 한다 [데이터 조회 후 제공까지 걸리는 시간 < 100ms] * 응답 시간 및 사용자 페이지 영향을 최소화	H	H	1	Q1
Performance	GPU 대기 시간	학습/평가 중 데이터 처리를 위해 GPU가 대기하는 시간을 최소화해야 한다 [데이터 전송 속도의 대기시간 < 100ms] * 응답 속도를 위해 1000개 데이터를 처리할 수 있는 GPU 대기 시간 기준	H	H	2	Q2
Security	보안 데이터 활용	훈련/평가에서 보안 데이터의 사용 후 삭제해야 하며 정기 점검해야 한다 [보안 데이터 사용 종료 후 1개월 이내] * 보안 데이터와 훈련/평가에서 보안 데이터 사용에 관한 정보 추적 가능	H	M	3	Q3
Reliability	데이터 전송 보장	데이터 전송 중 누락이 발생하지 않아야 한다 [누락 데이터 발생 데이터 < 100ms]	H	M	4	Q4
Usability	환경 구성 편의성	모든 학습/평가 환경을 위한 기본 구성이 되어 있어야 한다 [기본 구성 및 수동 설정을 위한 유지보수]가 수월해야 한다	M	H	5	Q5
Maintainability	서비스 배포 용이성	기능 추가 및 수정을 위한 재배포 용이성 (배포 주기 1개월 이내) * (인프라리스 운영 외) 사용자/개발자/운영자를 위한 System Client 개발로 지원	M	H	6	Q6
Usability	데이터 전처리	데이터 조회 시점의 최신 정보를 제공해야 한다	M	M	7	Q7
Efficiency	자원 효율성	데이터 저장에 위한 스토리지 자원을 효율적으로 활용해야 한다	M	M	8	Q8
Scalability	시스템 확장성	시스템 리소스를 서비스 중단 없이 확장/축소할 수 있어야 한다	M	M	9	Q9

What?

How? Why?

DP1. 보안 데이터 슈퍼컴 내 제공 방안



How?

Why? What?

제목만 읽고 과제에 대해
유추해 볼 수 있도록

(AS-WAS)
Supercom 向 MLOps 개발

슈퍼컴퓨터 향 AI 모델 학습/평가 관리 시스템

2024 SW Architect 현업 과제

SAIT 윤종훈

AI Research Center

Everything for AI Automation



Index

01

과제 소개

02

요구사항 분석

03

설계

04


구현 및 검증

05

성과 및 교훈


Generative AI 모델의 확산

Global Generative AI in Manufacturing Market



ChatGPT 등장 이후 AI 개발 트렌드가
딥러닝에서 Generative AI로 패러다임 전환

→ 산업 전반에 걸쳐 Generative AI 활용 증대




도메인 지식 학습을 통해, General LLM 대비 우수한 성능의 Fine-tuned LLM 활용

→ 각 분야에 적합한 Domain 특화 LLM

반도체 도메인 특화 LLM

AI Impact (EBIT)



반도체 경쟁력 강화를 위한 반도체 도메인
Use Case 특화된 LLM model 의 개발 필요

무엇이, 왜 필요한지

동향 → 현황 → 필요성

Defect 이미지 분석을 통한 혐의 공정 추정
원인 파악 및 사후 조치 추천
대형 영향도 사전 분석 및 개선
원인 조기 조치 추천
업무 Assistant Copilot
개발 업무 보조


Verilog CodeLLM

DS 부문 Gen-AI 활용 8대 Use Case (Turing T/F)

外 Use Case 36개 발굴 및 지속 검토 중

학습/평가 관리 시스템 필요성

✓ Use Case 별로 다양하게 개발되는 LLM 모델의
학습 및 평가 관리 시스템 필요



✓ LLM 학습 및 평가 이력 관리 시스템 필요

- 학습/평가 이력 관리를 통한 성능 변화 추적
- 효율적인 이력 공유를 통한 중복 개발 방지
- 변경 사항 추적, 재현성, 일관성 유지

✓ 학습 산출물(모델) 관리 시스템 필요


- 학습 산출물 관리를 통한 재학습 방지
- 학습 이력과 연동된 버전 관리 및 배포 관리

✓ 데이터 기반 학습/평가 시스템 필요

- 보안 데이터 수집/관리
- 데이터 연동된 학습/평가 파이프라인 제공

■ *슈퍼컴퓨터 환경 제약 내 사용할 수 있는 학습/평가 관리 시스템을 통해 AI 개발 효율 개선


AI 학습용 GPU	매수
V100	1064
A100	2664
H100	1180



* 전사를 대상으로 혁신센터에서 운영하는 고성능 CPU/GPU 컴퓨팅 인프라 서비스. 각종 시뮬레이션 및 AI 개발을 위한 GPU 제공
AI 모델 중 특히 LLM 개발은 대량(수십~수백) GPU 병렬 학습을 지원하는 슈퍼컴퓨터 인프라 사용

■ *슈퍼컴퓨터 환경 제약 내 사용할 수 있는 학습/평가 관리 시스템을 통해 AI 개발 효율 개선

AI 학습용 GPU	매수
V100	1064
A100	2664
H100	1180



* 전사를 대상으로 혁신센터에서 운영하는 고성능 CPU/GPU 컴퓨팅 인프라 서비스. 각종 시뮬레이션 및 AI 개발을 위한 GPU 제공
AI 모델 중 특히 LLM 개발은 대량(수십~수백) GPU 병렬 학습을 지원하는 슈퍼컴퓨터 인프라 사용

■ 과제 명

- 슈퍼컴 향 AI 모델 학습/평가 관리 시스템 개발

■ 과제 목표

- AI 학습 이력, 산출물, 데이터 관리 및 학습/평가를 위한 파이프라인 제공
 - AI 모델 개발 효율화를 통한 생산성 향상 및 모델 성능 향상
 - 슈퍼컴퓨터 환경에서 AI모델 개발 편의성 개선

■ 참여 인력

- 국내: 7명 (CL4 1명, CL3 5명, CL2 1명)
- 해외: 4명 (SRCX)

■ 일정

- 과제 기간: '24년 01월 ~ '24년 12월
 - LLM 모과제 기간: '23년 11월 ~ '26년 10월

과제 범위, 내용, 기간

배경에서 언급 했던 내용의 요약
적당한 규모

요구사항 분석

요구사항 수집

✓ 주요 Stakeholder 선정 및 의견청취

Stakeholder	주요 역할
LLM 모델 연구원	LLM Base 모델 개발
LLM 응용 개발자	LLM 응용 모델 개발
LLM 품질 관리자	LLM 모델 성능 평가
데이터 관리자	데이터 수집 및 전처리 개발, 데이터 거버넌스
시스템 개발자	시스템 개발 및 운영
슈퍼컴 운영자	슈퍼컴 운영 및 관리
보안 담당자	보안 규정 관리 및 확인

✓ 요구사항 수집 방법

- 유관 부서 회의를 통해
- 모델 개발 연구원/개발자
- 워크샵 및 관계자 미팅
- Github/Jira 상시 VoC

Stakeholder 는 모두 식별되었는지
요구사항 수집을 어떻게 진행하였는지

(발표시간 부족) 질문 시
참고자료 활용

요구사항 분석 및 정제


✓ 요구사항 분석

- 요구사항 분류 (비즈니스 & 기술)
- 관련 요구사항 통합
- 과제 범위 정의

✓ 요구사항 정제

- 기능 요구사항 도출
- 제약사항 도출
- 품질 시나리오 명세
- Use Case, Domain model 분석

대부분의 발표자가 비슷한
이야기를 다양한 템플릿으로
얘기함



Architecture Driver 도출

✓ 기능/품질/제약사항 분류

✓ *QAW를 통한 품질 속성 우선순위화

✓ 설계에 영향을 주는 핵심 요구사항 14종 선정

Functional Requirements	
F1	실험 이력 관리
F2	실험 산출물 관리
F3	보안 데이터 관리
F4	평가 자동화
F5	실험 결과 재현
F6	리소스 모니터링
Quality Attribute	
Q1	데이터 조회 응답성
Q2	보안 데이터 활용
Q3	GPU 대기 시간
Q4	데이터 전송 보장
Q5	환경 구성 편의성
Q6	자원 활용 효율성
Constraints	
C1	독립 네트워크 환경
C2	보안 데이터 규정

배경에서 언급했던
- 문제점 : FR 과 QA 로
- 환경 : 제약사항으로

기능 요구 사항 및 제약 사항

과제 소개

요구사항

설계

구현/검증

성과

■ 기능 요구 사항

Functional Requirements	Refinement	Description
F1	실험 이력 관리	실험(학습/평가) 이력을(parameter, metric, 등 Meta data) 관리(저장/공유/조회) 할 수 있어야 한다
F2	실험 산출물 관리	실험(학습/평가) 중 생성된 산출물(Model, Log, Image, Docs 등)의 관리(저장/공유/조회) 할 수 있어야 한다
F3	보안 데이터 관리	실험(학습/평가)에 사용되는 데이터를 보안규정에 맞게 관리(수집/공유/사용) 할 수 있어야 한다
F4	평가 자동화	동일한 기준의 평가를 반복 및 자동 수행할 수 있어야 한다
F5	실험 결과 재현	기존 실험(학습/평가) 결과를 재현할 수 있어야 한다
F6	리소스 모니터링	실험과 연관된 슈퍼컴 리소스 (GPU, job, Quota) 정보를 조회 할 수 있어야 한다

배경에서 목적을 잘 설명했다면 간략하게 설명하고 넘어갈 수 있음

설계에 영향을 주는 제약 사항만 선정

■ 제약 사항

Constraints	Refinement	Description
C1	독립 네트워크 환경	슈퍼컴 클러스터는 외부와 단절된 네트워크는 망으로 구성되어 있고, 허용된 채널 외 연결은 제한 한다
C2	보안 데이터 규정	보안 데이터는 반드시 암호화하여 DS Cloud에 보관해야 한다

품질 요구 사항

Confidential

설계 > 구현/검증 > 성과

■ 품질 요구 사항



QA 로 선정된 과정, 이유, 기준이 합리적이어야 함

정량 지표는 명확한 기준과 근거를 동반

반드시 논리적으로 기술/설명할 수 있어야 함

Quality Attribute	Refinement	Scenario	중요도	난이도	우선 순위	ID
Performance	데이터 조회 응답성	데이터 조회를 빠르게 수행할 수 있어야 한다 [데이터 요청 후 제공까지 걸리는 시간 ≤ 평균 3 sec] • 응답 시간 별 사용자 페이지 이탈률 통계 기준	H	H	1	Q1
Performance	GPU 대기 시간	학습/평가 중 데이터 처리를 위해 GPU가 대기하는 시간을 최소화 해야 한다 [데이터 전송 목적의 대기시간 ≤ 평균 51.1 sec] (10GB 기준) • 슈퍼컴으로 데이터 10GB 전송을 위해 평균 GPU 대기 시간 기준	H	H	2	Q2
Security	보안 데이터 활용	슈퍼컴에서 보안 데이터는 사용 후 삭제 해야하며 장기 보관하지 말아야 한다 [보안 데이터 사용 종료 후 미 삭제 위규 0건] • 보안 담당자와 슈퍼컴에서 보안 데이터 사용에 관한 협의 후 결정 사항	H	M	3	Q3
Reliability	데이터 전송 보장	데이터 전송 중 누락이 발생하지 않아야 한다 [(누락 데이터/ 전체 데이터) x 100] < 0.01%	H	M	4	Q4
Usability	환경 구성 편의성	모델 학습/평가를 위한 개발 환경 구축이 용이 해야 한다 [환경 구성을 위해 패키지 수동 설치 횟수 1회 이하]	M	H	5	Q5
Maintainability	서비스 배포 용이성	기능 추가 및 수정을 위한 유지보수가 수월 해야 한다 [기능 추가 및 수정의 적용을 위한 재배포 필요 서비스 개수 1개 이하] • (인터페이스 수정 외) 사용자의 재설치를 필요로 하는 System Client 재배포 지양	M	H	6	Q6
Usability	데이터 적시성	데이터 조회 시점의 최신 정보를 제공해야 한다	M	M	7	Q7
Efficiency	자원 효율성	데이터 저장을 위한 스토리지 자원을 효율적으로 활용해야 한다	M	M	8	Q8
Scalability	시스템 확장성	시스템 리소스를 서비스 중단을 최소화하며 확장/축소할 수 있어야 한다.	M	M	9	Q9

Constraints

C1. 독립 네트워크 환경

C2. 보안 데이터 규정

Functional Requirements

F1. 실험 이력 관리

F2. 실험 산출물 관리

F3. 보안 데이터 관리

F4. 평가 자동화

F5. 실험 결과 재현

F6. 리소스 모니터링

Quality Attributes

Q1. 데이터 조회 응답성

Q2. GPU 대기 시간

Q3. 보안 데이터 활용

Q4. 데이터 전송 보장

Q5. 환경 구성 편의성



Q6. 서비스 배포 용이성

Architecture Drivers

슈퍼컴 환경에서 AI 모델 학습/평가를 효율적으로 관리 할 수 있는 시스템 설계


설계

Overall System (Context Diagram)



Overall Architecture (Module View)

- 설계 포인트 선정



DP1	보안 데이터 슈퍼컴 내 제공 Q2 + Q3 + Q4
DP2	실험 이력 데이터 조회 Q1 + Q4 + Q6
DP3	슈퍼컴 리소스 데이터 조회 Q1 + Q4
DP4	산출물/모델 저장 효율화 Q2 + Q6
DP5	평가 수행 환경 구축 자동화 Q5

Quality Attribute	
Q1	데이터 조회 응답성
Q2	GPU 대기 시간
Q3	보안 데이터 활용
Q4	데이터 전송 보장
Q5	환경 구성 편의성
Q6	서비스 배포 용이성

전체 구조, 범위
설계 반영 전/후 비교

Legend	
기존 Module	
신규/수정 Module	

DP1. 보안 데이터 슈퍼컴 내 제공 방안

과제 소개

요구사항

설계

구현/검증

성과

■ 배경

- 반도체 향 LLM 학습/평가를 위해 슈퍼컴에서 반도체 데이터 사용 필요
- 반도체 데이터는 반드시 정해진 **보안 level이 확보된 공간에 암호화** 하여 보관 (DS Cloud)
- 슈퍼컴 학습 시 데이터 **사용 후 반드시 삭제**하고 상주를 최소화 해야 함 ※ 보안 데이터의 슈퍼컴 내 사용 종료 후 삭제. 단, 재사용 예정 시 최대 3일 보관 가능

F3 - 보안 데이터 관리

Q2 - GPU 대기 시간


Q4 - 데이터 전송 보장

C1 - 독립 네트워크

F4 - 평가 자동화

Q3 - 보안 데이터 활용

C2 - 보안 데이터



- ✓ **[데이터 보안]** 슈퍼컴으로의 데이터 복사 및 삭제는 사용자 책임하에 개인별 관리
 - ✓ **[키 공유]** 암호/복호화 키를 모델 개발자들 간 이메일, 메신저로 전달
 - ✓ **[GPU 대기]** 암호화 데이터의 공유/전송 중 GPU 미사용 대기
- 보안성 및 GPU 대기 시간 최소화를 고려한 **Data provision 시스템 필요**

가장 중요한(자신 있는) 문제를
다른 DP

DP 에서 해결하고자 하는 문제가
무엇인지 배경 설명

DP1. 보안 데이터 슈퍼컴 내 제공 방안

빈틈없이 준비해서 완벽하게 소개

설계 후보 안에 대해 소개하고
왜 채택하였는지 논리적으로 설득
및 토론


객관적인 지표들로 Trade-Off 관계
를 증명

내부 시스템 외부 모듈 외부 시스템

- F3 - 보안 데이터 관리
- Q2 - GPU 대기 시간
- Q4 - 데이터 전송 보장
- C1 - 독립 네트워크
- F4 - 평가 자동화
- Q3 - 보안 데이터 활용
- C2 - 보안 데이터


시스템 storage를 통한 데이터 제공 [채택]

ercom >>



*TTL: Time To Live

(2안) 사용자 storage를 통한 데이터 제공



핵심

데이터의 복호화 및 수명 주기 관리를 시스템 내에서 처리

장점

- NFS로 접근 가능한 System Storage의 폴더 접근 권한 설정을 통해 데이터 접근 (성능 ↑)
- 데이터 관리 이력 시스템에서 기록 (보안성 ↑)

단점

- Data Provision Service 장애 시 보안 데이터 제공 불가(*SPOF) (신뢰성 ↓)

Trade-off

- (Performance) GPU 대기 시간 (NFS) ※ 10GB 전송 : 평균 7.6 sec ★★★
- (Security) 데이터 보안 (시스템 내 데이터 운용, 관리 이력 제공) ★★★
- (Reliability) 데이터 전송 보장 (서비스 문제 시 전송 장애) ※ 이중화 설계를 통한 보완 ★★☆☆
- (Performance) 사용자 체감 학습 시간 ★★☆☆

데이터 복호화 및 수명 주기 관리를 End-point에서(Client) 처리

- NFS로 연결되어 있는 사용자 Storage를 통해 데이터 제공 (성능 ↑)
- 시스템 복잡도가 낮으며, *SPOF 없음(신뢰성 ↑)


- GPU process 비정상 종료 시 데이터 삭제 실패 가능성 ※ CPU Node Job을 통한 모니터링 보완
- Key 발급 통해 데이터 사용 이력 간접 확인. 데이터 관리 이력은 사용자 Log 기록 (보안성 ↓)

- (Performance) GPU 대기 시간 (NFS) ※ 10GB 전송 : 평균 7.6 sec ★★★
- (Security) 데이터 보안 (사용자 공간 내 데이터 운용, 이력 간접 확인) ★★☆☆
- (Reliability) 데이터 전송 보장 (가용성 보장된 외부 시스템) ★★★
- (Performance) 사용자 체감 학습 시간 ★★☆☆

DP1. 보안 데이터 슈퍼컴 내 제공 방안

Confidential

과제 소개 > 요구사항 > 설계 > 구현/검증 > 성과



F3 - 보안 데이터 관리

Q2 - GPU 대기 시간

Q4 - 데이터 전송 보장

C1 - 독립 네트워크

F4 - 평가 자동화


Q3 - 보안 데이터 활용

C2 - 보안 데이터

(1안) 시스템 storage를 통한 데이터 제공 [채택]


(2안) 사용자 storage를 통한 데이터 제공

설계 안



데이터 전송 시간 단축 보완 설계

보안 담당자와 협의를 통해 사용 종료 후 최대 3일 보관 가능 (보안 데이터 사용성 개선 목적)
이를 활용한 데이터 보관 정책 적용



부족한 Trade-off를 극복하기 위해
많은 고민을 했음을 표현

Trade-off 평가 시 QA의 우선순위
연동하면 논리적, 설명 간편

3 학습/평가 시작

GPU Node

Test / Train

핵심

데이터의 복호화 및 수명 주

장점

- NFS로 접근 가능한 System
- 데이터 관리 이력 시스템

단점

- Data Provision Service 장애 시 보안 데이터 제공 불가(*SPOF) (신뢰성 ↓)

Tradeoff

(Performance) GPU 대기 시간 (NFS) ※ 10GB 전송 : 평균 7.6 sec ★★★

(Security) 데이터 보안 (시스템 내 데이터 운용, 관리 이력 제공) ★★★

(Reliability) 데이터 전송 보장 (서비스 문제 시 전송 장애) ※ 이중화 설계를 통한 보완 ★★☆☆

(Performance) 사용자 체감 학습 시간 ★★★

(Performance) GPU 대기 시간 (NFS) ※ 10GB 전송 : 평균 7.6 sec ★★★

(Security) 데이터 보안 (사용자 공간 내 데이터 운용, 이력 간접 확인) ★★☆☆

(Reliability) 데이터 전송 보장 (가용성 보장된 외부 시스템) ★★★

(Performance) 사용자 체감 학습 시간 ★★★

*SPOF: Single Point Of Failure

DP2 / DP3. 슈퍼컴 데이터 조회 (배경)

과제 소개 > 요구사항 > 설계 > 구현/검증 > 성과

■ 배경

- 슈퍼컴 망 내부로의 Inbound는 로그인 서버의 SSH만 가능 하며 모든 데이터 조회는 Terminal(CLI)를 통해서
→ SSH 접속 및 Command 수행의 반복 조회 작업의 사용성을 개선 필요

(Secure Shell Protocol)

배경 설명 시 문제점을 설명하며 사용한 그림을 활용, 이어서 설명

무엇을 해결하고자 하는지 정의
Trade-off 관계에 있는 항목 소개

F6 - 리소스 모니터링

Q1 - D

Q4 - D

DP3. 슈퍼컴 리소스 데이터 조회

Job Scheduler

GPU Node

외부 시스템(슈퍼컴 인프라)가 제공하는 리소스 데이터의 조회

- ✓ 관련 정보 반복 조회를 대신 할 수 있는 모니터링 기능 부재
- ✓ 사용중인 슈퍼컴 리소스의 실시간 상태 정보 조회 필요
(GPU Memory, Utilization, Job Info, Project Quota)
- ✓ 정보 조회 응답성과 정보의 실시간성(최신성)간의 Trade-off
를 고려한 설계 필요

→ 조회 요청 → 데이터

Login Server

<AS-IS>

<TO-BE>

사용자가 기록한 실험 이력 데이터의 조회

- ✓ On-demand 방식의 문제(이력 공유 및 조회 속도) 개선 필요
- ✓ 폴더 공유 방식의 실험 이력 공유 개선
- ✓ 슈퍼컴 내 파일 삭제 시 실험 이력 보관/조회 불가

※ On-demand 실험 이력 수집 시간: 평균 2.9 초 (최대 8.3초)
<350K 데이터 수집 + parsing/전처리 / 실험 200건>

System
(Web UI)

System DB

DP2. 실험 이력 데이터 조회

F1 - 실험 이력 관리

F2 - 실험 산출물 관리

Q1 - 데이터 조회 응답성

Q4 - 데이터 전송 보장

Q6 - 서비스 배포 용이성

C1 - 독립 네트워크 환경

DP2. 실험 이력 데이터 조회

Confidential

과제 소개 > 요구사항 > 설계 > 구현/검증 > 성과



- F1 - 실험 이력 관리 Q1 - 데이터 조회 응답성 Q6 - 서비스 배포 용이성
- F2 - 실험 산출물 관리 Q4 - 데이터 전송 보장 C1 - 독립 네트워크

	(1안) End-point 에서 데이터 직접 전송	(2안) Service를 통한 데이터 수집 [채택]
설계안	1 학습/평가 시 GPU Node 별로 Client 에서 데이터 수집 및 처리 2 수집/처리 된 데이터를 DB에 실시간 저장 3 데이터 조회 시 DB/Storage에서 실시간 조회 << Supercom >> << System >>	1 Logger Service API를 통해 데이터 수집 2 Logger Service는 수집 된 데이터를 처리 후 DB에 실시간 저장 3 데이터 조회 시 DB/Storage에서 실시간 조회 << Supercom >> << System >>
핵심	DB를 중심으로 한 client 패키지에서 데이터 처리 및 실시간 전송	API Gateway 및 logic을 담당하는 Logger Service(proxy)를 통해 데이터 처리 및 전달
장점	- 사용자의 데이터 조회 요청과 이력 데이터의 기록 간의 의존성 분리 (응답성 ↑) - 이력 데이터를 시스템에 기록하여 권한 별 공유 기능 제공 가능 (사용성 ↑) - 슈퍼컴 내부에 단일 장애점을 유발할 수 있는 서비스 운영 불필요 (가용성 ↑)	- 사용자의 데이터 조회 요청과 이력 데이터의 기록 간의 의존성 분리 (응답성 ↑) - 이력 데이터를 시스템 내부에 기록하여 권한 별 공유 기능 제공 가능 (사용성 ↑) - 데이터 처리 logic 변경 시 업데이트 용이 (유지 보수성 ↑)
단점	- Logic 수정 시 package 재배포/설치 필요 (유지 보수성 ↓) - Resource 추가/변경 시 방화벽 설정 (정책 관리 포인트 증가)	Logger Service 장애 시, 전체 GPU Node에서 데이터 수집 불가 (가용성 ↓)
Tradeoff	(Performance) 이력 조회 속도 ※ System Service에서 DB 조회 완료: 평균 397ms ★★★ (Reliability) 단일 장애점 (장애 전파 없음) ★★★ (Maintainability) 배포 및 설정 용이성 (리소스 별 설정 관리. 재배포 필요) ★★☆☆	(Performance) 이력 조회 속도 ※ 조회 구조 동일하므로 1안과 동일 ★★★ (Reliability) 단일 장애점 (서비스 문제 시 데이터 전송 장애) ※ 이중화 설계를 통한 보완 ★★☆☆ (Maintainability) 배포 및 설정 용이성 ★★★

DP2. 실험 이력 데이터 조회

Confidential

과제 소개 > 요구사항 > 설계 > 구현/검증 > 성과



- F1 - 실험 이력 관리 Q1 - 데이터 조회 응답성 Q6 - 서비스 배포 용이성
- F2 - 실험 산출물 관리 Q4 - 데이터 전송 보장 C1 - 독립 네트워크

	(1안) End-point 에서 데이터 직접 전송	(2안) Service를 통한 데이터 수집 [채택]
설계	이해하기 쉽도록 Trade-off 에 정량 수치를 표시하여 Metric 에 대한 질문에 대비하여 Appendix 준비 << System >> << Supercom >> << System >>	데이터 전송 보장 보완 설계 Health Check Flow 서비스 장애 시 데이터 백업 Flow 정상 동작 시 데이터 Flow 서비스 재시작 시 데이터 복구 Flow 1 Health check, 장애 감지 2 데이터 파일로 임시 저장 3 서비스 재시작 시 복구할 데이터가 있는지 확인, 복구 수행 후 임시 파일 삭제 GPU Node System Client Client API Test / Train Application 된 데이터를 처리 후 DB에 실시간 저장 DB/Storage에서 실시간 조회 를 통해 데이터 처리 및 전달 의존성 분리 (응답성 ↑)
핵심	DB를 중심으로 한 client	
장점	- 사용자의 데이터 조회 속도 향상 - 이력 데이터를 시스템에 기록하여 권한 별 공유 기능 제공 가능 (사용성 ↑) - 슈퍼컴 내부에 단일 장애점을 유발할 수 있는 서비스 운영 불필요	- 이력 데이터를 시스템 내부에 기록하여 권한 별 공유 기능 제공 가능 (사용성 ↑) - 데이터 처리 logic 변경 시 업데이트 용이 (유지 보수성 ↑)
단점	- Logic 수정 시 package 재배포/설치 필요 (유지 보수성 ↓) - Resource 추가/변경 시 방화벽 설정 (정책 관리 포인트 증가)	Logger Service 장애 시, 전체 GPU Node에서 데이터 수집 불가 (가용성 ↓)
Tradeoff	(Performance) 이력 조회 속도 ※ System Service에서 DB 조회 완료: 평균 397ms ★★★ (Reliability) 단일 장애점 (장애 전파 없음) ★★★ (Maintainability) 배포 및 설정 용이성 (리소스 별 설정 관리, 재배포 필요) ★★☆☆	(Performance) 이력 조회 속도 ※ 조회 구조 동일하므로 1안과 동일 ★★★ (Reliability) 단일 장애점 (서비스 문제 시 데이터 전송 장애) ※ 서비스 장애 보완 설계를 통해 이력 데이터 복구 보장 ★★★★★ (Maintainability) 배포 및 설정 용이성 ★★★

DP2 / DP3. 슈퍼컴 데이터 조회 (배경)

과제 소개

요구사항

설계

구현/검증

성과

■ 배경

(Secure Shell Protocol)

- 슈퍼컴 망 내부로의 Inbound는 로그인 서버의 SSH만 가능 하며 모든 데이터 조회는 Terminal(CLI)를 통해서 수행
- SSH 접속 및 Command 수행의 반복 조회 작업의 사용성을 개선 필요

F6 - 리소스 모니터링

Q1 - 데이터 조회 응답성


C1 - 독립 네트워크 환경

Q4 - 데이터 전송 보장

DP3. 슈퍼컴 리소스 데이터 조회

Job Scheduler

GPU Node



외부 시스템(슈퍼컴 인프라)가 제공하는 리소스 데이터의 조회

- ✓ 관련 정보 반복 조회를 대신 할 수 있는 모니터링 기능 부재
- ✓ 사용중인 슈퍼컴 리소스의 실시간 상태 정보 조회 필요
(GPU Memory, Utilization, Job Info, Project Quota)
- ✓ 정보 조회 응답성과 정보의 실시간성(최신성)간의 Trade-off를 고려한 설계 필요

→ 조회 요청 → 데이터

Login Server

<AS-IS>

<TO-BE>

System
(Web UI)

System DB

사용자가 기록한 실험 이력 데이터의 조회

- ✓ On-demand 방식의 문제(이력 공유 및 조회 속도) 개선 필요
- ✓ 폴더 공유 방식의 실험 이력 공유 개선
- ✓ 슈퍼컴 내 파일 삭제 시 실험 이력 보관/조회 불가

※ On-demand 실험 이력 수집 시간: 평균 2.8 초 (최대 8.3초)

<350K 데이터 수집 + parsing/전처리 / 실험 200건>

Refresh
앞에서 이야기 했지만, 시간이 지나면 잊혀짐

F1 - 실험 이력 관리

Q1 - 데이터 조회 응답성

C1 - 독립 네트워크 환경

F2 - 실험 산출물 관리

Q4 - 데이터 전송 보장

C3 - 슈퍼컴 운영 정책

Q6 - 서비스 배포 용이성

DP3. 슈퍼컴 리소스 데이터 조회

Confidential

과제 소개

요구사항

설계

구현/검증

성과



F6 - 리소스 모니터링

Q1 - 데이터 조회 응답성

C1 - 독립 네트워크 환경

Q4 - 데이터 전송 보장

	(1안) On demand Pull 방식	(2안) scheduled push 방식 [채택]
설계안	<< Supercom >> << System >> 1 사용자 리소스 조회 요청 2 조회 요청 시점에 Login Server 를 통해 GPU 및 Scheduler 정보 취득 및 반환	<< Supercom >> << System >> 1 주기적으로 GPU Node 전체와 모든 Job 정보를 취득하여 DB에 저장 2 사용자 리소스 조회 요청 시 DB에 저장되어 있는 정보 반환
핵심	조회 요청이 발생하는 시점에 Login server를 통하여 요청된 정보만 조회	모든 리소스의 데이터를 일정한 주기로 수집하여 DB에 저장 후 조회 시 저장된 정보 제공
장점	- 조회 요청이 발생하는 시점의 최신 리소스 정보를 제공 (정보의 실시간성 ↑) - 요청한 리소스에 대한 정보만 조회 가능 (데이터 전송효율 ↑)	데이터 요청 시 저장되어 있는 정보를 즉각 제공 가능 (데이터 제공 속도 ↑)
단점	데이터 요청 시 조회를 수행하므로 처리에 시간 소요 (데이터 제공 속도 ↓)	전체 리소스를 수집 해야하므로 데이터 조회 및 전송 시간으로 인한 수집 주기 최소화 한계 (정보의 실시간성 ↓)
Tradeoff	(Performance) 데이터 조회 응답성 ※ SSH 를 통한 실시간 정보 조회 : 평균: 1.93 sec 최대: 7.1 sec ★★★ (Usability) 최신 데이터 제공 ※ 정보 조회 속도와 동일 ★★★ (Reliability) 단일 장애점 (가용성 보장된 외부 시스템 활용) ★★★	(Performance) 데이터 조회 응답성 ※ System Service에서 DB 조회 완료 : 평균 : 0.239 sec 최대: 0.427 sec ★★★ (Usability) 최신 데이터 제공 ※ 정보 전체 조회 : 평균 15 sec (409명) ★★★ (Reliability) 단일 장애점 (서비스 문제 시 데이터 수집 장애) ※ 이중화 설계를 통한 보완 ★★☆☆

DP3. 슈퍼컴 리소스 데이터 조회

Legend 방화벽

→ 데이터 → 제어

내부
모듈

내부
시스템

외부
모듈

외부
시스템

F6 - 리소스 모니터링

Q1 - 데이터 조회 응답성

C1 - 독립 네트워크 환경


Q4 - 데이터 전송 보장

	(1안) On demand Pull 방식	(2안) scheduled push 방식 [채택]
설계안	<< Supercom >> << System >>	수집 주기 최소화 보완 설계 ※ 시스템 로그 분석으로 하루 중 동시 접속 session 최대 38명으로 확인 (Session 유지 기준: 5분간 신규 요청이 없는 경우 이탈로 간주) 전체 조회 15s 접속자 조회 5.8s 1 주기적으로 GPU Node 전체와 모든 Job 정보를 취득하여 DB에 저장 2 사용자 리소스 조회 요청 시 DB에 저장되어 있는 정보 반환 3 접속자와 연관된 정보만 추가 조회 1 System에 접속하여 session을 유지하고 있는 접속자 리스트 업데이트 << Supercom >> << System >>
핵심	조회 요청이 발생하는 시점에 Login s	에 저장 후 조회 시 저장된 정보 제공
장점	- 조회 요청이 발생하는 시점의 최신 - 요청한 리소스에 대한 정보만 조회	가능 (데이터 제공 속도 ↑)
단점	데이터 요청 시 조회를 수행하므로 처리에 시간 소요 (데이터 제공 속도 ↓)	전체 리소스를 수집 해야하므로 데이터 조회 및 전송 시간으로 인한 수집 주기 최소화 한계 (정보의 실시간성 ↓) ※ 정보 전체 조회 : 평균 15 sec (409명)
Tradeoff	(Performance) 데이터 조회 응답성 ※ SSH를 통한 실시간 정보 조회 : 평균: 1.93 sec 최대: 7.1 sec ★★★ (Usability) 최신 데이터 제공 ※ 정보 조회 속도와 동일 ★★★ (Reliability) 단일 장애점 (가용성 보장된 외부 시스템 활용) ★★★	(Performance) 데이터 조회 응답성 ※ System Service에서 DB 조회 완료 : 평균 : 0.239 sec 최대: 0.427 sec ★★★ (Usability) 최신 데이터 제공 ※ 보완 설계를 통해 정보 delay : 평균 5.8 sec (38명) ★★★ (Reliability) 단일 장애점 (서비스 문제 시 데이터 수집 장애) ※ 이중화 설계를 통한 보완 ★★☆☆





Architectural Driver Design Point	F1. 실험 이력 관리	F2. 실험 산출물 관리	F3. 보안 데이터 관리	F4. 평가 자동화	F5. 실험 결과 재현	F6. 리소스 모니터링	Q1. 데이터 조회 응답성	Q2. GPU 대기 시간	Q3. 보안 데이터 활용	Q4. 데이터 전송 보장	Q5. 환경 구성 편의성	Q6. 서비스 배포 용이성	C1. 독립 네트워크 환경	C2. 보안 데이터 규정
DP1. 보안 데이터 슈퍼컴 내 제공 방안														
DP2. 실험 이력 데이터 조회														
DP3. 슈퍼컴 리소스 데이터 조회														
DP4. 산출물/모델 저장 효율화														
DP5. 평가 수행 환경 구축 자동화														
Coverage														

설계 안 적용 Architecture (Module View)


Presentation



Business



Repository



DP1	보안 데이터 슈퍼컴 내 제공 Q2 + Q3 + Q4
DP2	실험 이력 데이터 조회 Q1 + Q4 + Q6
DP3	슈퍼컴 리소스 데이터 조회 Q1 + Q4
DP4	산출물/모델 저장 효율화 Q2 + Q6
DP5	평가 수행 환경 구축 자동화 Q5




구현 및 검증


ASR 를 모두 만족하였는지 확인
(특히 품질속성)

품질 확보를 위한 프로세스

- ✓ Agile 기반 개발 프로세스 – SAIT software society 표준 Agile 개발 프로세스 준수
- ✓ 프로세스 및 문서 관리 – JIRA/Confluence 기반 Task / Item 관리



- ✓ Jenkins 기반 CI/CD – PR 단위 지표 산출 수행 및 dev/stage 배포 자동화
- ✓ 코드 리뷰 의무화 – 팀 내 Code Review Ground Rule 준수를 통한 코드 품질 향상



< Code review bot 기반 정적 분석 >

< Branch protection : Min 2 Approve >

코드 품질


- ✓ SAM (Software Architecture Maturity) 활용한 코드 품질 측정
→ 4.0 이상으로 품질 지표 만족



<JavaScript: Frontend / Backend>

<Python: Service / Client>

- ✓ Unit Test 수행 및 시나리오 기반 시스템 Test 수행
→ TEM : 4.1 달성



< Pull Request 단위 Unit Test 자동 수행 >

< 기능 검증 Test 시나리오 리스트 >

기능 요구사항 검증

과제 소개 > 요구사항 > 설계 > 구현/검증 > 성과

F1.실험 이력 관리, F2.실험 산출물 관리


Project: yho/ja/ai-rmsc

Job ID	Job Name	Start Time	Duration	Type	Status	Progress	Log
AI-2024-10-10-000001	job-0001	2024-10-10 00:00:00	00:01:00	train	Success	100%	view
AI-2024-10-10-000002	job-0002	2024-10-10 00:01:00	00:01:00	train	Success	100%	view
AI-2024-10-10-000003	job-0003	2024-10-10 00:02:00	00:01:00	train	Success	100%	view
AI-2024-10-10-000004	job-0004	2024-10-10 00:03:00	00:01:00	train	Success	100%	view
AI-2024-10-10-000005	job-0005	2024-10-10 00:04:00	00:01:00	train	Success	100%	view
AI-2024-10-10-000006	job-0006	2024-10-10 00:05:00	00:01:00	train	Success	100%	view
AI-2024-10-10-000007	job-0007	2024-10-10 00:06:00	00:01:00	train	Success	100%	view
AI-2024-10-10-000008	job-0008	2024-10-10 00:07:00	00:01:00	train	Success	100%	view
AI-2024-10-10-000009	job-0009	2024-10-10 00:08:00	00:01:00	train	Success	100%	view
AI-2024-10-10-000010	job-0010	2024-10-10 00:09:00	00:01:00	train	Success	100%	view

<실험 이력 제공>




<Metric 시각화>



<산출물 조회/관리>

F6.모니터링



<Job, GPU, quota Dashboard>

F3.보안 데이터 관리

EDM Uploader

File Name	Upload Time	Status
data-0001.csv	2024-10-10 00:00:00	Success
data-0002.csv	2024-10-10 00:01:00	Success
data-0003.csv	2024-10-10 00:02:00	Success
data-0004.csv	2024-10-10 00:03:00	Success
data-0005.csv	2024-10-10 00:04:00	Success
data-0006.csv	2024-10-10 00:05:00	Success
data-0007.csv	2024-10-10 00:06:00	Success
data-0008.csv	2024-10-10 00:07:00	Success
data-0009.csv	2024-10-10 00:08:00	Success
data-0010.csv	2024-10-10 00:09:00	Success

<Data 수집>

Dataset Catalog

Dataset Name	Type	Update By	Updated At
UCI_L101_AIRBORNE_SAM_AIRBORNE_DAT	UCS	ja-hw	2024-10-16
UCI_L101_AIRBORNE_SAM_AIRBORNE_DAT	UCS	ja-hw	2024-10-16
UCI_L101_AIRBORNE_SAM_AIRBORNE_DAT	UCS	ja-hw	2024-10-16
UCI_L101_AIRBORNE_SAM_AIRBORNE_DAT	UCS	ja-hw	2024-10-16
UCI_L101_AIRBORNE_SAM_AIRBORNE_DAT	UCS	ja-hw	2024-10-16
UCI_L101_AIRBORNE_SAM_AIRBORNE_DAT	UCS	ja-hw	2024-10-16
UCI_L101_AIRBORNE_SAM_AIRBORNE_DAT	UCS	ja-hw	2024-10-16
UCI_L101_AIRBORNE_SAM_AIRBORNE_DAT	UCS	ja-hw	2024-10-16
UCI_L101_AIRBORNE_SAM_AIRBORNE_DAT	UCS	ja-hw	2024-10-16
UCI_L101_AIRBORNE_SAM_AIRBORNE_DAT	UCS	ja-hw	2024-10-16

<Data Catalog>

F4.평가 자동화, F5.실험 결과 재현

Create Evaluation

Eval Module: In-Env, Serve, Evaluate

Type: Convert, Serve, Evaluate, Evaluate, Evaluate, Model Convert

Serving Type: TGI, VLLM

Evaluation

project_name: LLM_Evaluation

model_name: SAM_EB

output_path: /home/ubuntu/llm-eval-result

Taskset: Total 15, TaskSet: public_benchmark(2), public_in-eval(4-4-20), public_in-eval(16)

<평가 자동화 설정>

Job

Job ID	Name	User ID	Project	Model	GPU	GPU	Status	Taskset	Start Time	End Time
11020000	public_benchmark(2)	ja-hw	LLM_Evaluation	SAM_EB	100%	100%	Success	public_benchmark(2)	2024-10-16 00:00:00	2024-10-16 00:01:00
11020001	public_in-eval(4-4-20)	ja-hw	LLM_Evaluation	SAM_EB	100%	100%	Success	public_in-eval(4-4-20)	2024-10-16 00:01:00	2024-10-16 00:02:00
11020002	public_in-eval(16)	ja-hw	LLM_Evaluation	SAM_EB	100%	100%	Success	public_in-eval(16)	2024-10-16 00:02:00	2024-10-16 00:03:00
11020003	public_benchmark(2)	ja-hw	LLM_Evaluation	SAM_EB	100%	100%	Success	public_benchmark(2)	2024-10-16 00:03:00	2024-10-16 00:04:00
11020004	public_in-eval(4-4-20)	ja-hw	LLM_Evaluation	SAM_EB	100%	100%	Success	public_in-eval(4-4-20)	2024-10-16 00:04:00	2024-10-16 00:05:00
11020005	public_in-eval(16)	ja-hw	LLM_Evaluation	SAM_EB	100%	100%	Success	public_in-eval(16)	2024-10-16 00:05:00	2024-10-16 00:06:00
11020006	public_benchmark(2)	ja-hw	LLM_Evaluation	SAM_EB	100%	100%	Success	public_benchmark(2)	2024-10-16 00:06:00	2024-10-16 00:07:00
11020007	public_in-eval(4-4-20)	ja-hw	LLM_Evaluation	SAM_EB	100%	100%	Success	public_in-eval(4-4-20)	2024-10-16 00:07:00	2024-10-16 00:08:00
11020008	public_in-eval(16)	ja-hw	LLM_Evaluation	SAM_EB	100%	100%	Success	public_in-eval(16)	2024-10-16 00:08:00	2024-10-16 00:09:00
11020009	public_benchmark(2)	ja-hw	LLM_Evaluation	SAM_EB	100%	100%	Success	public_benchmark(2)	2024-10-16 00:09:00	2024-10-16 00:10:00

<평가 결과 확인/재현>

ID	QA	Refinement	Scenario	Response Measure	Measurement	Pass/Fail
Q1	Performance	데이터 조회 응답성	데이터 조회를 빠르게 수행할 수 있어야 한다	데이터 요청 후 제공까지 걸리는 시간 $\leq 3 \text{ sec}$ ✓ 실험 이력 조회 페이지 응답 속도 측정 ✓ 슈퍼컴 리소스 조회 페이지 응답 속도 측정	실험 이력 조회 : 평균 2.12 sec 슈퍼컴 리소스 조회 : 평균 0.98 sec	Pass
Q2	Performance	GPU 대기 시간	학습/평가 중 데이터 처리를 위해 GPU가 대기하는 시간을 최소화 해야 한다	데이터 처리 목적의 GPU 대기시간 $< 51.1 \text{ sec}$ (10GB 기준) ✓ GPU 점유 중 시스템 작업을 인한 대기 시간 측정 (10GB 기준)	대기시간 $\leq$ 평균 10.9 sec	Pass
Q3	Security	데이터 보안	슈퍼컴에서 보안 데이터는 사용 후 삭제 해야하며 장기 보관하지 말아야 한다	사용 종료 후 삭제 보안 위규 발생 건수 0건 ✓ 다운로드 및 삭제 System Log 확인 ✓ 파일 삭제 여부 확인	보안 위규 발생 0건	Pass
Q4	Reliability	데이터 전송 보장	데이터 전송 중 누락이 발생하지 않아야 한다	(누락 데이터/ 전체 데이터) $\times 100 < 0.01\%$ ✓ 운영 중 System Error Log 확인 및 장애 VoE 수집	데이터 전송 누락 0% (0건)	Pass
Q5	Usability	환경 구성 편의성	모델 학습/평가를 위한 개발 환경 구축이 용이 해야 한다	환경 구성을 위해 패키지 수동 설치 횟수 1회 이하 ✓ 개발 환경 구축 테스트, 수동 설치 횟수 검증	수동 설치 횟수 0회	Pass
Q6	Maintainability	서비스 배포 용이성	기능 추가 및 수정을 위한 유지보수가 수월 해야 한다	기능 추가 및 수정의 적용을 위한 재배포 필요 서비스 개수 1개 이하 ✓ 시스템 Logic 유지보수 시 재배포 서비스 개수 ✓ Client 재배포 횟수	서비스 1개 이하 배포 (Client 재배포 횟수 0회)	Pass



품질 속성 검증

Q1	Performance	데이터 조회 응답성	데이터 조회를 빠르게 수행할 수 있어야 한다	데이터 요청 후 제공까지 걸리는 시간 $\leq 3 \text{ sec}$ ✓ 실험 이력 조회 페이지 응답 속도 측정 ✓ 슈퍼컴 리소스 조회 페이지 응답 속도 측정	실험 이력 조회 : 평균 2.12 sec 슈퍼컴 리소스 조회 : 평균 0.98 sec	Pass
----	-------------	------------	--------------------------	--	---	------



■ 데이터 요청부터 제공까지 걸리는 시간 측정 결과

- Chrome driver 및 Selenium 사용하여 페이지 로딩 반복 테스트 수행. 100회 평균

업무 중 수집한 자료나
테스트 결과를
통계적인 수치로 제공



< 실험 이력 조회 페이지 응답 속도 측정 : 평균 2.12 sec >



< 슈퍼컴 리소스 조회 페이지 응답 속도 측정 : 평균 0.98 sec >


Q2	Performance	GPU 대기 시간	학습/평가 중 데이터 처리를 위해 GPU가 대기하는 시간을 최소화해야 한다 데이터 처리 목적의 GPU 대기시간 < 51.1 sec (10GB 기준) ✓ GPU 점유 중 시스템 작업을 인한 대기 시간 측정 (10GB 기준)	대기시간 ≤ 평균 10.9 sec	Pass
----	-------------	-----------	---	---------------------------	------

PoC 로 실험한 결과나 특정 상황을 가정한 실험도 유의미한 결과를 제공할 수 있다면 활용하는 것을 추천

■ 데이터 전송 관련 처리로 인해 발생하는 GPU 대기 시간 측정



- 10GB random data 생성 후 이를 처리(전송) 하는데 걸리는 시간 측정. 100회 평균

< DP1 채택 안의 데이터 전송 시간 : 평균 7.6 sec >



구분	방식	평균 전송 속도
Office local PC → Supercom	SFTP	124.8 sec
S3 Storage → Supercom	HTTP	51.1 sec
NFS Storage → GPU Node	NFS	7.6 sec

< DP4 채택 안의 데이터 처리(중복 검사) 시간 : 평균 10.9 sec >



< BLAKE3 256 hash 생성 평균 속도 측정 결과 >

품질 속성 검증

Q3	Security	데이터 보안	슈퍼컴에서 보안 데이터는 사용 후 삭제 해야하며 장기 보관하지 말아야 한다	사용 종료 후 삭제 보안 위규 발생 건수 0건 ✓ 다운로드 및 삭제 System Log 확인 ✓ 파일 삭제 여부 확인	보안 위규 발생 0건	Pass
----	----------	--------	---	---	-------------	------

■ 보안 데이터 사용 이력 확인

- 최근 한달 평가 수행 이력 (동일 날짜 숨김처리)

Job Id	Status	Member Id	Submit Time	Queue	Command	
1	11764853	Done	368	2024-10-11 12:00:11.760381	sam_llm_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
2	11758211	Done	287	2024-10-11 08:25:54.772665	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
3	11733402	Done	368	2024-10-10 17:20:56.866771	sam_llm_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
22	11724115	Done	211	2024-10-10 10:30:17.442950	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
23	11680172	Done	226	2024-10-09 12:00:52.384712	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
24	11609816	Done	226	2024-10-07 11:37:32.785040	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
48	11609484	Done	382	2024-10-07 11:11:40.237027	sam_mmmf_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
49	11538276	Done	226	2024-10-04 18:29:04.366256	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
55	11522876	Done	363	2024-10-04 10:25:30.261656	sam_mmmf_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
56	11493291	Done	382	2024-10-03 17:29:48.371308	sam_mmmf_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
68	11489304	Done	382	2024-10-03 15:20:51.778020	sam_mmmf_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
69	11381098	Done	287	2024-09-30 16:52:08.203663	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
75	11377552	Done	287	2024-09-30 10:40:13.562544	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
76	11342109	Done	287	2024-09-27 15:39:23.021390	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
77	11332186	Done	364	2024-09-27 08:24:05.158864	sam_code_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
78	11308974	Done	364	2024-09-26 15:53:12.823951	sam_code_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
89	11303104	Done	364	2024-09-26 08:29:17.888639	sam_code_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
90	11269815	Done	382	2024-09-25 17:52:58.074987	sam_mmmf_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
91	11267467	Done	364	2024-09-25 17:06:47.291895	sam_code_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
92	11228439	Done	364	2024-09-24 17:01:06.913059	sam_code_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
93	11180876	Done	45	2024-09-23 13:55:59.985609	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
110	11175168	Done	287	2024-09-23 09:19:03.696246	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
111	11123343	Done	1	2024-09-21 14:45:27.826354	sam_platform_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
118	1135	11089960	Done	1	2024-09-20 11:17:36.000000	sam_platform_gpu ['sh', '/home/sr5/AISW/evaluation/scrip
119	1136	11054219	Done	211	2024-09-19 14:57:22.526447	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip
136	1142	11053437	Done	211	2024-09-19 14:18:06.294943	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip
143	10824168	Done	287	2024-09-13 15:51:59.155775	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
149	109449	10818540	Done	211	2024-09-13 13:45:42.893827	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip
150	10799933	Done	92	2024-09-12 07:02:06.043556	sam_platform_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
151	10727388	Done	92	2024-09-11 17:42:55.234597	sam_platform_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
159	10711694	Done	211	2024-09-11 07:43:16.752740	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
160	10695355	Done	15	2024-09-10 20:41:45.142966	sam_mmmf_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
176	10695337	Done	15	2024-09-10 20:41:40.206347	sam_mmmf_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
177	10672628	Done	211	2024-09-09 15:42:07.919659	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	
202	10666115	Done	287	2024-09-09 08:49:10.760119	sam_video_gpu ['sh', '/home/sr5/AISW/evaluation/scrip	


<보안 다운로드>

3일 초과 시점

→ 16일 보안 데이터 슈퍼컴에서 삭제

→ 19일 S3 -> 슈퍼컴 으로 보안 데이터 다운로드 수행

< 평가 Job 수행 이력 >



<보안 데이터 다운로드/삭제 이력>

```

2024-09-16 15:37:07 [19271] [INFO] Req: {'experiment_id': 'ec2d9c424bf34b8aa5fcca4bd883705'}, Res: {'return': 1}
2024-09-16 15:37:07 [19271] [INFO] 172.18.0.2 - - [16/Sep/2024:15:37:07 +0900] "PUT /api/db/runs/update-time HTTP/1.1" 200 13 "-" "python-req
2024-09-16 15:40:28 [19271] [INFO] Req: {'experiment_id': 'a6016615db4e4d9f861e6c8c41fa728b'}, Res: {'return': 1}
2024-09-16 15:40:28 [19271] [INFO] 172.18.0.2 - - [16/Sep/2024:15:40:28 +0900] "PUT /api/db/runs/update-time HTTP/1.1" 200 13 "-" "python-req
2024-09-16 15:41:07 [19273] [INFO] Req: {'dataset_id': '6f4f4d320c7d476d999b12eac26ca8c', 'exp': 'expired'}, Res: {'return': 'done'}
2024-09-16 15:41:07 [19273] [INFO] 172.18.0.2 - - [16/Sep/2024:15:41:07 +0900] "DELETE /api/dataset/remove_cache HTTP/1.1" 200 13 "-" "python
2024-09-16 15:43:54 [19273] [INFO] Req: {'experiment_id': '4c0d3c58fa964ed29db0bb5d3ab0eca'}, Res: {'return': 1}
2024-09-16 15:43:54 [19273] [INFO] 172.18.0.2 - - [16/Sep/2024:15:43:54 +0900] "PUT /api/db/runs/update-time HTTP/1.1" 200 13 "-" "python-req
2024-09-16 15:54:21 [19273] [INFO] Req: {'experiment_id': '4c0d3c58fa964ed29db0bb5d3ab0eca'}, Res: {'return': 1}
2024-09-16 15:54:21 [19273] [INFO] 172.18.0.2 - - [16/Sep/2024:15:54:21 +0900] "PUT /api/db/runs/update-time HTTP/1.1" 200 13 "-" "python-req

```

< 보안 데이터 삭제
로그 >

```

2024-09-19 14:11:05 [19268] [INFO] Req: {'experiment_id': '6f4f4d320c7d476d999b12eac26ca8c', 'member_id': 211}, Res: {'return': 1}
2024-09-19 14:11:05 [19268] [INFO] 172.18.0.2 - - [19/Sep/2024:14:11:05 +0900] "PUT /api/db/runs/update-time HTTP/1.1" 200 13 "-" "python-req
2024-09-19 14:14:32 [19273] [INFO] Req: {'dataset_id': '6f4f4d320c7d476d999b12eac26ca8c', 'member_id': 211}, Res: {'return': 1}
2024-09-19 14:14:32 [19273] [INFO] 172.18.0.2 - - [19/Sep/2024:14:14:32 +0900] "GET /api/dataset/s3-download HTTP/1.1" 200 13 "-" "python-req
2024-09-19 14:21:06 [19273] [INFO] Req: {'experiment_id': '6f4f4d320c7d476d999b12eac26ca8c', 'member_id': 211}, Res: {'return': 1}
2024-09-19 14:21:06 [19273] [INFO] 172.18.0.2 - - [19/Sep/2024:14:21:06 +0900] "PUT /api/db/runs/update-time HTTP/1.1" 200 13 "-" "python-req
2024-09-19 14:32:28 [19273] [INFO] args: {'experiment_id': '9261616eae03417fb581b8879409cc6e', 'project_id': 1241, 'solve_type': 'basic',
, 'member_id': 16, 'job_info': "11053822>8<yh0.jo>8<yh0.jo:QAT_PreOnly_7_1020_NonUniform_opt0826_Bittage7_LWwP2R_GradFirst_Step2000>8<R
ogin05>8</home/sr5/yh0.jo/code/airmsc>8<phd_logs/11053822.log>8<2024-09-19 14:33:42>8<['python', 'runner.py', '--opt_path', 'config/QAT_P
rm_opt0826_Bittage7_LWwP2R_GradFirst_Step2000.yaml', '--bug fix', '--resume', '--model_args.qat_layerwise_s

```

< 보안 데이터 다운로드
로그 >

성과 및 교훈

성과 및 교훈

과제 소개

요구사항

설계

구현/검증

성과

■ 주요 성과

- 슈퍼컴 내 보안규정에 맞는 데이터 제공을 통한 LLM 성능 향상
 - LLM의 정량적 평가 자동화 및 Benchmark 성능 이력 제공을 통한 LLM 품질 확보
 - LLM을 비롯한 AI 모델의 이력/산출물 관리를 통한 개발 효율성 증대 및 사용성 개선
- 사용자 만족도 조사 결과 (*CSAT score: 85.6점)

Customer SATisfaction score

설문 기간: 10/4 ~ 10/15

설문 대상 인원: 106명

최종 만족도 점수: **85.6점**

$$CSAT = \frac{\text{매우만족} + \text{만족}}{\text{전체 응답자}} \times 100 \quad (\text{각 항목 산술 평균 계산})$$

■ 향후 계획

- 데이터 기반 학습 자동화 시스템으로 확장
- Multi-modal Foundation Model 을 위한 기능 확장
- 모델 배포 및 서비스를 포함한 Full cycle LLMOps/FMOps 지원하는 서비스로 확장

■ As an Architect

- 요구사항의 중요성 (아무리 잘 만들어도 안쓰거나 못쓰는 기능 발생)
- 협의 & 설득... 그리고 설득! 조율과 중재의 역할
- 아는 만큼 보인다

당신의 성격 유형은 :
열정적인 중재자

INFP-T




Appendix

요구사항 수집 및 정제

Confidential


■ 주요 Stakeholder 선정 및 주요 관심사



■ 인터뷰를 통한 Pain point 및 주요 기능 선별

Stage	Data 준비 / 관리		Experiment 생성/관리				실험/재실험		실험 결과/평가			배포/관리	
Action	요구사항 전달	데이터 업로드	데이터 가공/관리	실험 생성/관리		실험 실행/관리	실험 결과/평가		실험 결과/평가	실험 결과/평가	실험 결과/평가	실험 결과/평가	실험 결과/평가
Stage	각 그룹	파트너사	각 그룹	각 그룹		각 그룹	각 그룹		각 그룹	각 그룹	각 그룹	각 그룹	각 그룹
Channel	메일	CD 디바이스? 이메일 local... > 유무	슬루싱확인유무? Local?	Pycharm유무		Pycharm유무	Pycharm유무		Pycharm유무	Pycharm유무	Pycharm유무	Pycharm유무	Pycharm유무
(Pain-point/ Needs)	데이터 관리자	중복된 요구사항이나 데이터 요청이 있는지 파악이 안됨	수퍼컴에 저장된 데이터 버전 관리가 안되고 있으며 동일한 데이터가 존재함										
데이터 Engineer			데이터 버전 관리 및 Error Case 분석이 쉽지 않음 내기 테스트하는 데이터 버전 관리가 필요함										
알고리즘 연구자			데이터 버전 관리가 안되고 있으며 동료와 사용된 모델도 확인이 어려움, 데이터 버전 관리가 버전 변경이 어렵고 내역이 필요함										
배포자													
관리자													

Stakeholder	주요 관심 사항
LLM 모델 연구원 (ooo xxx님 외)	이력 확인 용이성, 모델 개발 편리성, 재현 용이성,
LLM 응용 개발자 (ooo xxx님 외)	이력 확인 용이성, 평가 수행 용이성,
LLM 품질 관리자 (ooo xxx님 외)	평가 수행 용이성, 재현 용이성
데이터 관리자 (ooo xxx님 외)	데이터 수집 및 전처리 편리성 데이터 보안성
시스템 개발자	시스템 변경 용이성, 개발 용이성, 유지보수성,
슈퍼컴 운영자 (ooo xxx님 외)	슈퍼컴 운영 안정성, 슈퍼컴 운영 정책 준수
보안 담당자 (ooo xxx님 외)	보안 데이터 관리, 보안 규정 준수



품질 속성 기준 (1/2)

★★★	품질 속성을 모두 달성. 품질속성에 대한 최적의 선택
★★☆	품질 속성을 부분적으로 달성.
★☆☆	품질 속성을 거의 달성하지 못 함. 반드시 보완책이 필요

Confidential



Performance	데이터 조회 응답성	데이터 조회를 빠르게 수행할 수 있어야 한다 [데이터 요청 후 제공까지 걸리는 시간 ≤ 평균 3 sec] 응답 시간 별 사용자 페이지 이탈률 통계 기준
Performance	GPU 대기 시간	학습/평가 중 데이터 처리를 위해 GPU가 대기하는 시간을 최소화 해야 한다 [데이터 처리 목적의 GPU 대기시간 ≤ 평균 51.1 sec] (10GB 기준) 슈퍼컴으로 데이터 10GB 전송을 위해 평균 GPU 대기 시간 기준
Security	보안 데이터 활용	슈퍼컴에서 보안 데이터는 사용 후 삭제 해야하며 장기 보관하지 말아야 한다 [보안 데이터 사용 종료 후 미 삭제 위규 0건] 보안 담당자와 슈퍼컴에서 보안 데이터 사용에 관한 협의 후 결정 사항

품질 속성 평가 시 사용한 지표
Trade-off 평가 시 모두 동일한 기준을 사용하여 평가

Q1. 데이터 조회 응답성

	사용자의 조회 요청에 데이터 지공까지 걸리는 시간
★★★	1.5 sec (50%)
★★☆	3 sec
★☆☆	

- 사용자의 데이터 요청 후 페이지 제공까지 ≤ 3sec를 만족해야하는 기준으로 설정.
(Google 의 페이지 로딩 시간 별 페이지 이탈률 통계 기준)
- DP에서는 데이터 조회 시간만을 고려하여 평가

Q2. GPU 대기 시간

	학습 중 데이터 처리 목적으로 GPU가 대기하는 시간
★★★	25.5 sec (50%)
★★☆	51.1 sec (학습 중 GPU 대기시간)
★☆☆	

- 슈퍼컴망 내/외부로 SFTP를 통해 데이터를 전송 시 평균 51.1sec 필요함을 실험적으로 확인.
이를 시스템 설계 시 만족해야 할 기준으로 설정
- DP에서는 시스템으로 인해 GPU가 대기하는 시간 최소화를 고려하여 평가

Q3. 보안 데이터 활용

	보안 위규 발생 가능성
★★★	이력 관리
★★☆	데이터 자동 삭제 보장
★☆☆	

- 시스템을 통해 보안 데이터를 제공할 때, 사용 완료 후 데이터의 자동 삭제를 보장 할 수 있는가를 기준으로 설정
- DP에서는 데이터 관리 이력을 쉽게 확인할 수 있는지 추가 고려하여 평가

품질 속성 기준 (2/2)

★★★	품질 속성을 모두 달성. 품질속성에 대한 최적의 선택
★★☆	품질 속성을 부분적 으로 달성.
★☆☆	품질 속성을 거의 달성하지 못 함 . 반드시 보완책 이 필요

Confidential



Reliability	데이터 전송 보장	데이터 전송 중 누락이 발생하지 않아야 한다 [(누락 데이터/ 전체 데이터) x 100] < 0.01%	H	M	4	Q4
Usability	환경 구성 편의성	모델 학습/평가를 위한 개발 환경 구축이 용이 해야 한다 [환경 구성을 위해 패키지 수동 설치 횟수 1회 이하]	M	H	5	Q5
Maintainability	서비스 배포 용이성	기능 추가 및 수정을 위한 유지보수가 수월 해야 한다 [기능 추가 및 수정의 적용을 위한 재배포 필요 서비스 개수 1개 이하] • (인터페이스 수정 외) 사용자의 재설치를 필요로 하는 System Client 재배포 지양	M	H	6	Q6

Q4. 데이터 전송 보장

	시스템 장애로 인한 데이터 전송 실패 확률
★★★	
★★☆	데이터 전송 누락 확률 없음 (SPOF 없음)
★☆☆	데이터 전송 누락 확률 최소화 방안 유/무

- 이력/산출물의 관리를 위해 슈퍼컴 외부로 데이터를 전송하는 모듈에 대해 시스템 가용성을 보장할 수 있는 설계 유/무를 기준으로 설정
- DP에서는 SPOF의 유무를 주로 평가

Q5. 환경 구성 편의성

	수동 패키지 설치 횟수
★★★	
★★☆	0회 (자동화)
★☆☆	1회 이하

- 학습/평가를 위한 개발 환경 구성에 필요한 수동 패키지 설치를 최소화 하기 위해 1회를 기준으로 설정 (LLM 평가 앱 lm-harness 기준 15회)


Q6. 서비스 배포 용이성

	유지보수를 위한 재배포가 필요한 서비스 개수
★★★	
★★☆	Client 재배포 여부
★☆☆	1개 이하


- Dependency를 낮춰 기능의 추가 및 수정 시 재배포 해야하는 서비스의 개수가 최소화 되도록 1개 이하를 기준으로 설정.
- DP에서는 Client의 재배포 필요 여부를 주로 평가 (사용자의 사용성 문제 및 Legacy 버전 호환 문제와 연결되므로 감점 요인)

■ 페이지 로딩 시간과 페이지 이탈률(bounce rate)

- 페이지 로딩에 3초 이상 걸릴 경우 페이지 이탈률이 크게 증가 함



[로딩 시간에 따른 Page 이탈률]



[AS-WAS 실험 이력 조회 페이지 로딩 시간]

*리소스 정보 조회 페이지 로딩 평균 0.7sec

DP1. GPU 대기 시간 비교

■ 파일 전송 시간 비교

- 10 GB 파일 전송 기준 (100회 평균)

구분	방식	평균 전송 속도 (sec)	Min	Max
Office local PC → Supercom	SFTP	124.8	113.2	135.7
S3 Storage → Supercom	HTTP	51.1	47.6	59.6
NFS Storage → GPU Node	NFS	7.6	7.2	9.4

■ 보안 데이터 사용 빈도

- 최근 한달 평가 수행 이력 (동일 날짜 숨김처리)

Job Id	Status	Member Id	Submit Time	Queue	Command
1	Done	368	2024-10-11 12:00:11.760381	sam_llm_gpu	['sh', '/home/sr5/AISW/evaluation/scr
4	Done	287	2024-10-11 08:25:54.772665	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
5	Done	368	2024-10-10 17:20:56.366771	sam_llm_gpu	['sh', '/home/sr5/AISW/evaluation/scr
22	Done	211	2024-10-10 10:30:17.442950	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
23	Done	226	2024-10-09 12:00:52.384712	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
24	Done	226	2024-10-07 11:37:32.785040	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
48	Done	382	2024-10-07 11:14:02.37027	sam_mmfm_gpu	['sh', '/home/sr5/AISW/evaluation/scr
49	Done	226	2024-10-04 18:29:04.366256	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
55	Done	363	2024-10-04 10:25:30.261656	sam_mmfm_gpu	['sh', '/home/sr5/AISW/evaluation/scr
56	Done	382	2024-10-03 17:29:48.371308	sam_mmfm_gpu	['sh', '/home/sr5/AISW/evaluation/scr
68	Done	382	2024-10-03 15:20:51.778020	sam_mmfm_gpu	['sh', '/home/sr5/AISW/evaluation/scr
69	Done	287	2024-09-30 16:52:08.203663	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
75	Done	287	2024-09-30 10:40:13.562544	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
76	Done	287	2024-09-27 15:39:23.021390	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
77	Done	364	2024-09-27 08:24:05.158864	sam_code_gpu	['sh', '/home/sr5/AISW/evaluation/scr
78	Done	364	2024-09-26 15:53:12.823951	sam_code_gpu	['sh', '/home/sr5/AISW/evaluation/scr
89	Done	364	2024-09-26 08:29:17.888639	sam_code_gpu	['sh', '/home/sr5/AISW/evaluation/scr
90	Done	382	2024-09-25 17:52:58.074987	sam_mmfm_gpu	['sh', '/home/sr5/AISW/evaluation/scr
91	Done	364	2024-09-25 17:06:47.291895	sam_code_gpu	['sh', '/home/sr5/AISW/evaluation/scr
92	Done	364	2024-09-24 17:01:06.913059	sam_code_gpu	['sh', '/home/sr5/AISW/evaluation/scr
93	Done	45	2024-09-23 13:55:59.985609	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
110	Done	287	2024-09-23 09:19:03.696246	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
111	Done	11089960	2024-09-20 11:17:36.000000	sam_platform_gpu	['sh', '/home/sr5/AISW/evaluation/scr
112	Done	211	2024-09-19 14:57:22.526447	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
113	Done	211	2024-09-19 14:18:06.294943	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
114	Done	287	2024-09-13 15:51:59.155775	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
115	Done	211	2024-09-13 13:45:42.893827	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
150	Done	92	2024-09-12 07:30:24.34332	sam_platform_gpu	['sh', '/home/sr5/AISW/evaluation/scr
151	Done	92	2024-09-11 17:42:55.234597	sam_platform_gpu	['sh', '/home/sr5/AISW/evaluation/scr
159	Done	211	2024-09-11 07:43:16.752740	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
160	Done	15	2024-09-10 20:41:45.142966	sam_mmfm_gpu	['sh', '/home/sr5/AISW/evaluation/scr
167	Done	15	2024-09-10 20:41:40.206347	sam_mmfm_gpu	['sh', '/home/sr5/AISW/evaluation/scr
177	Done	211	2024-09-09 15:42:07.919659	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr
202	Done	287	2024-09-09 08:49:10.760119	sam_video_gpu	['sh', '/home/sr5/AISW/evaluation/scr

3일 초과 시점

→ 16일 보안 데이터 슈퍼컴에서 삭제

→ 19일 (S3 → 슈퍼컴) 보안 데이터 다운로드 수행

보안 데이터 리스트

xxxx_xxxx	1.4G
oooo_oooo	29G
yyyyy_yyyy	12G
ggggg_gggg	27M
dddd_dddd	799K

< 보안 데이터 예시 >

DP1. 설계 안 QA 측정

1 시스템을 통한 데이터 복호화 및 전송 [채택]

2 슈퍼컴 스토리지를 통한 데이터 전송


Confidential



Performance	GPU 대기 시간	학습/평가 중 데이터 처리를 위해 GPU가 대기하는 시간을 최소화 해야 한다 [데이터 처리 목적의 GPU 대기시간 ≤ 평균 51.1 sec] (10GB 기준)	Q2
Security	보안 데이터 활용	슈퍼컴에서 보안 데이터는 사용 후 삭제 해야하며 장기 보관하지 말아야 한다 [보안 데이터 사용 종료 후 미 삭제 위규 0건]	Q3
Reliability	데이터 전송 보장	데이터 전송 중 누락이 발생하지 않아야 한다 [(누락 데이터/ 전체 데이터) x 100] < 0.01%	Q4


Q2. GPU 대기 시간

학습/평가 시작 후 데이터를 읽기 위해 GPU 연산을 대기하고 기다리는 시간



Q3. 보안 데이터 활용

보안 데이터 사용 관련 위규 발생 방지



Q4. 데이터 전송 보장

(데이터 전송 관련 서비스)
시스템 장애로 인한 데이터 전송 실패



DP2. 설계 안 QA 측정

- 1 End-point 에서 데이터 직접 전송
- 2 API Service를 통한 데이터 전송 **[채택]**

Confidential



Performance	데이터 조회 응답성	데이터 조회를 빠르게 수행할 수 있어야 한다 [데이터 요청 후 제공까지 걸리는 시간 ≤ 평균 3 sec]	Q1
Reliability	데이터 전송 보장	데이터 전송 중 누락이 발생하지 않아야 한다 [(누락 데이터/ 전체 데이터) x 100] < 0.01%	Q4
Maintainability	서비스 배포 용이성	기능 추가 및 수정을 위한 유지보수가 수월 해야 한다 [기능 추가 및 수정의 적용을 위한 재배포 필요 서비스 개수 1개 이하]	Q6


Q1. 데이터 조회 응답성

실험 이력 데이터 조회에 걸리는 시간
(이력 페이지 로딩 시간 평균 1.6sec 제외)

★★★ ② Web browser 에서 실험 이력
데이터 조회에 걸리는 Network
시간 측정. 평균 397msec

① 동일

0.7 sec
(50%)



1.4 sec

☆☆☆

Q4. 데이터 전송 보장

(데이터 전송 관련 서비스)
시스템 장애로 인한 데이터 전송 실패

★★★ ① End-point 에서 DB로 직접
데이터 전송 (SPOF 없음)

데이터 전송 누락 확률
없음 (SPOF 없음)

② 서비스 이중화 보완 설계

서비스 장애 복구 설계로
데이터 누락 보완

데이터 전송 누락 확률
최소화 방안 유/무

☆☆☆

Q6. 서비스 배포 용이성

기능 유지보수를 위한 재배포가 필요
한 서비스 단위 개수

★★★ ② - 1개, 서비스 업데이트
(Logger Service)
- Client 재배포 불필요

Client 재배포 여부

☆☆☆ ① - Client 재배포 필요
- GPU Resource 관련
방화벽 설정 관리

1개 이하

☆☆☆

DP3. 설계 안 QA 측정

- 1 On demand Pull 방식
- 2 scheduled push 방식 **[채택]**


Confidential



Performance	데이터 조회 응답성	데이터 조회를 빠르게 수행할 수 있어야 한다 [데이터 요청 후 제공까지 걸리는 시간 ≤ 평균 3 sec]	Q1
Reliability	데이터 전송 보장	데이터 전송 중 누락이 발생하지 않아야 한다 [(누락 데이터/ 전체 데이터) x 100] < 0.01%	Q4

Q1. 데이터 조회 응답성

슈퍼컴 리소스 데이터 조회에 걸리는 시간
(페이지 로딩 시간 평균 0.7sec 제외)




Q4. 데이터 전송 보장

(데이터 전송 관련 서비스)
시스템 장애로 인한 데이터 전송 실패



Tips

■ 일정 관리



- 시간은 **생각보다 빠르게** 흘러간다 (팀 과제 끝나면 곧 면접 심사)
- 리뷰를 많이 받아라 → **첫 리뷰를 빨리** 시작해라
- 업무 중 자료로 사용할 수 있는 **Back Data**를 모아두자
- **업무 조율, 인수인계** 사전 준비/협의

Tips

■ 멘토링

- 개인 멘토를 적극 활용하고, 수시로 리뷰하는 것을 추천
- 문제점과 구멍을 계속 찾아주는데 큰 도움
- 좌절 할 때마다 멘탈 관리

■ 팀 과제

- 팀원과 절대 대립하지 말 것
- 팀 과제 멘토에게 적극적으로 도움을 받는 것을 추천
- 팀 과제도 중요. But **개인 과제 알아서 잘 병행**할 것
- 팀 과제 종료 후 개인 과제 상호 리뷰

■ Review

- 리뷰 횟수에 대한 의견은 다양하지만, 중요하다는 점은 모두가 동의
- 분야 별 전문가에게 중점 리뷰 추천
 - 멘토 및 주변 Architect → DP/품질속성
 - 과제 PL/TL, 임원 → 과제 배경 및 발표 흐름
 - 과제를 잘 모르는 동료 → 용어, 이해도
- 많은 리뷰의 장점
 - 다양한 질문에 대한 답변을 준비할 수 있는 기회
 - 놓치고 있던 허점 발견

Tips

■ 배경의 중요성

- 배경에서 이해가 부족하면 뒤 내용에 대한 의구심이 계속 이어짐
- DP까지 가기도 전에 질문 세례에 지치고 당황하여, 발표 지장

■ QA의 중요성

- 설계에서 무엇을 어떠한 관점에서 고민 해야하는지에 대한 내용 (과제의 어려움을 대변)
- QA 가 잘 정의되어 있지 않으면, 설계 안 평가 채택 과정이 순탄치 못함

■ QA가 먼저? DP 부터 고민?

- DP를 먼저 고민하여 발굴 했으나, QA를 만족하지 못하는 경우가 발생
- 결국 QA를 재정비하고 새로운 DP를 고민

■ DP 후보

- "이렇게 설계 안 하면 무슨 문제가 있는데?" 라는 질문을 계속 던져볼 것
- QA를 억지로 끼워 넣을 경우 대답하지 못하는 경우가 발생
- 후보 구조는 반드시 둘 다 선택 가능한 구조일 것 (들러리 후보, 1안+2안=3안 지양)
- Trade-off 평가에 Non-ASR도 등장할 수 있으나, 채택 사유는 가급적 우선순위가 높은 ASR 위주로

Tips

■ (면접 발표) 발표 준비

- 첫 페이지 혹은 배경은 가급적 외워서 발표 하는 것 추천
- (질의 응답 없이) 50분 이내로 발표 준비
- 이렇게 준비하더라도 DP 3 이후 부터는 발표 시간 부족할 수 있음

■ (면접 발표) DP 1,2 에서 결판

- DP를 탄탄하게 만들려면 품질 속성이 잘 준비되어 있어야 함
- DP를 많이 만드는 것 보다, 알찬 DP를 만드는 것이 훨씬 중요
- 면접 시간의 대부분을 DP1에 (+ 2,3) 사용하게 되므로 여기에 집중

■ (면접 발표) 질의 응답

- 해당 도메인을 잘 아는 심사위원이 있다면, 맹점을 예리하게 짚어 냄. 답변을 철저하게 준비해 갈 것
- 본인이 생각하는 설계 단점을 굳이 자진해서 얘기 할 필요 없음. "사실은..."
- 유사한 질문이 반복된다면 질문의 의미를 다시 파악해 보자

■ (면접 발표) 대립 금지

- 정말 궁금한 질문 → 대부분 한 번의 대답으로 해결
- 의구심, 애매함 → 2~3번의 토론
- 명백한 문제점 → 대립하지 말 것

Tips

■ 멘탈 관리

- 이 SW의 설계에 대해 나보다 더 많이 알거나, 고민한 사람은 없음
- 좌절하거나 패닉 순간이 찾아옴, 그러나 포기하지만 않으면 어떻게든 끝나 있음
- 양성과정 입과 인원, 합격률 매년 높아지고 있음
- 기회는 준비된 사람의 것