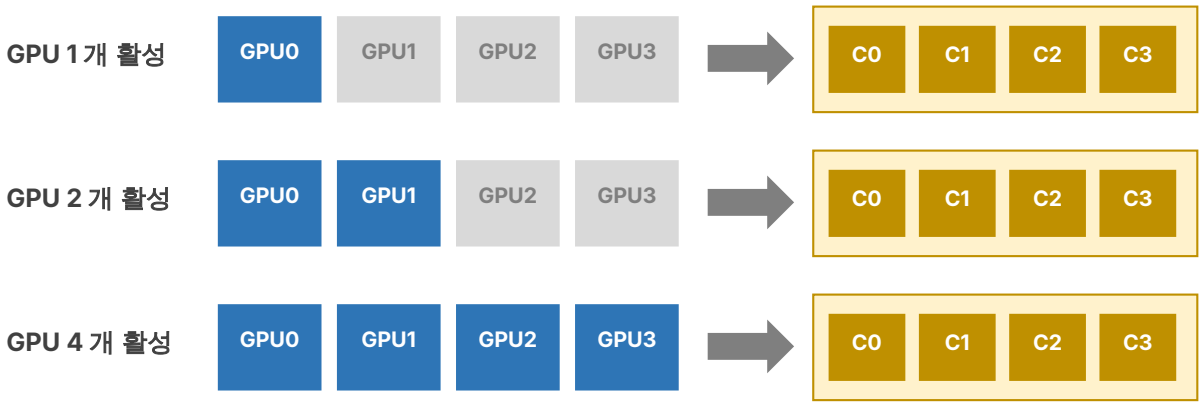
DP3. CXL 메모리 풀 - Q3 확장성 측정 방법

핵심 CXL 메모리 풀은 실구현이 없다. Target 1 노드의 CXL-PNM 4 카드를 '작은 풀'로 보고 GPU 를 1·2·4 개로 늘려 경합을 실측한 뒤, 그 적은 측정점으로 σ 를 구해 풀을 공유하는 GPU 가 늘어날 때의 SE 를 외삽한다 [C].

① 측정 : Target 1 노드 (GPU 4 + CXL-PNM 4 카드 공유)



GPU 수에 비례해 요청률을 올리고, CXL 카드 4 개와 KV 배치는 고정. 구성마다 5 회 반복해 Goodput(SLO 만족 처리량) 을 잰다.

활성 GPU N	Goodput	SE(N) = G(N) ÷ (N·G(1))
1	G(1)	기준 (100%)
2	G(2)	G(2) ÷ (2·G(1))
4	G(4)	G(4) ÷ (4·G(1))

② 피팅 : 측정한 SE 로 σ 를 구한다

- SE(N) = 1 / (1 + σ(N−1)) → σ = (1/SE − 1) / (N−1)
- N=2, N=4 두 점에서 각각 σ 를 구해 평균하고, 반복 측정으로 신뢰구간을 낸다
- σ = 풀 (CXL 카드) 을 여러 GPU 가 공유하며 생기는 직렬 경합 비중

③ 외삽 : 풀을 공유하는 GPU 수를 늘리면

피팅 σ (예시)	SE(4) 실측권	SE(16) 외삽	SE(64) 외삽
0.3%	99.1%	95.7%	84.1%
0.5%	98.5%	93.0%	76.0%
1.0%	97.1%	87.0%	61.3%

- 4 GPU 까지만 측정하고 16·64 GPU 는 σ 가 일정하다고 가정해 계산한다
- 별 판정은 σ 기준 : ★ ≤ 0.74%, ★★★ ≤ 0.35% (QA-03 과 동일, 제안)

한계

- 측정점이 3 개 (1·2·4 GPU) 뿐이고 외삽 폭이 4 배 ~16 배로 커서 불확실성이 큼 → 신뢰구간 병기
- 스위치·패브릭 지연, 풀 관리 SW 비용, 혼잡 급증 (κ) 은 반영 못 해 낙관적일 수 있음
- 풀 크기를 GPU 수에 비례해 늘린다고 가정

σ 예시값은 설명용 가정이며 실측값이 아니다. 노드 간 풀은 별도로 에뮬레이션 (원격 DRAM 의 지연·대역폭 제한) 이나 모델로 보완한다.