QA-01. Performance (Throughput) - 별 기준과 근거

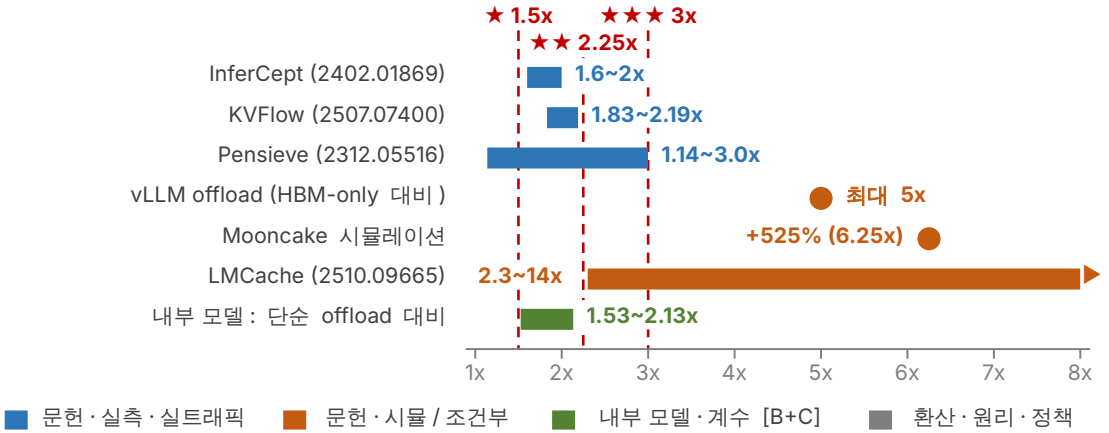
지표 설명 Max Goodput 배수 R = SLO(TTFT ≤ 2 s, TPOT ≤ 50 ms) 를 만족하는 최대 요청률 (req/s) 의 후보 ÷ Baseline. Baseline 은 HBM-only 가 아니라 HBM+DRAM 단순 offloading(LRU, 동기 로드) 이다 . 시나리오 × 시스템 쌍별 R 의 기하평균 . 단위 x(배), 높을수록 좋음 (↑).

별	조건 (R = 후보 ÷ Baseline)	근거
★★★	R ≥ 3.0x	상한 . 서버 67% 절감 환산 . Pensieve 3.0x (실 GPU 다중 턴 서빙 보고 상한)
★★½	R ≥ 2.625x	★★(2.25x) 과 ★★★ (3x) 의 중점 . 서버 62% 절감
★★	R ≥ 2.25x	★(1.5x) 과 ★★★ (3x) 의 중점 . 서버 56% 절감 . KVFlow 최대 2.19x 에 대응
★½	R ≥ 1.875x	★(1.5x) 과 ★★ (2.25x) 의 중점 . 서버 47% 절감 . InferCept 상단 2x 에 대응
★	R ≥ 1.5x	Stakeholder 요구사항 : SLO 만족 최대 처리량 ≥ Baseline 대비 1.5x. 서버 33% 절감 환산 [C]
☆ 미충족	R < 1.5x	Stakeholder 요구사항 미달 . 같은 수요에 서버를 2/3 로 줄이지 못함

품질 시나리오 측정 시나리오 (6 element)

자극원 (Source)	다수의 agent 세션 (동시 요청 클라이언트)
자극 (Stimulus)	multi-turn 요청 동시 도착 : 활성 세션 수백 ~1,200 개 , Poisson 도착 , 부하 sweep
대상 (Artifact)	KV cache 서빙 경로 (HBM·DRAM· 확장 메모리의 배치 · 이동 · 재사용 계층), 후보 vs Baseline
환경 (Environment)	정상 운영 , working set > HBM+DRAM 용량 . 8×H100 급 노드 , 70B 급 모델 , 컨텍스트 16K~32K
응답 (Response)	KV 재사용 hit 는 재계산 없이 로드 , SLO 안에서 더 많은 요청을 처리
응답 측정 (Measure)	SLO 만족 Max Goodput ÷ Baseline ≥ 1.5x (★, Stakeholder 요구사항), ≥ 3x (★★★)

Goodput· 처리량 개선 배수 R (Baseline 대비)



구분	문헌 · 출처	지표 · 조건	값	별 반영
문헌	InferCept arXiv 2402.01869	tool 호출 (augmented LLM) 서빙 , 최신 서빙 시스템 대비 처리량	1.6~2x	★ 하한 / ★½ 상단
문헌	KVFlow arXiv 2507.07400	멀티에이전트 prefix cache, SGLang(HiCache) 대비 최대	1.83x / 2.19x	★½~★★
문헌	Pensieve arXiv 2312.05516	다중 턴 stateful 서빙 , vLLM·TensorRT-LLM 대비	1.14~3.0x	★★★ 상한
조건부	vLLM blog 2026-01, Mooncake 시뮬 , LMCache	HBM-only 대비 CPU offload 최대 5x, 시뮬 +525%, LMCache 최대 14x (특정 조건)	5~14x	상한 제외
내부 [C]	qa_evidence_models.py (5 seeds, 유효 2/12)	단순 offload(HBM 400 GB+DRAM 1.5 TB) 대비 4-tier(+CXL, SSD)+prefetch 겹침 70%	1.53x / 2.13x	★~★½

출처 : arXiv 2402.01869, 2507.07400, 2312.05516, 2510.09665(LMCache, 검색 요약 · 원문 미확인), vLLM blog 2026-01-08(검색 요약), Mooncake arXiv 2407.00079. 내부 모델은 12 개 시나리오 중 비교유효 2 건 (포화 3, Baseline 붕괴 2(R 9~16x 는 상한 제외), Baseline infeasible 5) 이며 실측이 아닌 [C]. 유효 판정 (Baseline ≥ 1 req/s, R > 1.10) 은 1 차 결과를 본 뒤 fit-label 정의로 적용 . 문헌은 baseline·workload 가 달라 직접 비교 불가 .

QA-02. Performance (Tail Latency) - 별 기준과 근거

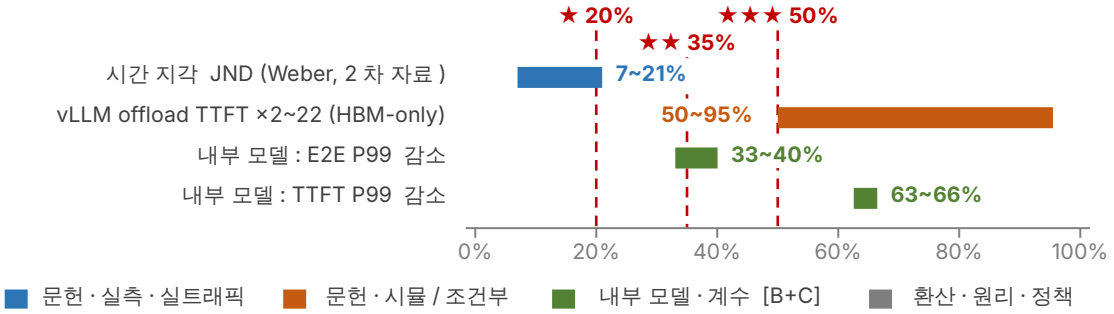
지표 설명 P99 지연 감소율 r = 1 − P99(후보) ÷ P99(Baseline). Elapsed Time = 요청 도착 ~ 마지막 토큰(큐 대기 + KV 로드/재계산 + decode). 고부하 = 서버 이용률 ρ 70%(근거 : 다음 장), SLO 만족 조건. Baseline 은 QA-01 과 같음. 단위 %, 높을수록 좋음 (↑). r 은 속도 1/(1−r) 배와 같다 (20% → 1.25x, 50% → 2x).

별	조건 (r = P99 감소율)	근거
★★★	r ≥ 50%	상한 [정책]. 지연이 절반 (2x faster). vLLM offload 의 TTFT ×2 하한과 일치
★★½	r ≥ 42.5%	★★(35%) 과 ★★★ (50%) 의 중점. 속도 1.74x
★★	r ≥ 35%	★(20%) 과 ★★★ (50%) 의 중점. 속도 1.54x
★½	r ≥ 27.5%	★(20%) 과 ★★ (35%) 의 중점. 속도 1.38x
★	r ≥ 20%	사용자 체감 성능 개선 기준 (요구사항). JND 상단 (≈21%) 에 해당하는 체감 가능 하한 [문헌 2 차]. 속도 1.25x
☆ 미충족	r < 20%	사용자 체감 성능 개선 기준 미달. 시간 지각 JND(≈7~21%) 이내라 개선을 확신하기 어려움

품질 시나리오 측정 시나리오 (6 element)

자극원 (Source)	다수의 agent 세션, 사용자 (응답을 기다리는 클라이언트)
자극 (Stimulus)	고부하 요청 폭주 : 서버 이용률 ρ 70%(Baseline 기준), working set > HBM+DRAM
대상 (Artifact)	KV cache 서빙 경로 (요청 큐 → KV 로드/재계산 → prefill → decode)
환경 (Environment)	정상 운영 · 고부하, SLO(TTFT ≤ 2 s, TPOT ≤ 50 ms) 충족 조건, 70B 급 모델, 컨텍스트 16K~64K
응답 (Response)	KV tier 이동 ·prefetch 로 miss 재계산과 큐 대기를 줄여 최악 지연을 단축
응답 측정 (Measure)	Elapsed Time P99 감소율 ≥ 20% vs Baseline (★, 사용자 체감 성능 개선 기준), ≥ 50% (★★★), SLO 만족 시

Elapsed Time(P99) 감소율 r (Baseline 대비, %)



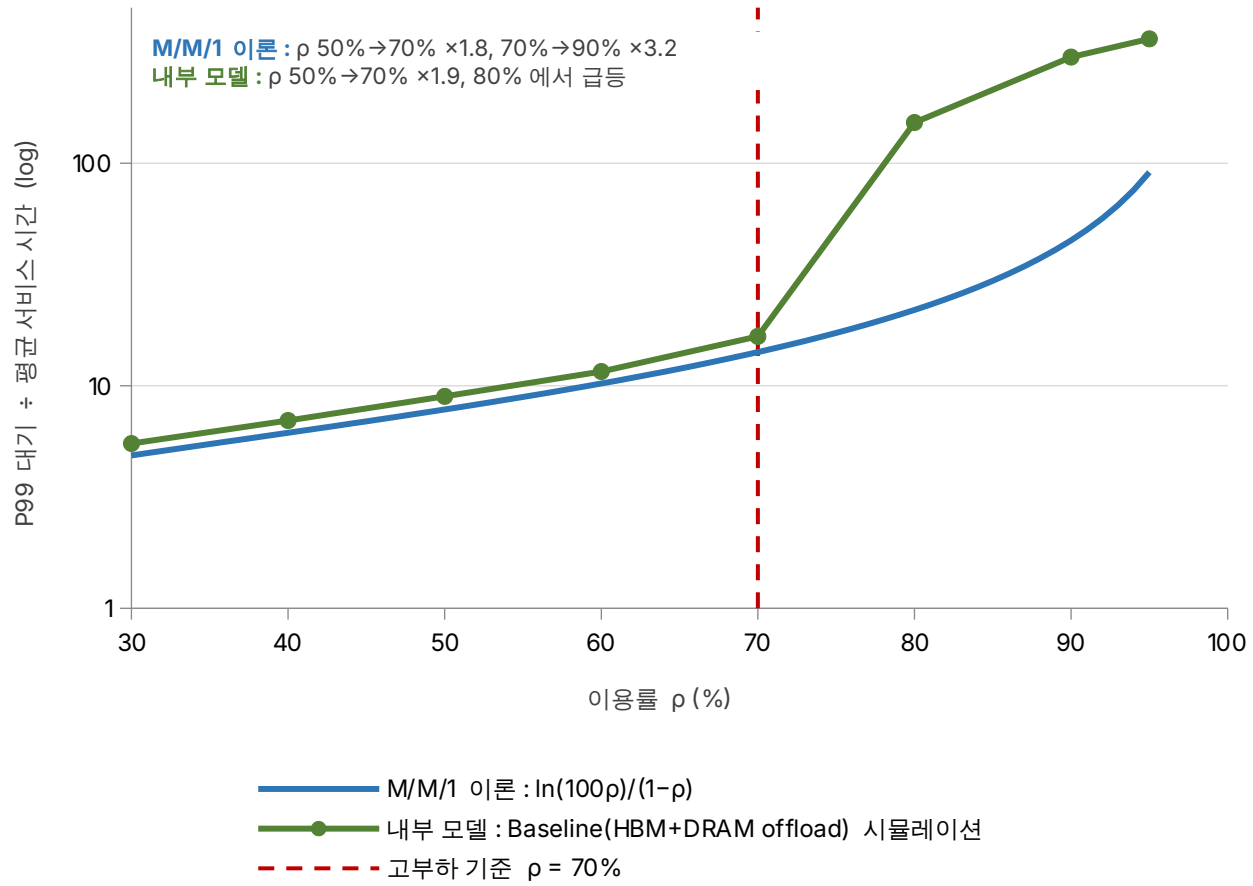
구분	문헌 · 출처	지표 · 조건	값	별 반영
문헌	Calibre 'perceived performance' 등 (2 차)	시간 지각 Weber 분수 : 1 s 규모 JND ≈ 0.17~0.21, 일부 자료는 7~18%	7~21%	★ 근거
문헌	web.dev 'Milliseconds make millions' (Deloitte×Google 2020)	모바일 0.1 s 속도 개선 → 리테일 전환율 +8.4% (37 개 브랜드)	+8.4% / 0.1 s	지연 민감도 참고
조건부	vLLM blog 2026-01 (KV offloading connector)	CPU offload 로 TTFT ×2~×22↓ (HBM-only 대비, 프롬프트 길이 의존)	50~95%	★★★ 하한 참고
내부 [C]	qa2_load_rho.py (유효 2/12)	ρ 70%, 5 seeds. 후보 P99 TTFT 1.3~1.5 s 로 SLO 2 s 충족	E2E 33~40% TTFT 63~66%	E2E ★½~★★ TTFT ★★★

출처 : calibreapp.com/blog/perceived-performance(2 차), web.dev/case-studies/milliseconds-make-millions, vLLM blog 2026-01-08(검색 요약). 내부 : doc-mk/QA-criteria-v5/qa2_load_rho.py. JND 는 1 차 심리물리 논문 미확인이며 LLM 스트리밍 응답에 그대로 적용되는지 검증되지 않았다. 체감은 과업 의존 (arXiv 2604.06183, 2608.24189: 검색 요약). 이전 정의 (Baseline SLO 한계 처리량의 70%) 는 이 모델에서 ρ≈0.34 라 폐기했고 그 값은 qa_evidence_out.json 에 보존.

QA-02 보충 . 고부하 (High Load) - 조건 · 의미 · 빈도

핵심 고부하 = 서버 이용률 ρ(요청률 ÷ 포화 처리율) 70% 이상 . 큐 대기가 ρ=70% 부근부터 급증해 P99 가 커지고 (이론 · 시뮬레이션), 실트래픽에서는 시간으로는 드물어도 요청의 약 1~11% 가 이 구간에서 처리되어 P99 를 결정한다 (BurstGPT 계산 [C]).

이용률 ρ 별 P99 큐 대기시간 (평균 서비스 시간 대비 배수 , 로그 축)



내부 모델 ρ≥80% 구간은 6,000 요청 시뮬레이션 길이 때문에 정상상태가 아니라 큐가 누적되는 값이다 .

조건 : 어떤 상태를 고부하라 하는가

ρ = 요청률 λ ÷ 포화 처리율 (=1/ 평균 서비스시간) ≥ 70%. SLO 와 무관한 서버 이용률이다 .
예 : 평균 서비스 0.25 s → 포화 4 req/s → 고부하 시험 요청률 2.8 req/s.
Baseline· 후보를 같은 절대 요청률로 비교 , working set > HBM+DRAM(KV miss 발생). 70% 는 [정책] 이며 50/70/90% sweep 병기 .

의미 : 왜 70% 인가 (꼬리가 급증하는 지점)

큐 대기는 1/(1−ρ) 에 비례해 늘어난다 . 이론 (M/M/1) 에서 ρ 50%→70% 는 P99 대기 ×1.8, 70%→90% 는 ×3.2.
내부 모델도 같은 형태 : ρ 50%→70% ×1.9 후 80% 에서 급등 (서비스 시간 편차가 커 knee 가 일찍 옴).
문헌 (2 차): 60~70% 를 운영 상한으로 권고 (arXiv 2608.14967), 70% 부근에서 꼬리가 커지기 시작 .
서비스 편차가 크면 더 일찍 꺾임 .

빈도 : 실트래픽에서 얼마나 자주 ρ ≥ 70% 인가 (BurstGPT)

용량 가정 (1 분 요청률)	시간 기준 ρ ≥ 70%	요청 기준 ρ ≥ 70%
관측 최대치에 맞춤	0.02%	1.2%
99.9 분위에 맞춤	0.3%	10.8%
99 분위에 맞춤	1.9%	31.1%

트레이스 : Azure OpenAI 실서비스 1,429,737 요청 , 61 일 . 1 분 요청률 최대 / 평균 77 배 , 중앙값은 평균의 12%.
P99 는 ' 상위 1% 요청 ' 이 결정하므로 요청 기준 비율이 1% 이상이면 P99 는 고부하 상태가 정한다 . 용량을 최대치에 맞추면 요청의 1.2%(10 초 창 0.13%) 로 경계적이다 .
한계 : 챗 /API 트래픽 (agent 세션 아님), 요청 수만 반영 (토큰 작업량 제외), 용량은 가정 , 오토스케일링 효과 없음 [C].

출처 : arXiv 2401.17644(BurstGPT, GitHub HPMLL/BurstGPT BurstGPT_1.csv), arXiv 2608.14967(검색 요약 기준 , 2 차), M/M/1 대기 분포 P(Wq>t)=ρe^{-μ(1-ρ)t}. 내부 : doc-mk/QA-criteria-v5/qa2_load_rho.py, burstgpt_load_stats.py

QA-03. Scalability - 별 기준과 근거

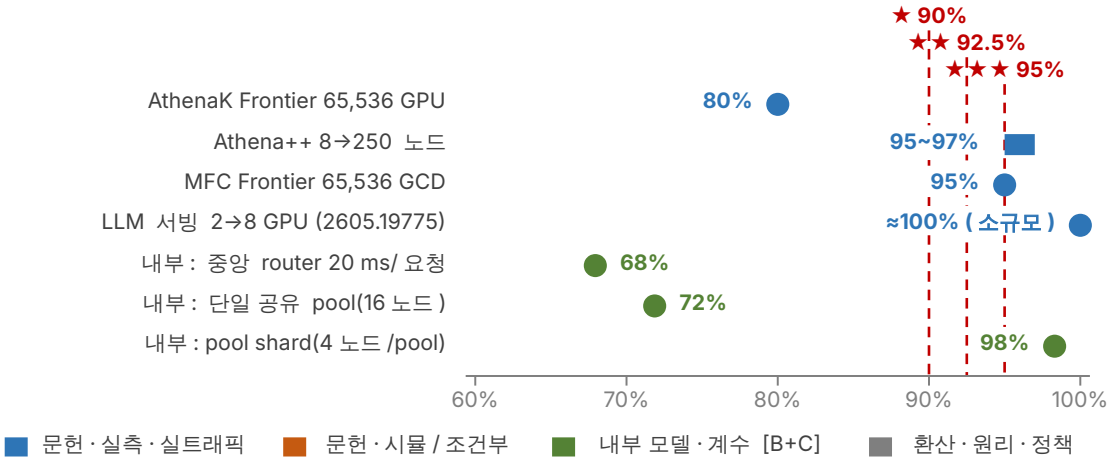
지표 설명 σ = 조율 계층 (router·metadata· 공유 tier) 이 요청 처리 시간 중 직렬로 차지하는 비중 (USL, 노드 간 경합 κ≈0 가정). SE(N) = Goodput(N) ÷ ((N/2) × Goodput(2)). 비 -target GPU 4 노드에서 SE(2~4) 를 실측해 σ 를 피팅하고 target 16 노드 SE 는 외삽 [C]. 별은 σ(노드 수 무관) 로 판정하고 SE(16) 은 환산값이다 . SE 는 높을수록 좋음 (↑).

별	조건 (SE(N=16) ↔ σ 상한)	근거
★★★	**SE > 95% (σ ≤ 0.38%)**	상한 . 조율 계층이 요청 처리의 0.38% 이하 . MFC 95%(65,536 GCD), Athena++ 95~97% 와 동급
★★½	**SE > 93.75% (σ ≤ 0.48%)**	★★(92.5%) 과 ★★★ (95%) 의 중점 . 유효 15.0 노드분
★★	**SE > 92.5% (σ ≤ 0.58%)**	★(90%) 과 ★★★ (95%) 의 중점 . 유효 14.8 노드분
★½	**SE > 91.25% (σ ≤ 0.69%)**	★(90%) 과 ★★ (92.5%) 의 중점 . 유효 14.6 노드분 . QA-01 순이득 1.37x
★	**SE > 90% (σ ≤ 0.80%)**	문헌 보고 값 (대규모 4k~65k GPU 에서도 80~97%) 을 16 노드 규모로 보정 . QA-01 ★ 이득 1.5x 가 확장 후 1.35x 이상 유지
☆ 미충족	**SE ≤ 90% (σ > 0.80%)**	조율 계층 손실이 10% 초과 . 중앙 router· 단일 공유 pool 구성은 이 구간 (내부 모델 68~72%)

품질 시나리오 측정 시나리오 (6 element)

자극원 (Source)	운영자 (자원 증설) / 서비스 사용자 (부하 증가)
자극 (Stimulus)	노드 수를 2 → 3 → 4 로 증설 (요청 도착률도 노드 수에 비례) 후 16 노드로 외삽
대상 (Artifact)	분산 KV 조율 계층 (전역 router·metadata· 공유 tier) 과 노드별 서빙 경로
환경 (Environment)	정상 운영 , N0 = 2 기준 , target 과 다른 사양의 GPU 4 노드에서 측정 , 공유 tier 경합 미반영
응답 (Response)	증설한 노드 수만큼 SLO 만족 처리량이 선형에 가깝게 증가
응답 측정 (Measure)	피팅 σ ≤ 0.80% (★) ↔ SE(16) > 90%, σ ≤ 0.38% (★★★) ↔ SE(16) > 95%

Scaling Efficiency SE(N=16) (%) — 문헌은 대규모 weak scaling



구분	문헌 · 출처	지표 · 조건	값	별 반영
문헌	AthenaK arXiv 2409.16053	Frontier 65,536 GPU weak scaling 80% (MHD 시뮬레이션 코드)	80%	대규모 하한
문헌	MFC 2509.13575 Athena++ 2005.06651	MFC Frontier 65,536 GCD weak 95%, Athena++ 8→250 노드 95~97%	95~97%	★★★ 근거
문헌	arXiv 2605.19775 LLM-Pilot 2410.02425	LLM 서빙 8B 2→8 GPU ≈4x, 13B ≤8 pod 근사 선형	≈100%	소규모 , 외삽 불가
원리	Amdahl 1967, Gunther USL 2008	SE = (1+σ)/(1+(N−1)σ). 90% → σ 0.80%, 95% → σ 0.38%. 4 노드 SE 는 98.4~99.3%	σ 환산	별 경계 환산
내부 [C]	공유 tier 구성 sweep	16 노드 , 로컬 처리 0.2 s, remote hit 30%, KV 10.7 GB, pool 200 GB/s	68~100%	☆~★★★ 구성 의존

출처 : arXiv 2409.16053(AthenaK), 2509.13575(MFC), 2005.06651(Athena++), 2605.19775, 2410.02425(LLM-Pilot)(모두 검색 요약 기준 , 원문 미확인), Amdahl 1967, Gunther 2008. 문헌은 weak scaling 병렬 효율이라 서빙 SE 와 정의가 다르다 [유추]. 4 노드 SE 오차는 외삽 시 크게 증폭되므로 (SE(4) ±1 point → SE(16) 약 80~90%) 별 판정은 σ 의 신뢰구간으로 하고 경계 걸침을 표기한다 . 내부 : doc-mk/QA-criteria-v5/qa_evidence_models.py.

QA-04. Modifiability - 별 기준과 근거

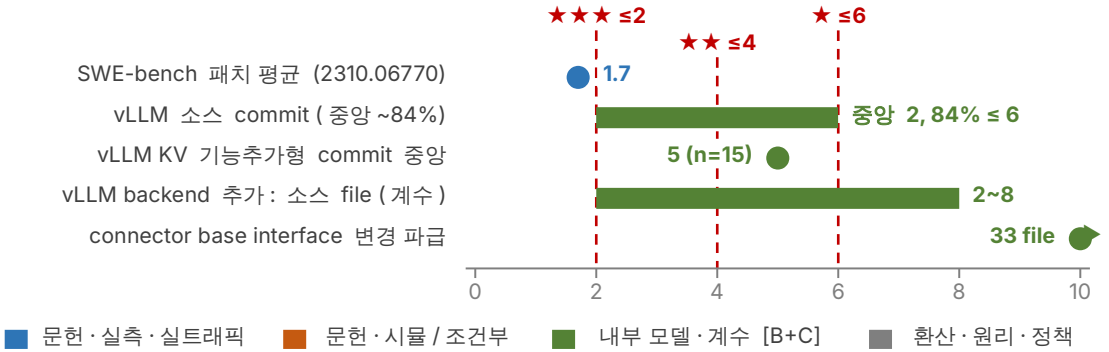
지표 설명 변경 module 수 = 변경 시나리오 (S1~S5) 1 건을 구현했을 때 수정 · 추가 · 삭제되는 소스 파일 수 (테스트 · 문서 제외), 시나리오 평균 . 기준은 vLLM commit 의 변경 파일 수 분포 (vllm-project/vllm main 최근 1,498 commit, 2026-10-13~2026-11-04) 에 맞췄다 . 단위 개 , 낮을수록 좋음 (↓).

별	조건 (변경 module 수)	근거
★★★	≤ 2 개	상한 . vLLM 소스 commit 의 62% 가 해당 (중앙값 2). SWE-bench 해결 패치 평균 1.7 file
★★½	≤ 3 개	★★(4) 과 ★★★ (2) 의 중점 . vLLM 소스 commit 의 71%
★★	≤ 4 개	★(6) 과 ★★★ (2) 의 중점 . vLLM 소스 commit 의 77%
★½	≤ 5 개	★(6) 과 ★★ (4) 의 중점 . vLLM 소스 commit 의 81% (p80 = 5)
★	≤ 6 개	요구사항 : vLLM commit 의 80% 가 6 file 이하 . 계수 : 소스 commit 의 84%
☆ 미충족	≥ 7 개	vLLM 소스 commit 의 약 16% 만 해당하는 큰 변경 (요구사항 기준 초과)

품질 시나리오 측정 시나리오 (6 element)

자극원 (Source)	제품 로드맵 · 운영 요구 → 개발자 (또는 코드 에이전트)
자극 (Stimulus)	변경 S1 신규 메모리 tier(CXL → HBF/ScHBM) · S2 이동 · 배치 정책 교체 (LRU → hotness 예측) · S3 신규 data type(LoRA·MoE expert·RAG 캐시를 tier 관리 대상에 추가) · S4 신규 이벤트 (tool-call 종료 시 prefetch trigger) · S5 신규 KV 코덱 (압축 · 양자화)
대상 (Artifact)	서빙 경로의 메모리 계층 추상화 (connector·manager·scheduler·worker)
환경 (Environment)	개발 시점 . 현행 vLLM + 제안 구조에 구현 , 기존 unit test 통과 (회귀 없음)
응답 (Response)	변경이 새 module 추가와 등록 지점 안에 머물고 서빙 경로 핵심 코드는 수정하지 않음
응답 측정 (Measure)	변경 module 수 (소스 file) 시나리오 평균 ≤ 6 (★, vLLM commit 의 80% 가 6 file 이하), ≤ 2 (★★★)

변경 module 수 (소스 file, 낮을수록 좋음)



구분	문헌 · 출처	지표 · 조건	값	별 반영
내부 계수	vLLM 최근 commit, 소스 file	n=1,279 (테스트 · 문서 제외). 요구사항의 '80% 가 6 file 이하 ' 확인	중앙 2 ≤6: 84%	★ 근거
내부 계수	KV connector·offload commit, 소스	n=150, 같은 기간	중앙 2 ≤6: 85%	★ 근거 보강
내부 계수	KV 기능 추가형 commit	제목 키워드로 고른 15 건 (표본 작음). S1~S5 와 성격 유사	중앙 5 ≤6: 67%	★ 경계 , ★★★ 은 상위
문헌	SWE-bench arXiv 2310.06770	실제 GitHub issue 해결 패치 2,294 건 : 평균 수정 파일 1.7 개	1.7 file	★★★ (≤ 2)
내부 계수	이 저장소 grep	backend 추가에 닿는 소스 2~8 file, connector base interface 참조 33 file	4(중앙) / 33	As-Is ★~☆ / interface ☆

출처 : vllm-project/vllm main git log(squash merge 라 commit≈PR 로 가정 , 봇 ·revert 포함), arXiv 2310.06770(SWE-bench), 품질 요구사항 표 (QA-04). 한계 : 3 주 표본 , 기능 추가형 15 건은 제목 키워드 선별 , 시나리오별 실제 구현 · 측정은 아직 하지 않았다 . 내부 : doc-mk/QA-criteria-v5/vllm_commit_stats.py, qa_evidence_out.json(qa4).

QA-05. Functional Correctness - 별 기준과 근거

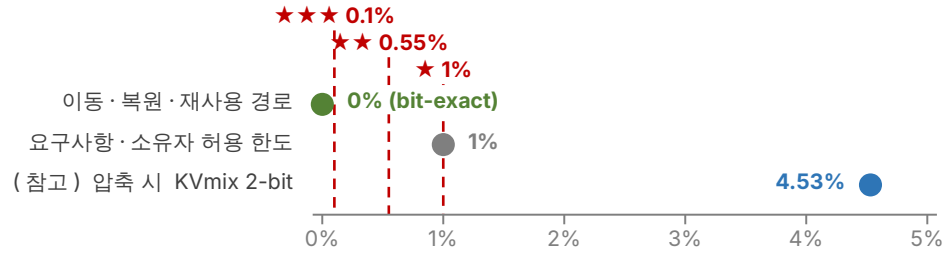
지표 설명 F1 상대 하락률 = (F1_baseline − F1_후보) ÷ F1_baseline, Baseline = 재사용 전 full recompute. 본 시스템은 압축을 쓰지 않으므로 이동 · 복원 · 재사용 경로가 대상이다 (무손실 경로는 bit-exact 확인). 판정은 문항별 paired bootstrap 으로 얻은 하락률 95% 신뢰구간의 상한이 기준 미만일 때 해당 별 . 단위 %(상대), 낮을수록 좋음 (↓).

별	조건 (하락률 95% CI 상한)	근거
★★★	상한 < 0.1%	상한 [정책]. 사실상 무손실 . 입증에는 평가 문항 수가 많이 필요 (CI 폭이 문항 수에 반비례)
★★½	상한 < 0.325%	★★(0.55%) 과 ★★★ (0.1%) 의 중점
★★	상한 < 0.55%	★(1%) 과 ★★★ (0.1%) 의 중점
★½	상한 < 0.775%	★(1%) 과 ★★ (0.55%) 의 중점
★	상한 < 1%	요구사항 (품질 요구사항 표): Baseline 대비 F1 감소율 1% 이하 . 소유자 허용 한도
☆ 미충족	상한 ≥ 1%	Stakeholder 요구사항 초과 : 1% 를 넘을 가능성을 배제하지 못함

품질 시나리오 측정 시나리오 (6 element)

자극원 (Source)	서빙 엔진 운영자 (KV 재사용 · 이동 경로 변경)
자극 (Stimulus)	KV cache 를 tier 간 이동 · 복원 · 재사용한 뒤 추론 요청 수행 (압축 미사용)
대상 (Artifact)	KV 이동 · 복원 · 재사용 경로 , 추론 결과 (task 별 F1)
환경 (Environment)	동일 task·dataset· 모델 ·precision, greedy decoding, 고정 seed, 정상 운영
응답 (Response)	재사용 경로를 거쳐도 추론 결과가 full recompute 와 동등
응답 측정 (Measure)	F1 하락률 95% CI 상한 < 1% (★, 요구사항), < 0.1% (★★★). 이동 · 복원은 bit-exact(0%)

F1 상대 하락률 (재사용 전 full recompute 대비 , %)



문헌 · 실측 · 실트래픽 문헌 · 시뮬 / 조건부 내부 모델 · 계수 [B+C] 환산 · 원리 · 정책

구분	문헌 · 출처	지표 · 조건	값	별 반영
요구사항	품질 요구사항 표 , 소유자 결정 (2026-10-09)	LLM 출력 정확도 (F1) Baseline 대비 감소율 1% 이하	1%	★ 근거
문헌	KVQuant 2401.18079, KVmix 2506.08018	(참고) 손실 압축 : 3-bit ppl 저하 < 0.1, 2-bit 급 LongBench 평균 상대 손실 4.53% (검색 요약)	ppl<0.1 / 4.53%	압축 미사용 : 참고
문헌	vLLM FP8 KV-cache blog (2026-04)	FP8 KV near-baseline, 장문 accumulation 오류 수정 후 BF16 수준 회복	정성	★ 가능성 (참고)
문헌	Thinking Machines Lab (2025-09)	batch-invariant 가 아닌 kernel 은 같은 입력에도 출력 변동 → 재사용 경로 비트 차이 가능	정성	★★★ 잡음 유의
내부 검증	qa_evidence_models.py	tier 왕복 복사 (직렬화→복원) 후 비트 비교 : fp16 KV block 10,000 개 (NaN·denormal 포함)	불일치 0	무손실 경로 0%

출처 : arXiv 2401.18079, 2506.08018(검색 요약 기준), vLLM blog 2026-04-22(검색 요약), Thinking Machines Lab 'Defeating Nondeterminism in LLM Inference'(2 차 요약), 품질 요구사항 표 (QA-05). 내부 검증은 복사 정확성 (메모리 왕복) 만 보이며 평가 데이터셋 F1 은 측정하지 않았다 . 0.1% 는 문항 수가 부족하면 CI 상한으로 입증하기 어렵다 .