# QA-01. Performance (Throughput) - 별 기준과 근거



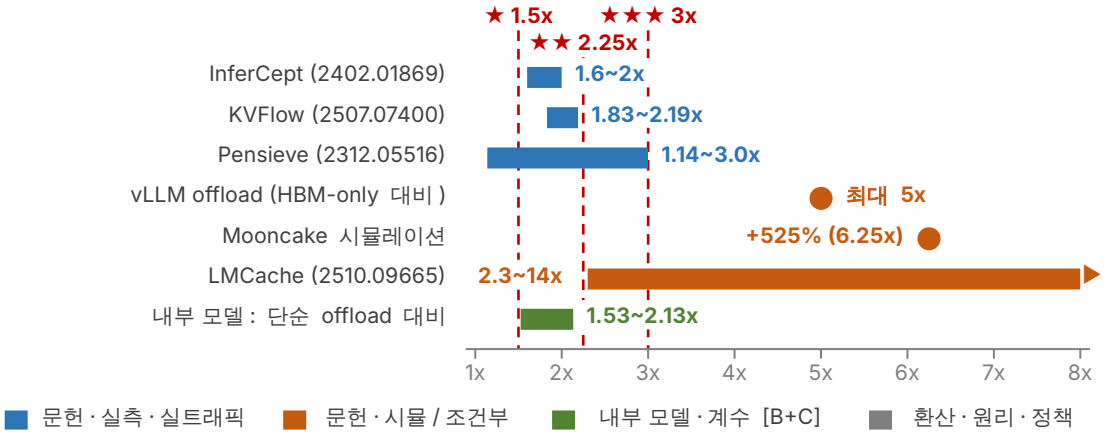
**지표 설명** Max Goodput 배수 R = SLO(TTFT ≤ 2 s, TPOT ≤ 50 ms) 를 만족하는 최대 요청률 (req/s) 의 후보 ÷ Baseline. Baseline 은 HBM-only 가 아니라 HBM+DRAM 단순 offloading(LRU, 동기 로드 ) 이다 . 시나리오 × 시스템 쌍별 R 의 기하평균 . 단위 x( 배 ), 높을수록 좋음 (↑).

| 별 | 조건 (R = 후보 ÷ Baseline) | 근거 |
|---|---|---|
| ★★★ | R ≥ 3.0x | 상한 . 서버 67% 절감 환산 . Pensieve 3.0x ( 실 GPU 다중 턴 서빙 보고 상한 ) |
| ★★½ | R ≥ 2.625x | ★★(2.25x) 과 ★★★ (3x) 의 중점 . 서버 62% 절감 |
| ★★ | R ≥ 2.25x | ★(1.5x) 과 ★★★ (3x) 의 중점 . 서버 56% 절감 . KVFlow 최대 2.19x 에 대응 |
| ★½ | R ≥ 1.875x | ★(1.5x) 과 ★★ (2.25x) 의 중점 . 서버 47% 절감 . InferCept 상단 2x 에 대응 |
| ★ | R ≥ 1.5x | Stakeholder 요구사항 : SLO 만족 최대 처리량 ≥ Baseline 대비 1.5x. 서버 33% 절감 환산 [C] |
| ☆ 미충족 | R < 1.5x | Stakeholder 요구사항 미달 . 같은 수요에 서버를 2/3 로 줄이지 못함 |

## 품질 시나리오 측정 시나리오 (6 element)

| | |
|---|---|
| **자극원 (Source)** | 다수의 agent 세션 ( 동시 요청 클라이언트 ) |
| **자극 (Stimulus)** | multi-turn 요청 동시 도착 : 활성 세션 수백 ~1,200 개 , Poisson 도착 , 부하 sweep |
| **대상 (Artifact)** | KV cache 서빙 경로 (HBM·DRAM· 확장 메모리의 배치 · 이동 · 재사용 계층 ), 후보 vs Baseline |
| **환경 (Environment)** | 정상 운영 , working set > HBM+DRAM 용량 . 8×H100 급 노드 , 70B 급 모델 , 컨텍스트 16K~32K |
| **응답 (Response)** | KV 재사용 hit 는 재계산 없이 로드 , SLO 안에서 더 많은 요청을 처리 |
| **응답 측정 (Measure)** | SLO 만족 Max Goodput ÷ Baseline ≥ 1.5x (★, Stakeholder 요구사항 ), ≥ 3x (★★★) |

## Goodput· 처리량 개선 배수 R (Baseline 대비 )




| 구분 | 문헌 · 출처 | 지표 · 조건 | 값 | 별 반영 |
|---|---|---|---|---|
| 문헌 | InferCept<br>arXiv 2402.01869 | tool 호출 (augmented LLM) 서빙 , 최신 서빙 시스템 대비 처리량 | 1.6~2x | ★ 하한 / ★½ 상단 |
| 문헌 | KVFlow<br>arXiv 2507.07400 | 멀티에이전트 prefix cache, SGLang(HiCache) 대비 최대 | 1.83x / 2.19x | ★½~★★ |
| 문헌 | Pensieve<br>arXiv 2312.05516 | 다중 턴 stateful 서빙 , vLLM·TensorRT-LLM 대비 | 1.14~3.0x | ★★★ 상한 |
| 조건부 | vLLM blog 2026-01,<br>Mooncake 시뮬 ,<br>LMCache | HBM-only 대비 CPU offload 최대 5x, 시뮬 +525%, LMCache 최대 14x ( 특정 조건 ) | 5~14x | 상한 제외 |
| 내부 [C] | qa_evidence_models.py<br>(5 seeds, 유효 2/12) | 단순 offload(HBM 400 GB+DRAM 1.5 TB) 대비 4-tier(+CXL, SSD)+prefetch 겹침 70% | 1.53x / 2.13x | ★~★½ |

출처 : arXiv 2402.01869, 2507.07400, 2312.05516, 2510.09665(LMCache, 검색 요약 · 원문 미확인 ), vLLM blog 2026-01-08( 검색 요약 ), Mooncake arXiv 2407.00079. 내부 모델은 12 개 시나리오 중 비교유효 2 건 ( 포화 3, Baseline 붕괴 2(R 9~16x 는 상한 제외 ), Baseline infeasible 5) 이며 실측이 아닌 [C]. 유효 판정 (Baseline ≥ 1 req/s, R > 1.10) 은 1 차 결과를 본 뒤 fit-label 정의로 적용 . 문헌은 baseline·workload 가 달라 직접 비교 불가 .

# QA-02. Performance (Tail Latency) - 별 기준과 근거



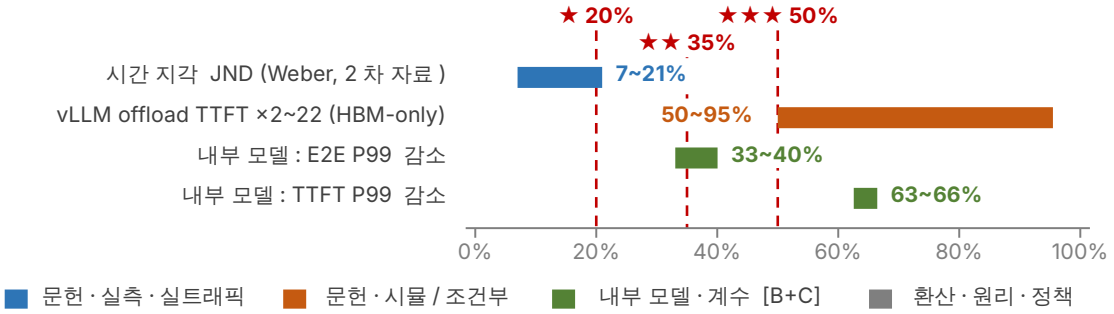
**지표 설명** P99 지연 감소율 r = 1 − P99(후보) ÷ P99(Baseline). Elapsed Time = 요청 도착 ~ 마지막 토큰(큐 대기 + KV 로드/재계산 + decode). 고부하 = 서버 이용률 ρ 70%(근거 : 다음 장), SLO 만족 조건. Baseline 은 QA-01 과 같음. 단위 %, 높을수록 좋음 (↑). r 은 속도 1/(1−r) 배와 같다 (20% → 1.25x, 50% → 2x).

| 별 | 조건 (r = P99 감소율) | 근거 |
|---|---|---|
| ★★★ | r ≥ 50% | 상한 [정책]. 지연이 절반 (2x faster). vLLM offload 의 TTFT ×2 하한과 일치 |
| ★★½ | r ≥ 42.5% | ★★(35%) 과 ★★★ (50%) 의 중점. 속도 1.74x |
| ★★ | r ≥ 35% | ★(20%) 과 ★★★ (50%) 의 중점. 속도 1.54x |
| ★½ | r ≥ 27.5% | ★(20%) 과 ★★ (35%) 의 중점. 속도 1.38x |
| ★ | r ≥ 20% | 사용자 체감 성능 개선 기준 (요구사항). JND 상단 (≈21%) 에 해당하는 체감 가능 하한 [문헌 2 차]. 속도 1.25x |
| ☆ 미충족 | r < 20% | 사용자 체감 성능 개선 기준 미달. 시간 지각 JND(≈7~21%) 이내라 개선을 확신하기 어려움 |

## 품질 시나리오 측정 시나리오 (6 element)

| | |
|---|---|
| **자극원 (Source)** | 다수의 agent 세션, 사용자 (응답을 기다리는 클라이언트) |
| **자극 (Stimulus)** | 고부하 요청 폭주 : 서버 이용률 ρ 70%(Baseline 기준), working set > HBM+DRAM |
| **대상 (Artifact)** | KV cache 서빙 경로 (요청 큐 → KV 로드/재계산 → prefill → decode) |
| **환경 (Environment)** | 정상 운영 · 고부하, SLO(TTFT ≤ 2 s, TPOT ≤ 50 ms) 충족 조건, 70B 급 모델, 컨텍스트 16K~64K |
| **응답 (Response)** | KV tier 이동 ·prefetch 로 miss 재계산과 큐 대기를 줄여 최악 지연을 단축 |
| **응답 측정 (Measure)** | Elapsed Time P99 감소율 ≥ 20% vs Baseline (★, 사용자 체감 성능 개선 기준), ≥ 50% (★★★), SLO 만족 시 |

## Elapsed Time(P99) 감소율 r (Baseline 대비, %)




| 구분 | 문헌 · 출처 | 지표 · 조건 | 값 | 별 반영 |
|---|---|---|---|---|
| 문헌 | Calibre 'perceived performance' 등 (2 차) | 시간 지각 Weber 분수 : 1 s 규모 JND ≈ 0.17~0.21, 일부 자료는 7~18% | 7~21% | ★ 근거 |
| 문헌 | web.dev 'Milliseconds make millions' (Deloitte×Google 2020) | 모바일 0.1 s 속도 개선 → 리테일 전환율 +8.4% (37 개 브랜드) | +8.4% / 0.1 s | 지연 민감도 참고 |
| 조건부 | vLLM blog 2026-01 (KV offloading connector) | CPU offload 로 TTFT ×2~×22↓ (HBM-only 대비, 프롬프트 길이 의존) | 50~95% | ★★★ 하한 참고 |
| 내부 [C] | qa2_load_rho.py (유효 2/12) | ρ 70%, 5 seeds. 후보 P99 TTFT 1.3~1.5 s 로 SLO 2 s 충족 | E2E 33~40% TTFT 63~66% | E2E ★½~★★ TTFT ★★★ |

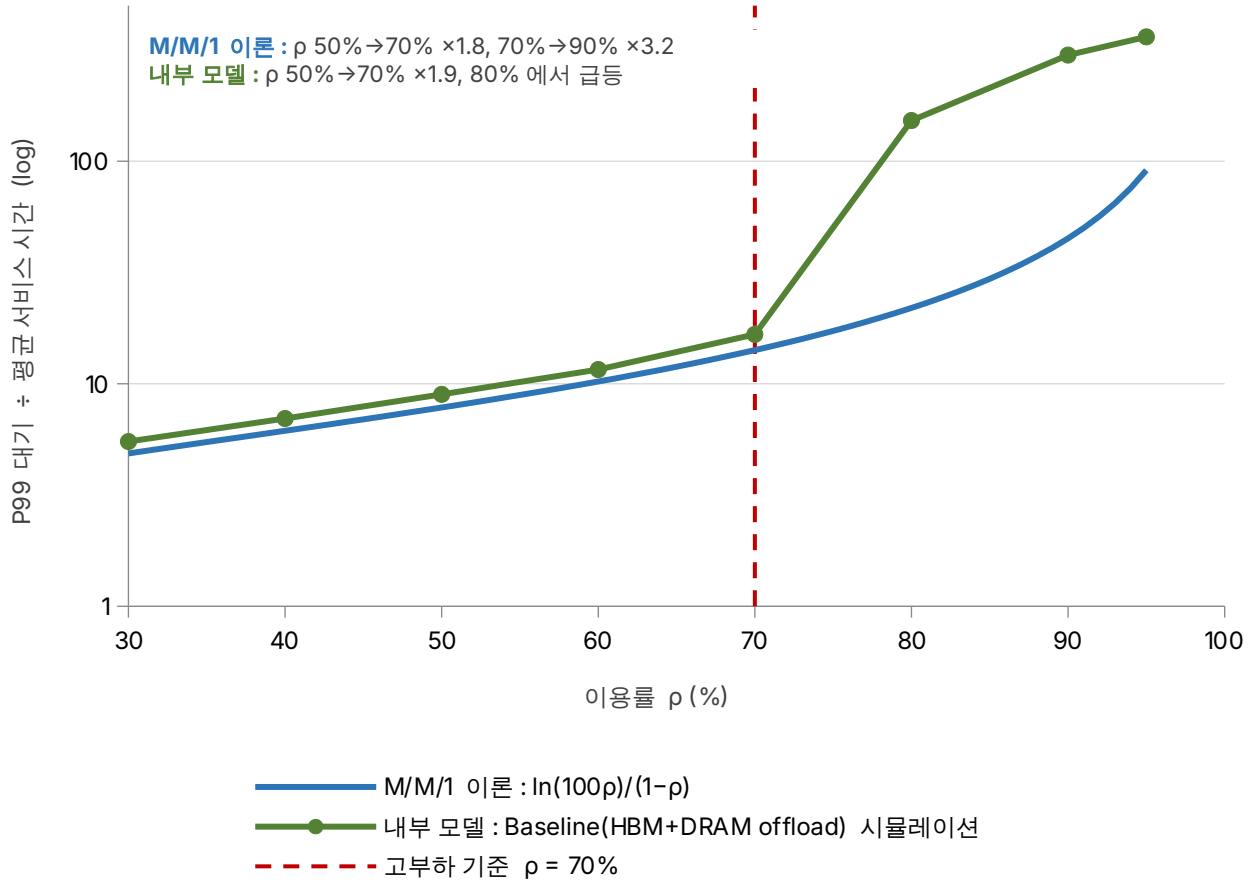
출처 : calibreapp.com/blog/perceived-performance(2 차), web.dev/case-studies/milliseconds-make-millions, vLLM blog 2026-01-08(검색 요약). 내부 : doc-mk/QA-criteria-v5/qa2_load_rho.py. JND 는 1 차 심리물리 논문 미확인이며 LLM 스트리밍 응답에 그대로 적용되는지 검증되지 않았다. 체감은 과업 의존 (arXiv 2604.06183, 2608.24189: 검색 요약). 이전 정의 (Baseline SLO 한계 처리량의 70%) 는 이 모델에서 ρ≈0.34 라 폐기했고 그 값은 qa_evidence_out.json 에 보존.

# QA-02 보충 . 고부하 (High Load) - 조건 · 의미 · 빈도



**핵심** 고부하 = 서버 이용률 ρ( 요청률 ÷ 포화 처리율 μ) 70% 이상 . 큐 대기가 ρ=70% 부근부터 급증해 P99 가 커진다 ( 이론 · 시뮬레이션 ). 실트래픽에서의 빈도는 μ 가 평균 요청률의 몇 배인지에 달려 있다 : 10 배 이하이면 시간의 3% 이상 , 요청의 42% 이상이 고부하에서 처리된다 (BurstGPT 계산 [C]).

### 이용률 ρ 별 P99 큐 대기시간 ( 평균 서비스 시간 대비 배수 , 로그 축 )




내부 모델 ρ≥80% 구간은 6,000 요청 시뮬레이션 길이 때문에 정상상태가 아니라 큐가 누적되는 값이다 .

### 조건 : 어떤 상태를 고부하라 하는가

ρ = 요청률 λ ÷ 포화 처리율 (=1/ 평균 서비스시간 ) ≥ 70%. SLO 와 무관한 서버 이용률이다 .
예 : 평균 서비스 0.25 s → 포화 4 req/s → 고부하 시험 요청률 2.8 req/s.
Baseline· 후보를 같은 절대 요청률로 비교 , working set > HBM+DRAM(KV miss 발생 ). 70% 는 [ 정책 ] 이며 50/70/90% sweep 병기 .

### 의미 : 왜 70% 인가 ( 꼬리가 급증하는 지점 )

큐 대기는 1/(1−ρ) 에 비례해 늘어난다 . 이론 (M/M/1) 에서 ρ 50%→70% 는 P99 대기 ×1.8, 70%→90% 는 ×3.2.
내부 모델도 같은 형태 : ρ 50%→70% ×1.9 후 80% 에서 급등 ( 서비스 시간 편차가 커 knee 가 일찍 옴 ).
문헌 (2 차 ): 60~70% 를 운영 상한으로 권고 (arXiv 2608.14967), 70% 부근에서 꼬리가 커지기 시작 .
서비스 편차가 크면 더 일찍 꺾임 .

### 빈도 : ρ ≥ 70%( 요청률 ≥ 0.7μ) 가 얼마나 자주인가 (BurstGPT)

| μ ( 평균 요청률 대비 ) | 0.7μ 이상인 시간 | 하루 중 | 그 구간 처리 요청 |
|---|---|---|---|
| 2 배 (0.54 req/s) | 16.4% | 3.9 시간 | 84.3% |
| 5 배 (1.36 req/s) | 8.2% | 2.0 시간 | 65.9% |
| 10 배 (2.71 req/s) | 3.3% | 48 분 | 42.3% |
| 20 배 (5.43 req/s) | 0.78% | 11 분 | 18.7% |
| 50 배 (13.57 req/s) | 0.15% | 2 분 | 6.0% |

트레이스 : Azure OpenAI 실서비스 1,429,737 요청 , 61 일 , 1 분 요청률 ( 평균 0.27 req/s, 최대 / 평균 77 배 ). P99 는 상위 1% 요청이 정하므로 그 구간 처리 요청이 1% 이상이면 고부하 상태가 P99 를 결정한다 .
한계 : 챗 /API 트래픽 (agent 세션 아님 ), 요청 수만 반영 ( 토큰 작업량 제외 ), 오토스케일링 없음 [C].

출처 : arXiv 2401.17644(BurstGPT, GitHub HPMLL/BurstGPT BurstGPT_1.csv), arXiv 2608.14967( 검색 요약 기준 , 2 차 ), M/M/1 대기 분포 $P(Wq>t)=\rho e^{-\mu(1-\rho)t}$. 내부 : doc-mk/QA-criteria-v5/qa2_load_rho.py, burstgpt_load_stats.py

# QA-03. Scalability - 별 기준과 근거



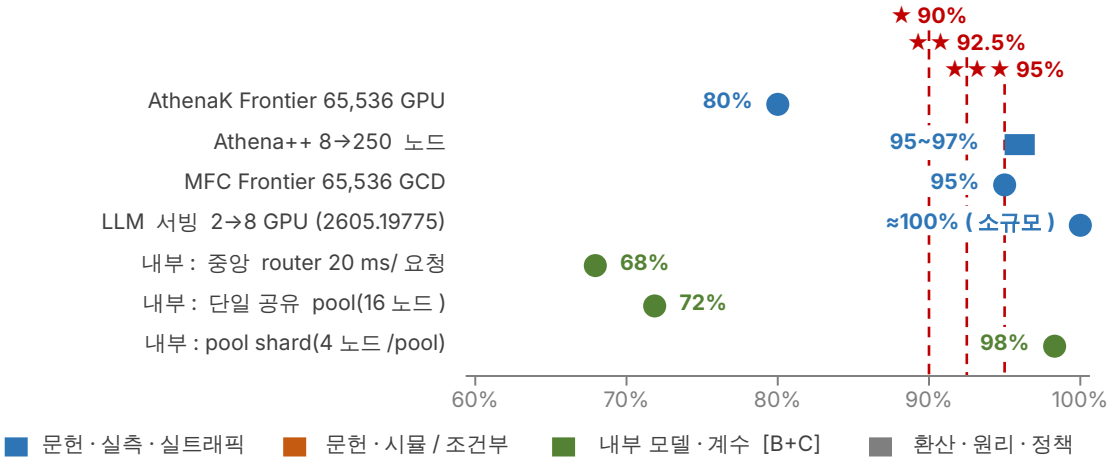
**지표 설명** σ = 조율 계층 (router·metadata· 공유 tier) 이 요청 처리 시간 중 직렬로 차지하는 비중 (USL, 노드 간 경합 κ≈0 가정 ). SE(N) = Goodput(N) ÷ ((N/2) × Goodput(2)). 비 -target GPU 4 노드에서 SE(2~4) 를 실측해 σ 를 피팅하고 target 16 노드 SE 는 외삽 [C]. 별은 σ( 노드 수 무관 ) 로 판정하고 SE(16) 은 환산값이다 . SE 는 높을수록 좋음 (↑).

| 별 | 조건 (SE(N=16) ↔ σ 상한 ) | 근거 |
|---|---|---|
| ★★★ | **SE > 95% (σ ≤ 0.38%)** | 상한 . 조율 계층이 요청 처리의 0.38% 이하 . MFC 95%(65,536 GCD), Athena++ 95~97% 와 동급 |
| ★★½ | **SE > 93.75% (σ ≤ 0.48%)** | ★★(92.5%) 과 ★★★ (95%) 의 중점 . 유효 15.0 노드분 |
| ★★ | **SE > 92.5% (σ ≤ 0.58%)** | ★(90%) 과 ★★★ (95%) 의 중점 . 유효 14.8 노드분 |
| ★½ | **SE > 91.25% (σ ≤ 0.69%)** | ★(90%) 과 ★★ (92.5%) 의 중점 . 유효 14.6 노드분 . QA-01 순이득 1.37x |
| ★ | **SE > 90% (σ ≤ 0.80%)** | 문헌 보고 값 ( 대규모 4k~65k GPU 에서도 80~97%) 을 16 노드 규모로 보정 . QA-01 ★ 이득 1.5x 가 확장 후 1.35x 이상 유지 |
| ☆ 미충족 | **SE ≤ 90% (σ > 0.80%)** | 조율 계층 손실이 10% 초과 . 중앙 router· 단일 공유 pool 구성은 이 구간 ( 내부 모델 68~72%) |

## 품질 시나리오 측정 시나리오 (6 element)

| | |
|---|---|
| **자극원 (Source)** | 운영자 ( 자원 증설 ) / 서비스 사용자 ( 부하 증가 ) |
| **자극 (Stimulus)** | 노드 수를 2 → 3 → 4 로 증설 ( 요청 도착률도 노드 수에 비례 ) 후 16 노드로 외삽 |
| **대상 (Artifact)** | 분산 KV 조율 계층 ( 전역 router·metadata· 공유 tier) 과 노드별 서빙 경로 |
| **환경 (Environment)** | 정상 운영 , N0 = 2 기준 , target 과 다른 사양의 GPU 4 노드에서 측정 , 공유 tier 경합 미반영 |
| **응답 (Response)** | 증설한 노드 수만큼 SLO 만족 처리량이 선형에 가깝게 증가 |
| **응답 측정 (Measure)** | 피팅 σ ≤ 0.80% (★) ↔ SE(16) > 90%, σ ≤ 0.38% (★★★) ↔ SE(16) > 95% |

## Scaling Efficiency SE(N=16) (%) — 문헌은 대규모 weak scaling




| 구분 | 문헌 · 출처 | 지표 · 조건 | 값 | 별 반영 |
|---|---|---|---|---|
| 문헌 | AthenaK arXiv 2409.16053 | Frontier 65,536 GPU weak scaling 80% (MHD 시뮬레이션 코드 ) | 80% | 대규모 하한 |
| 문헌 | MFC 2509.13575 Athena++ 2005.06651 | MFC Frontier 65,536 GCD weak 95%, Athena++ 8→250 노드 95~97% | 95~97% | ★★★ 근거 |
| 문헌 | arXiv 2605.19775 LLM-Pilot 2410.02425 | LLM 서빙 8B 2→8 GPU ≈4x, 13B ≤8 pod 근사 선형 | ≈100% | 소규모 , 외삽 불가 |
| 원리 | Amdahl 1967, Gunther USL 2008 | SE = (1+σ)/(1+(N−1)σ). 90% → σ 0.80%, 95% → σ 0.38%. 4 노드 SE 는 98.4~99.3% | σ 환산 | 별 경계 환산 |
| 내부 [C] | 공유 tier 구성 sweep | 16 노드 , 로컬 처리 0.2 s, remote hit 30%, KV 10.7 GB, pool 200 GB/s | 68~100% | ☆~★★★ 구성 의존 |

출처 : arXiv 2409.16053(AthenaK), 2509.13575(MFC), 2005.06651(Athena++), 2605.19775, 2410.02425(LLM-Pilot)( 모두 검색 요약 기준 , 원문 미확인 ), Amdahl 1967, Gunther 2008. 문헌은 weak scaling 병렬 효율이라 서빙 SE 와 정의가 다르다 [ 유추 ]. 4 노드 SE 오차는 외삽 시 크게 증폭되므로 (SE(4) ±1 point → SE(16) 약 80~90%) 별 판정은 σ 의 신뢰구간으로 하고 경계 걸침을 표기한다 . 내부 : doc-mk/QA-criteria-v5/qa_evidence_models.py.

# QA-04. Modifiability - 별 기준과 근거



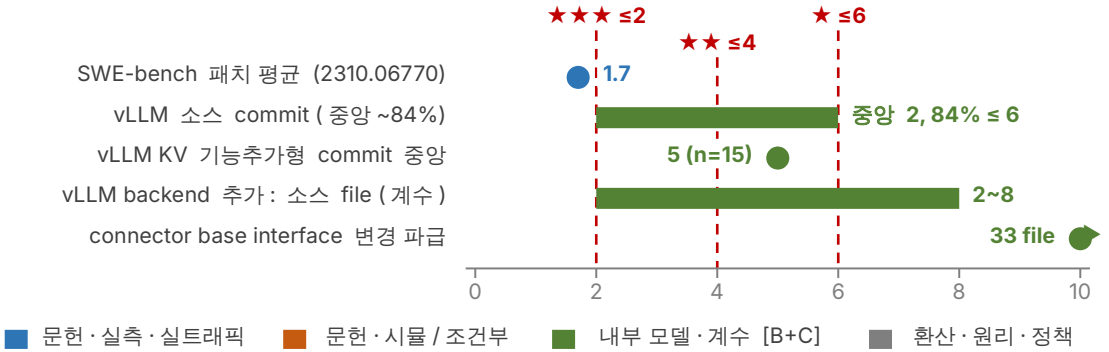
**지표 설명** 변경 module 수 = 변경 시나리오 (S1~S5) 1 건을 구현했을 때 수정 · 추가 · 삭제되는 소스 파일 수 ( 테스트 · 문서 제외 ), 시나리오 평균 . 기준은 vLLM commit 의 변경 파일 수 분포 (vllm-project/vllm main 최근 1,498 commit, 2026-10-13~2026-11-04) 에 맞췄다 . 단위 개 , 낮을수록 좋음 (↓).

| 별 | 조건 ( 변경 module 수 ) | 근거 |
|---|---|---|
| ★★★ | ≤ 2 개 | 상한 . vLLM 소스 commit 의 62% 가 해당 ( 중앙값 2). SWE-bench 해결 패치 평균 1.7 file |
| ★★½ | ≤ 3 개 | ★★(4) 과 ★★★ (2) 의 중점 . vLLM 소스 commit 의 71% |
| ★★ | ≤ 4 개 | ★(6) 과 ★★★ (2) 의 중점 . vLLM 소스 commit 의 77% |
| ★½ | ≤ 5 개 | ★(6) 과 ★★ (4) 의 중점 . vLLM 소스 commit 의 81% (p80 = 5) |
| ★ | ≤ 6 개 | 요구사항 : vLLM commit 의 80% 가 6 file 이하 . 계수 : 소스 commit 의 84% |
| ☆ 미충족 | ≥ 7 개 | vLLM 소스 commit 의 약 16% 만 해당하는 큰 변경 ( 요구사항 기준 초과 ) |

## 품질 시나리오 측정 시나리오 (6 element)

| | |
|---|---|
| **자극원 (Source)** | 제품 로드맵 · 운영 요구 → 개발자 ( 또는 코드 에이전트 ) |
| **자극 (Stimulus)** | 변경 S1 신규 메모리 tier(CXL → HBF/ScHBM) · S2 이동 · 배치 정책 교체 (LRU → hotness 예측 ) · S3 신규 data type(LoRA·MoE expert·RAG 캐시를 tier 관리 대상에 추가 ) · S4 신규 이벤트 (tool-call 종료 시 prefetch trigger) · S5 신규 KV 코덱 ( 압축 · 양자화 ) |
| **대상 (Artifact)** | 서빙 경로의 메모리 계층 추상화 (connector·manager·scheduler·worker) |
| **환경 (Environment)** | 개발 시점 . 현행 vLLM + 제안 구조에 구현 , 기존 unit test 통과 ( 회귀 없음 ) |
| **응답 (Response)** | 변경이 새 module 추가와 등록 지점 안에 머물고 서빙 경로 핵심 코드는 수정하지 않음 |
| **응답 측정 (Measure)** | 변경 module 수 ( 소스 file) 시나리오 평균 ≤ 6 (★, vLLM commit 의 80% 가 6 file 이하 ), ≤ 2 (★★★) |

### 변경 module 수 ( 소스 file, 낮을수록 좋음 )




| 구분 | 문헌 · 출처 | 지표 · 조건 | 값 | 별 반영 |
|---|---|---|---|---|
| 내부 계수 | vLLM 최근 commit, 소스 file | n=1,279 ( 테스트 · 문서 제외 ). 요구사항의 '80% 가 6 file 이하 ' 확인 | 중앙 2<br>≤6: 84% | ★ 근거 |
| 내부 계수 | KV connector·offload commit, 소스 | n=150, 같은 기간 | 중앙 2<br>≤6: 85% | ★ 근거 보강 |
| 내부 계수 | KV 기능 추가형 commit | 제목 키워드로 고른 15 건 ( 표본 작음 ). S1~S5 와 성격 유사 | 중앙 5<br>≤6: 67% | ★ 경계 ,<br>★★★ 은 상위 |
| 문헌 | SWE-bench arXiv 2310.06770 | 실제 GitHub issue 해결 패치 2,294 건 : 평균 수정 파일 1.7 개 | 1.7 file | ★★★ (≤ 2) |
| 내부 계수 | 이 저장소 grep | backend 추가에 닿는 소스 2~8 file, connector base interface 참조 33 file | 4( 중앙 ) / 33 | As-Is ★~☆ /<br>interface ☆ |

출처 : vllm-project/vllm main git log(squash merge 라 commit≈PR 로 가정 , 봇 ·revert 포함 ), arXiv 2310.06770(SWE-bench), 품질 요구사항 표 (QA-04). 한계 : 3 주 표본 , 기능 추가형 15 건은 제목 키워드 선별 , 시나리오별 실제 구현 · 측정은 아직 하지 않았다 . 내부 : doc-mk/QA-criteria-v5/vllm_commit_stats.py, qa_evidence_out.json(qa4).

# QA-05. Functional Correctness - 별 기준과 근거



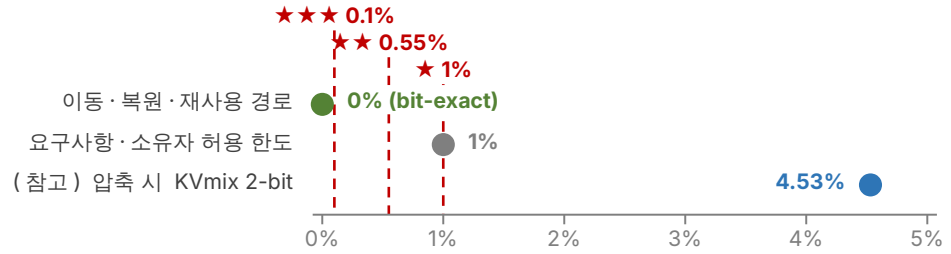
**지표 설명** F1 상대 하락률 = (F1_baseline − F1_후보) ÷ F1_baseline, Baseline = 재사용 전 full recompute. 본 시스템은 압축을 쓰지 않으므로 이동 · 복원 · 재사용 경로가 대상이다 ( 무손실 경로는 bit-exact 확인 ). 판정은 문항별 paired bootstrap 으로 얻은 하락률 95% 신뢰구간의 상한이 기준 미만일 때 해당 별 . 단위 %( 상대 ), 낮을수록 좋음 (↓).

| 별 | 조건 ( 하락률 95% CI 상한 ) | 근거 |
|---|---|---|
| ★★★ | 상한 < 0.1% | 상한 [ 정책 ]. 사실상 무손실 . 입증에는 평가 문항 수가 많이 필요 (CI 폭이 문항 수에 반비례 ) |
| ★★½ | 상한 < 0.325% | ★★(0.55%) 과 ★★★ (0.1%) 의 중점 |
| ★★ | 상한 < 0.55% | ★(1%) 과 ★★★ (0.1%) 의 중점 |
| ★½ | 상한 < 0.775% | ★(1%) 과 ★★ (0.55%) 의 중점 |
| ★ | 상한 < 1% | 요구사항 ( 품질 요구사항 표 ): Baseline 대비 F1 감소율 1% 이하 . 소유자 허용 한도 |
| ☆ 미충족 | 상한 ≥ 1% | Stakeholder 요구사항 초과 : 1% 를 넘을 가능성을 배제하지 못함 |

## 품질 시나리오 측정 시나리오 (6 element)

| | |
|---|---|
| **자극원 (Source)** | 서빙 엔진 운영자 (KV 재사용 · 이동 경로 변경 ) |
| **자극 (Stimulus)** | KV cache 를 tier 간 이동 · 복원 · 재사용한 뒤 추론 요청 수행 ( 압축 미사용 ) |
| **대상 (Artifact)** | KV 이동 · 복원 · 재사용 경로 , 추론 결과 (task 별 F1) |
| **환경 (Environment)** | 동일 task·dataset· 모델 ·precision, greedy decoding, 고정 seed, 정상 운영 |
| **응답 (Response)** | 재사용 경로를 거쳐도 추론 결과가 full recompute 와 동등 |
| **응답 측정 (Measure)** | F1 하락률 95% CI 상한 < 1% (★, 요구사항 ), < 0.1% (★★★). 이동 · 복원은 bit-exact(0%) |

## F1 상대 하락률 ( 재사용 전 full recompute 대비 , %)




문헌 · 실측 · 실트래픽 문헌 · 시뮬 / 조건부 내부 모델 · 계수 [B+C] 환산 · 원리 · 정책

| 구분 | 문헌 · 출처 | 지표 · 조건 | 값 | 별 반영 |
|---|---|---|---|---|
| 요구사항 | 품질 요구사항 표 , 소유자 결정 (2026-10-09) | LLM 출력 정확도 (F1) Baseline 대비 감소율 1% 이하 | 1% | ★ 근거 |
| 문헌 | KVQuant 2401.18079, KVmix 2506.08018 | ( 참고 ) 손실 압축 : 3-bit ppl 저하 < 0.1, 2-bit 급 LongBench 평균 상대 손실 4.53% ( 검색 요약 ) | ppl<0.1 / 4.53% | 압축 미사용 : 참고 |
| 문헌 | vLLM FP8 KV-cache blog (2026-04) | FP8 KV near-baseline, 장문 accumulation 오류 수정 후 BF16 수준 회복 | 정성 | ★ 가능성 ( 참고 ) |
| 문헌 | Thinking Machines Lab (2025-09) | batch-invariant 가 아닌 kernel 은 같은 입력에도 출력 변동 → 재사용 경로 비트 차이 가능 | 정성 | ★★★ 잡음 유의 |
| 내부 검증 | qa_evidence_models.py | tier 왕복 복사 ( 직렬화→복원 ) 후 비트 비교 : fp16 KV block 10,000 개 (NaN·denormal 포함 ) | 불일치 0 | 무손실 경로 0% |

출처 : arXiv 2401.18079, 2506.08018( 검색 요약 기준 ), vLLM blog 2026-04-22( 검색 요약 ), Thinking Machines Lab 'Defeating Nondeterminism in LLM Inference'(2 차 요약 ), 품질 요구사항 표 (QA-05). 내부 검증은 복사 정확성 ( 메모리 왕복 ) 만 보이며 평가 데이터셋 F1 은 측정하지 않았다 . 0.1% 는 문항 수가 부족하면 CI 상한으로 입증하기 어렵다 .