# QA-01. Performance (Throughput) - 별 기준과 근거



## SLO 를 만족하는 Max Goodput 이 Baseline(HBM+DRAM 단순 offloading) 의 몇 배일 때 ★ / ★★ / ★★★ 인가

QA-01

**지표 설명**

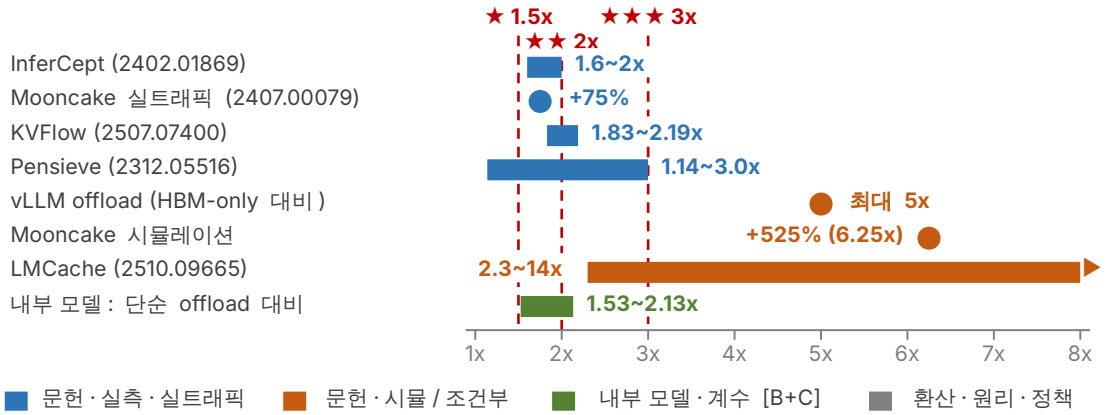
Max Goodput 배수 R = [SLO(TTFT ≤ 2 s, TPOT ≤ 50 ms) 를 만족하며 처리 가능한 최대 요청량 (req/s)] 의 후보 ÷ Baseline. Baseline 은 HBM-only 가 아니라 HBM+DRAM 단순 offloading(LRU, 동기 로드 ) 이다 . 같은 HW· 모델 ·workload 에서 부하를 sweep 해 SLO 위반 직전 요청률을 Goodput 으로 보고 , 시나리오 × 시스템 쌍별 R 을 구해 기하평균으로 집계한다 . 단위 x( 배 ), 높을수록 좋음 (↑).

| 별 | 조건 (R = 후보 ÷ Baseline) | 근거 |
|---|---|---|
| ☆ 미충족 | R < 1.5x | 시나리오 목표 미달 . 같은 수요에 서버를 2/3 로 줄이지 못함 (1/1.5) |
| ★ | R ≥ 1.5x | 시나리오 목표 ( 하한 ). 서버 33% 절감 환산 [C]. 문헌 하한대 : InferCept 1.6x, Mooncake 실트래픽 +75% |
| ★½ | R ≥ 1.75x | ★(1.5x) 과 ★★ (2x) 의 중점 . 서버 43% 절감 환산 . Mooncake +75%, KVFlow 1.83x 구간 |
| ★★ | R ≥ 2.0x | 서버 50% 절감 . KVFlow 최대 2.19x(vs SGLang HiCache, DRAM offload 기반 ), InferCept 상단 2x |
| ★★½ | R ≥ 2.5x | ★★(2x) 과 ★★★ (3x) 의 중점 . 서버 60% 절감 . 문헌 실 GPU 보고 2~3x 구간의 상단 |
| ★★★ | R ≥ 3.0x | 상한 . 서버 67% 절감 환산 . 실 GPU 다중 턴 서빙 보고 상한 (Pensieve 3.0x) |

### 품질 시나리오 측정 시나리오 (6 element)

| | |
|---|---|
| 자극원 (Source) | 다수의 agent 세션 ( 동시 요청 클라이언트 ) |
| 자극 (Stimulus) | multi-turn 요청 동시 도착 : 활성 세션 수백 ~1,200 개 , Poisson 도착 , 부하 sweep |
| 대상 (Artifact) | KV cache 서빙 경로 (HBM·DRAM· 확장 메모리의 배치 · 이동 · 재사용 계층 ), 후보 vs Baseline |
| 환경 (Environment) | 정상 운영 , working set > HBM+DRAM 용량 . 8×H100 급 노드 , 70B 급 모델 , 컨텍스트 16K~32K |
| 응답 (Response) | KV 재사용 hit 는 재계산 없이 로드 , SLO 안에서 더 많은 요청을 처리 |
| 응답 측정 (Measure) | SLO(TTFT ≤ 2 s, TPOT ≤ 50 ms) 만족 Max Goodput ÷ Baseline ≥ 1.5x (★), ≥ 3x (★★★) |

### Goodput· 처리량 개선 배수 R (Baseline 대비 )




| 구분 | 문헌 · 출처 | 지표 · 조건 | 값 | 별 반영 |
|---|---|---|---|---|
| 문헌 | InferCept<br>arXiv 2402.01869 | tool 호출 (augmented LLM) 서빙 , 최신 서빙 시스템 대비 처리량 | 1.6~2x | ★ 하한 / ★★ 상단 |
| 문헌 | Mooncake FAST'25<br>arXiv 2407.00079 | KVCache 중심 분리 서빙 , SLO 하 실트래픽 (Kimi) 요청 처리 | +75% | ★~★½ |
| 문헌 | KVFlow<br>arXiv 2507.07400 | 멀티에이전트 workflow prefix cache, SGLang(HiCache) 대비 최대 | 1.83x / 2.19x | ★½~★★ 근거 |
| 문헌 | Pensieve<br>arXiv 2312.05516 | 다중 턴 stateful 서빙 , vLLM·TensorRT-LLM 대비 처리량 | 1.14~3.0x | ★★★ 상한 |
| 조건부 | vLLM blog 2026-01,<br>Mooncake 시뮬 , LMCache | HBM-only 대비 CPU offload 최대 5x(v0.12);<br>특정 trace· 조건의 최대치 | 5~14x | 상한 제외 |
| 내부 [C] | qa_evidence_models.py<br>(5 seeds, 12 시나리오 중 유효 2) | 단순 offload(HBM 400 GB+DRAM 1.5 TB) 대비 4-tier(+CXL 2 TB, SSD 8 TB)+prefetch 겹침 70%, Zipf α=0.8 재방문 | 1.53x / 2.13x | geomean 1.80x<br>★~★★ 구간 |

**주의** 문헌 지표 ( 처리량 · 요청 수 ·goodput) 와 baseline·workload 가 달라 직접 비교 불가 [ 문헌 인용 ]. 문헌 baseline 은 대부분 HBM-only· 단일 offload 라 'HBM+DRAM 단순 offloading 대비 ' 로 읽을 수 없고 KVFlow(vs HiCache) 가 가장 가깝다 . 내부 모델은 12 개 시나리오 중 비교유효 2 건 ( 포화 3: R≈1.02~1.06 · Baseline 붕괴 (<1 req/s) 2: R 9~16x 는 상한 제외 · Baseline infeasible 5: 64K 컨텍스트 miss 재계산이 SLO 초과이거나 goodput 탐색 하한 0.05 req/s 도달 ) 이며 단일 큐 · 고정 파라미터 모델이라 실측이 아니다 . 유효 판정 기준 (Baseline ≥ 1 req/s, R > 1.10; ≤1.10 은 동등 처리 , seed 간 CI 미산출 ) 은 1 차 실행 결과를 본 뒤 fit-label 정의에 따라 적용했다 .

출처 : arXiv 2402.01869, 2407.00079(FAST'25), 2507.07400, 2312.05516, 2510.09665(LMCache, 검색 요약 기준 · 원문 미확인 ), vLLM blog 2026-01-08 'Inside vLLM's New KV Offloading Connector'( 검색 요약 기준 ). 내부 : doc-mk/QA-criteria-v5/qa_evidence_models.py, qa_evidence_out.json

# QA-02. Performance (Tail Latency) - 별 기준과 근거



## 고부하 Elapsed Time(P99) 을 Baseline 대비 몇 % 줄이면 ★ / ★★ / ★★★ 인가 ( 단 , SLO 만족 )

QA-02

**지표 설명**

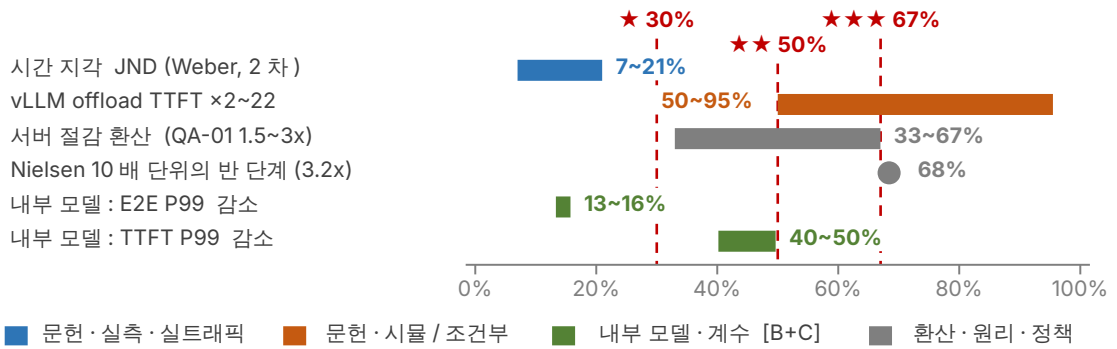
P99 지연 감소율 r = 1 − P99( 후보 ) ÷ P99(Baseline). Elapsed Time = 요청 도착부터 마지막 토큰 완료까지 ( 큐 대기 + KV 로드 / 재계산 + decode). 같은 부하 (Baseline 한계 처리량의 70%) 에서 비교하고 SLO(TTFT ≤ 2 s, TPOT ≤ 50 ms) 를 못 지키면 미충족 . Baseline 은 QA-01 과 같은 HBM+DRAM 단순 offloading. 단위 %, 높을수록 좋음 (↑). r 은 속도 배수 1/(1−r) 와 같다 (30% → 1.43x, 50% → 2x, 67% → 3x).

| 별 | 조건 (r = P99 감소율 ) | 근거 |
|---|---|---|
| ☆ 미충족 | r < 30% | 체감 임계 미달 . 시간 지각 JND(≈7~21%) 에 가까워 사용자가 개선을 확신하기 어려움 |
| ★ | r ≥ 30% | 시나리오 목표 ( 하한 ). JND 20% 안팎의 1.5 배 : ' 분명히 빨라졌다 ' 고 느끼는 수준 [ 환산 ], 속도 1.43x |
| ★½ | r ≥ 40% | ★(30%) 과 ★★ (50%) 의 중점 . 속도 1.67x. 지연이 절반에 가까워지는 구간 |
| ★★ | r ≥ 50% | 지연이 절반 (2x faster) 이라 인지 구분이 명확 . vLLM offload 의 TTFT ×2 하한과 일치 |
| ★★½ | r ≥ 58.5% | ★★(50%) 과 ★★★ (67%) 의 중점 . 속도 2.4x |
| ★★★ | r ≥ 67% | 상한 . 지연 1/3(3x). Nielsen 응답시간 한계 (0.1/1/10 s, 10 배 단위 ) 의 반 단계 (10^0.5≈3.2x) 에 대응 [ 환산 ] |

### 품질 시나리오 측정 시나리오 (6 element)

| | |
|---|---|
| **자극원 (Source)** | 다수의 agent 세션 , 사용자 ( 응답을 기다리는 클라이언트 ) |
| **자극 (Stimulus)** | 고부하 요청 폭주 : Baseline 한계 처리량의 70% 부하 , working set > HBM+DRAM |
| **대상 (Artifact)** | KV cache 서빙 경로 ( 요청 큐 → KV 로드 / 재계산 → prefill → decode) |
| **환경 (Environment)** | 정상 운영 · 고부하 , SLO(TTFT ≤ 2 s, TPOT ≤ 50 ms) 충족 조건 , 70B 급 모델 , 컨텍스트 16K~64K |
| **응답 (Response)** | KV tier 이동 ·prefetch 로 miss 재계산과 큐 대기를 줄여 최악 지연을 단축 |
| **응답 측정 (Measure)** | Elapsed Time P99 감소율 ≥ 30% vs Baseline (★), ≥ 67% (★★★), SLO 만족 시 |

### Elapsed Time(P99) 감소율 r (Baseline 대비 , %)




| 구분 | 문헌 · 출처 | 지표 · 조건 | 값 | 별 반영 |
|---|---|---|---|---|
| 문헌 | Calibre 'perceived performance' 등 | 시간 지각 Weber 분수 : 1 s 규모 JND ≈ 0.17~0.21, 일부 자료는 7~18% | 7~21% | ★ 근거 (30% > JND) |
| 문헌 | NN/g 3 response-time limits | 응답시간 한계 0.1 / 1 / 10 s (Miller 1968, Nielsen 1993): 10 배 단위 | 10 배 단위 | ★★★ 환산 (3x≈ 반 단계 ) |
| 문헌 | web.dev 'Milliseconds make millions' (Deloitte×Google, 2020) | 모바일 0.1 s 속도 개선 → 리테일 전환율 +8.4% (37 개 브랜드 , 4 주 ) | +8.4% / 0.1 s | 지연 민감도 ( 도메인 상이 ) |
| 일화 | Linden(Amazon), Mayer(Google) 발표 | +100 ms → 판매 약 - 1%, +0.5 s → 트래픽 - 20% (1 차 자료 미확인 ) | −1% / −20% | 참고 ( 일화 ) |
| 문헌 | vLLM blog 2026-01 (KV offloading connector) | CPU offload 로 TTFT ×2~×22↓ (HBM-only 대비 , 프롬프트 길이 의존 ) | 50~95% | ★★ 하한 / 상한 참고 |
| 내부 [C] | QA-01 과 같은 모델 ( 유효 2/12) | Baseline 한계 처리량의 70% 부하 , 5 seeds, E2E = TTFT + 128 tok × 25 ms | E2E 13~16% TTFT 40~50% | E2E ☆ / TTFT ★~★★ |

**주의** 체감은 과업 의존이다 : arXiv 2604.06183(TTFT 2/9/20 s 실험 ) 에서 2 s 응답이 9~20 s 보다 ' 덜 사려 깊다 ' 고 평가됐고 arXiv 2608.24189( 배포 데이터 ) 는 TTFT 와 만족도의 유의한 상관을 못 찾았다 ( 둘 다 검색 요약 기준 ) → 30~67% 는 ' 분명한 속도 개선 ' 의 기준이지 만족도 보증이 아니다 . JND 값은 2 차 자료 (1 차 심리물리 논문 미확인 ). 내부 모델의 E2E 감소율은 후보와 무관한 decode 구간 (3.2 s) 이 분모를 키워 희석되며 , TTFT 기준으로는 ★ ~★★ 구간이다 . 이 차이는 ★ 판정 시 어떤 지연을 쓸지 (E2E vs TTFT) 를 평가 정의에서 고정해야 함을 뜻한다 .

출처 : calibreapp.com/blog/perceived-performance, nngroup.com(3 response time limits), web.dev/case-studies/milliseconds-make-millions, Linden·Mayer 발표 (2 차 인용 ), vLLM blog 2026-01-08( 검색 요약 기준 ), arXiv 2604.06183, 2608.24189. 내부 : doc-mk/QA-criteria-v5/qa_evidence_models.py

# QA-03. Scalability - 별 기준과 근거



## 노드를 N 배로 늘릴 때 처리량이 선형 대비 몇 % 유지되면 ★ / ★★ / ★★★ 인가

QA-03

**지표 설명**

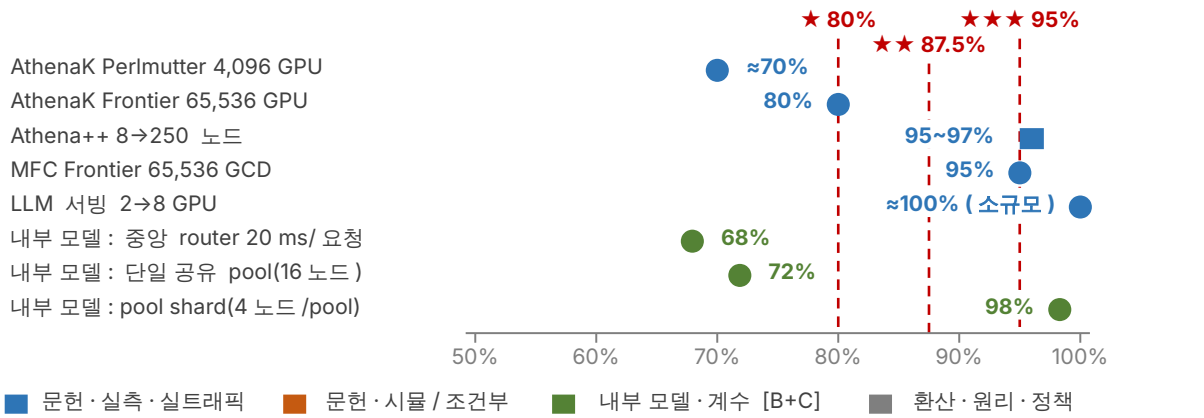
Scaling Efficiency SE(N) = 처리량 증가 배율 ÷ 자원 증가 배율 = Goodput(N) ÷ ((N / N0) × Goodput(N0)), N0 = 2, N = 16( 요청 도착률도 N 에 비례해 증가 ). Goodput 은 QA-01 과 같이 SLO(TTFT ≤ 2 s, TPOT ≤ 50 ms) 를 만족한 처리량 . 단위 %, 높을수록 좋음 (↑), 이론 상한 100%. N > 2 구간은 모델 외삽 ( 시뮬레이션 , 제약 C04) 이며 , 별은 보완 설계 ( 샤딩 등 ) 적용 전 구성 기준이다 .

| 별 | 조건 (SE(N=16)) | 근거 |
|---|---|---|
| ☆ 미충족 | SE ≤ 80% | 증설 비용의 20% 이상이 조율 계층에서 손실 . 시나리오 목표 미달 |
| ★ | SE > 80% | 시나리오 목표 ( 하한 ). 조율 직렬 비중 σ ≤ 1.67%. 유효 12.8 노드분 . AthenaK 65,536 GPU 80% 와 동급 |
| ★½ | SE > 83.75% | ★(80%) 과 ★★ (87.5%) 의 중점 . σ ≤ 1.29%. 유효 13.4 노드분 |
| ★★ | SE > 87.5% | ★(80%) 과 ★★★ (95%) 의 중점 . σ ≤ 0.95%. 유효 14.0 노드분 |
| ★★½ | SE > 91.25% | ★★(87.5%) 과 ★★★ (95%) 의 중점 . σ ≤ 0.64%. 유효 14.6 노드분 |
| ★★★ | SE > 95% | 상한 . σ ≤ 0.35%( 조율 계층이 요청 처리의 0.35% 이하 ). MFC 95%, Athena++ 95~97% 보고와 동급 |

### 품질 시나리오 측정 시나리오 (6 element)

| | |
|---|---|
| 자극원 (Source) | 운영자 ( 자원 증설 ) / 서비스 사용자 ( 부하 증가 ) |
| 자극 (Stimulus) | 노드 수를 2 → 4 → 8 → 16 으로 증설하고 요청 도착률을 노드 수에 비례해 증가 |
| 대상 (Artifact) | 분산 KV 조율 계층 ( 전역 router·metadata· 공유 tier) 과 노드별 서빙 경로 |
| 환경 (Environment) | 정상 운영 , N0 = 2 기준 , 공유 tier 대역폭 고정 , 요청 독립 replica 가정 |
| 응답 (Response) | 증설한 노드 수만큼 SLO 만족 처리량이 선형에 가깝게 증가 |
| 응답 측정 (Measure) | SE(16) = Goodput(16) ÷ (8 × Goodput(2)) > 80% (★), > 95% (★★★) |

### Scaling Efficiency SE(N) (%)




| 구분 | 문헌 · 출처 | 지표 · 조건 | 값 | 별 반영 |
|---|---|---|---|---|
| 문헌 | AthenaK arXiv 2409.16053 | Frontier 65,536 GPU weak scaling 80%, Perlmutter 4,096 GPU ≈70% (MHD 시뮬레이션 코드 ) | 80% / 70% | ★ 근거 ( 유추 ) |
| 문헌 | MFC arXiv 2509.13575 Athena++ arXiv 2005.06651 | MFC Frontier 65,536 GCD weak 95%; Athena++ 8→250 노드 hydro 97% / MHD 95% | 95~97% | ★★★ 근거 ( 유추 ) |
| 문헌 | arXiv 2605.19775 LLM-Pilot 2410.02425 | 8B 모델 2→8 GPU 처리량 ≈ 4x; 13B A100 ≤8 pod 근사 선형 | ≈100% | 소규모 , 외삽 불가 |
| 원리 | Amdahl(1967) Gunther USL(2008) | SE(N)=1/(1+σ(N−1)). N=16 에서 80% → σ 1.67%, 95% → σ 0.35% | σ 환산 | 별 경계 환산 |
| 내부 [C] | 공유 tier 구성 sweep ( 후보 비종속 ) | 16 노드 , 노드당 로컬 처리 0.2 s, remote hit 30%, KV 10.7 GB(32K), pool 200 GB/s, M/M/1 형 지연 고정점 | 68~100% | ☆~★★★ 구성 의존 |

**주의** HPC 값은 문제 크기를 노드 수에 비례시킨 weak scaling 병렬 효율이라 서빙 SE 와 정의가 다르고 [ 유추 ], 서빙 문헌은 ≤ 8 GPU 라 N=16 외삽 근거가 못 된다 . 이전 문서가 'AMD Frontier 65,536 GPU 학습 ' 으로 적은 arXiv 2409.16053 은 AthenaK( 천체물리 MHD 코드 ) 논문이라 위처럼 바로잡았다 . 95% 는 HPC 보고의 상한대이며 서빙 시스템에 적용하는 것은 정책 선택이다 . 내부 모델은 파라미터를 사전 고정한 해석 모델이며 ( 공유 pool 을 쓰면 용량 공유 이득이 있으나 모델에 미반영 ), 노드 로컬 tier+ 전역 metadata 구성의 100% 는 hit 가 로컬에 한정된 경우다 .

출처 : arXiv 2409.16053(AthenaK), 2509.13575(MFC), 2005.06651(Athena++), 2605.19775, 2410.02425(LLM-Pilot)( 모두 검색 요약 기준 , 원문 미확인 ), Amdahl 1967, Gunther USL 2008. 내부 : doc-mk/QA-criteria-v5/qa_evidence_models.py

# QA-04. Modifiability - 별 기준과 근거



## 새 메모리 · 정책 · 데이터 · 이벤트 추가 1 건의 변경 module 이 몇 개 이하일 때 ★ / ★★ / ★★★ 인가

QA-04

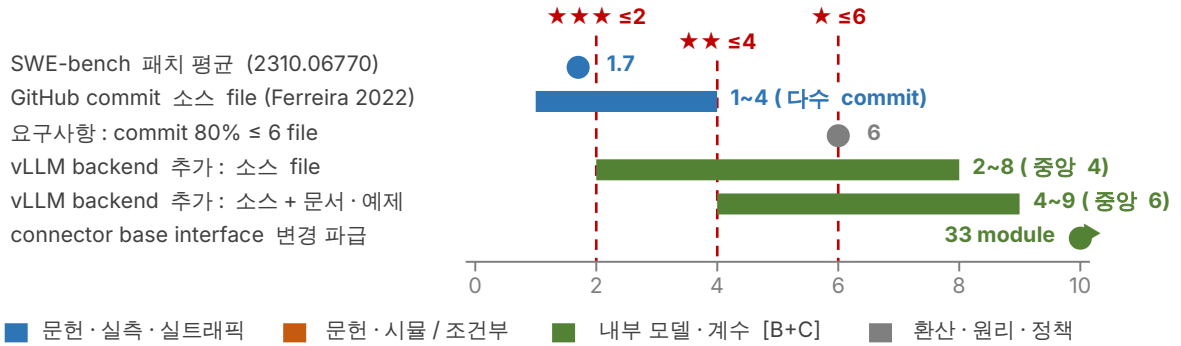
**지표 설명** 변경 module 수 = 변경 시나리오 1 건을 구현했을 때 수정 · 추가 · 삭제되는 module( 소스 파일 단위 , 테스트 · 문서 제외 ). 아래 변경 시나리오 S1~S5 를 각각 구현해 세고 시나리오 평균으로 별을 판정한다 . 단위 개 (module), 낮을수록 좋음 (↓). 서빙 경로 (scheduler·worker) 에 닿는 수정과 공개 interface 변경은 별도로 표기한다 . 현행 vLLM 에서 같은 변경을 했을 때의 module 수를 Baseline 으로 병기한다 .

| 별 | 조건 ( 변경 module 수 ) | 근거 |
|---|---|---|
| ☆ 미충족 | ≥ 7 개 | 오픈소스 commit 대부분 (80%) 이 6 file 이하라는 요구사항 기준을 벗어나는 변경 |
| ★ | ≤ 6 개 | 시나리오 목표 ( 하한 ). 요구사항 기준 : 오픈소스 commit 의 80% 가 6 file 이하 [1 차 출처 미확인 ] |
| ★½ | ≤ 5 개 | ★(6) 과 ★★ (4) 의 중점 . Ferreira 2022: 대부분 commit 이 1~10 file, 소스는 1~4 file |
| ★★ | ≤ 4 개 | ★(6) 과 ★★★ (2) 의 중점 . 소스 file 1~4 개 commit 이 다수인 구간 (Ferreira 2022) |
| ★★½ | ≤ 3 개 | ★★(4) 과 ★★★ (2) 의 중점 . 일상 변경 규모에 가까운 구간 |
| ★★★ | ≤ 2 개 | 상한 . SWE-bench 실제 issue 해결 패치의 평균 수정 1.7 file → 일상적 변경 한 건 규모 |

### 품질 시나리오 측정 시나리오 (6 element)

| | |
|---|---|
| **자극원 (Source)** | 제품 로드맵 · 운영 요구 → 개발자 ( 또는 코드 에이전트 ) |
| **자극 (Stimulus)** | 변경 S1 신규 메모리 tier(CXL → HBF/ScHBM) · S2 이동 · 배치 정책 교체 (LRU → hotness 예측 ) · S3 신규 data type(LoRA·MoE expert·RAG 캐시를 tier 관리 대상에 추가 ) · S4 신규 이벤트 (tool-call 종료 시 prefetch trigger) · S5 신규 KV 코덱 ( 압축 · 양자화 ) |
| **대상 (Artifact)** | 서빙 경로의 메모리 계층 추상화 (connector·manager·scheduler·worker) |
| **환경 (Environment)** | 개발 시점 . 현행 vLLM + 제안 구조에 구현 , 기존 unit test 통과 ( 회귀 없음 ) |
| **응답 (Response)** | 변경이 새 module 추가와 등록 지점 안에 머물고 서빙 경로 핵심 코드는 수정하지 않음 |
| **응답 측정 (Measure)** | 변경 module 수 ( 소스 file) 시나리오 평균 ≤ 6 (★), ≤ 2 (★★★). 공개 interface 변경 시 ☆ |

### 변경 module 수 ( 소스 file, 낮을수록 좋음 )




| 구분 | 문헌 · 출처 | 지표 · 조건 | 값 | 별 반영 |
|---|---|---|---|---|
| 문헌 | SWE-bench arXiv 2310.06770 | 실제 GitHub issue 해결 패치 2,294 건 : 평균 수정 파일 1.7 개 , 32.8 줄 | 1.7 file | ★★★ (≤ 2) |
| 문헌 | Ferreira 외 , SBQS 2022 (GitHub commit) | 대부분 commit 이 1~10 file, 소스 file 은 1~4 ( 요약 기준 ) | 1~4 / 1~10 | ★½~★★ 근거 |
| 요구사항 | QAW 요구사항 ( 품질 요구사항 표 ) | 오픈소스 commit 의 80% 가 6 file 이하 — 1 차 출처 미확인 | 6 file | ★ 하한 |
| 내부 계수 | 이 저장소 grep: KV connector 5 종 참조 file | backend 1 개 추가에 닿는 file — 소스 2~8, + 문서 · 예제 4~9, + 테스트 5~16 | 중앙 4 / 6 / 8 | As-Is ≈ ★~☆ 경계 |
| 내부 계수 | KVConnectorBase_V1 참조 module | connector 공개 interface(base) 를 바꿀 때 vllm/ 안에서 함께 영향받는 file 수 | 33 | interface 변경 ☆ |

**주의** 변경 시나리오 S1~S5 는 제안안이며 , 선정 근거는 이 저장소에서 KV connector 구현이 FlexKV·LMCache·Mooncake·NIXL·hf3fs·moriio·P2P·offloading 등 8 종 이상 누적됐다는 계수 (S1 이 가장 흔한 변경 유형 ) 와 정책 ·data type· 이벤트 · 코덱이 각각 독립적으로 바뀌는 축이라는 설계 가정이다 . 계수는 ' 이 저장소에서 connector 이름을 참조하는 파일 ' 수로 변경량의 대리 지표일 뿐 실제 commit 의 변경 file 수가 아니며 , 시나리오별 실제 구현 · 측정은 아직 하지 않았다 (Evidence: 문헌 + 직접 계수 , 구현 측정 미실시 ). Ferreira 2022 와 요구사항의 80% 근거는 1 차 출처 미확인 .

출처 : arXiv 2310.06770(SWE-bench), Ferreira 외 SBQS 2022(llp.dcc.ufmg.br, 검색 요약 기준 ), 품질 요구사항 표 (QA-04). 내부 : doc-mk/QA-criteria-v5/qa_evidence_out.json(qa4), grep 대상 vllm/·tests/·docs/·examples/ (doc-mk 제외 )

# QA-05. Functional Correctness - 별 기준과 근거



## LLM 출력 F1 이 Baseline(full recompute) 대비 몇 % 이내로 유지되면 ★ / ★★ / ★★★ 인가

QA-05

**지표 설명**

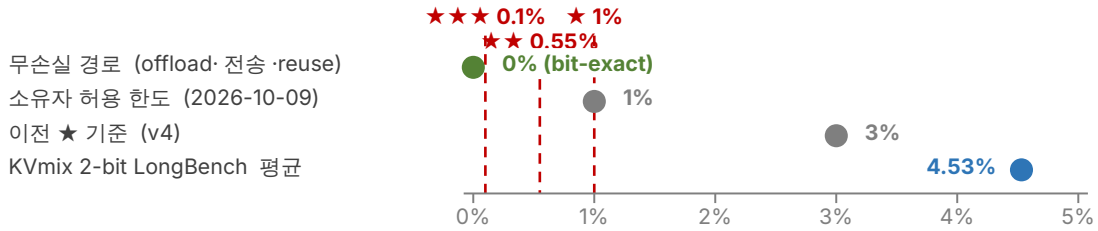
F1 상대 하락률 = (F1_baseline − F1_ 후보 ) ÷ F1_baseline. Baseline = KV 압축 · 재사용 전 full recompute 경로 . 같은 task·dataset· 모델 ·precision·greedy decoding(temperature 0) 에서 비교한다 . 압축 없이 이동 · 복원 · 재사용만 거치는 무손실 경로는 출력 bit-exact 확인 ( 하락 0%) 으로 갈음한다 . 단위 %( 상대 ), 낮을수록 좋음 (↓).

| 별 | 조건 (F1 상대 하락률 ) | 근거 |
|---|---|---|
| ☆ 미충족 | 하락 ≥ 1% | 시나리오 허용 한도 (1%) 초과 |
| ★ | 하락 < 1% | 시나리오 목표 ( 하한 ). 소유자 허용 한도 . 손실 압축 문헌의 'negligible' 구간과 같은 방향 |
| ★½ | 하락 < 0.775% | ★(1%) 과 ★★ (0.55%) 의 중점 |
| ★★ | 하락 < 0.55% | ★(1%) 과 ★★★ (0.1%) 의 중점 |
| ★★½ | 하락 < 0.325% | ★★(0.55%) 과 ★★★ (0.1%) 의 중점 |
| ★★★ | 하락 < 0.1% | 상한 [ 정책 ]. 사실상 무손실 . 비결정성 등 측정 잡음과 구분이 어려워 반복 측정 ·CI 필요 |

### 품질 시나리오 측정 시나리오 (6 element)

| | |
|---|---|
| 자극원 (Source) | 서빙 엔진 운영자 (KV 재사용 · 압축 경로 변경 ) |
| 자극 (Stimulus) | KV cache 를 tier 간 이동 · 복원 · 재사용 ( 또는 압축 ) 한 뒤 추론 요청 수행 |
| 대상 (Artifact) | KV 변환 · 이동 경로 ( 압축 코덱 · 재계산 경로 ), 추론 결과 (task 별 F1) |
| 환경 (Environment) | 동일 task·dataset· 모델 ·precision, greedy decoding, 고정 seed, 정상 운영 |
| 응답 (Response) | 압축 · 재사용 경로를 거쳐도 추론 결과가 Baseline 과 동등 |
| 응답 측정 (Measure) | F1 상대 하락률 < 1% (★), < 0.1% (★★★). 무손실 경로는 bit-exact(0%) |

### F1 상대 하락률 ( 압축 · 재사용 전 full recompute 대비 , %)




■ 문헌 · 실측 · 실트래픽 ■ 문헌 · 시뮬 / 조건부 ■ 내부 모델 · 계수 [B+C] ■ 환산 · 원리 · 정책

| 구분 | 문헌 · 출처 | 지표 · 조건 | 값 | 별 반영 |
|---|---|---|---|---|
| 문헌 | KVQuant arXiv 2401.18079 | 3-bit KV 양자화 (outlier 1% 분리 ), perplexity 저하 < 0.1 (Wikitext-2, C4) | ppl < 0.1 | F1 아님 (★★★ 방향 참고 ) |
| 문헌 | KVmix arXiv 2506.08018 | KV 2-bit 급 혼합정밀도 , LongBench 평균 상대 손실 4.53% ( 검색 요약 , KVQuant 3-bit 과 비슷 ) | 4.53% | ☆ (≥ 1%) |
| vendor | vLLM FP8 KV-cache blog (2026-04) | FP8 KV 는 검증 경로에서 near-baseline, 장문 accumulation 오류 수정 후 BF16 수준 회복 | 정성 | ★ 가능성 |
| 문헌 | Thinking Machines Lab (2025-09) | batch-invariant 가 아닌 kernel 은 같은 입력에도 출력이 변동 | 정성 | ★★★ 측정 잡음 유의 |
| 정책 | 소유자 결정 (2026-10-09) | 압축 · 재사용 전 + full recompute 대비 F1 1% 이내 허용 | 1% | ★ 하한 |
| 내부 검증 | qa_evidence_models.py | tier 왕복 복사 ( 직렬화→복원 ) 후 비트 비교 : fp16 KV block 10,000 개 (NaN·denormal 포함 임의 비트패턴 ) | 불일치 0 | 무손실 경로 0% |

**주의** 문헌은 perplexity· 정성 표현이라 F1 으로 직접 환산할 수 없고 F1 하락의 일반 임계 문헌이 없어 1% 는 소유자 한도 , 0.1% 는 정책이다 . 이전 (v4) 기준은 ★ 3% / ★★ 2% / ★★★ 1% 였으므로 이번 기준은 3~10 배 엄격하다 . 내부 검증은 무손실 경로의 복사 정확성 ( 메모리 왕복 ) 만 보이며 압축 경로의 F1 은 측정하지 않았다 . 0.1% 는 반복 측정 잡음과 겹칠 수 있어 seed·prompt 반복의 신뢰구간으로 판정해야 한다 .

출처 : arXiv 2401.18079(KVQuant), 2506.08018(KVmix, 검색 요약 기준 ), vLLM blog 2026-04-22 'The State of FP8 KV-Cache...'( 검색 요약 기준 ), Thinking Machines Lab 'Defeating Nondeterminism in LLM Inference'(2 차 요약 ). 내부 : doc-mk/QA-criteria-v5/qa_evidence_models.py, 소유자 결정 : doc-mk/Requirements/qa-star-criteria-evidence.md