QA 평가 시나리오 (1/5) - 평가 환경 · 부하 규모

핵심 평가 시나리오 = 어떤 워크로드를, 얼마나 많은 동시 세션으로, 얼마나 오래 넣고, 무엇을 재는가. 모든 QA 가 같은 환경을 공유하고, 부하 규모는 '메모리 용량 대비 세션 수' 와 'QPS 단계' 로 정한다.

평가 시스템

항목	Baseline	Target
노드 수	4 노드	1 노드
GPU / HBM	H100 80GB × 8 / 640 GB	H100 80GB × 4 / 320 GB
DRAM	1,024 GB	1,024 GB
CXL-PNM	—	512 GB × 4 = 2,048 GB
SSD	NVMe 16 TB	NVMe 16 TB + PIM-SSD
비용 / 노드	$283K	$242.7K

모델 : 70B 급 fp16 (가중치 140 GB), KV 320 KB/token [가정]. Baseline 은 HBM+DRAM 단순 offloading.

시간 · 반복 규칙

- 워밍업 5 분 (캐시 채움, 측정 제외)
- QPS 시작점 = 예상 포화 QPS 의 10%, 5 분마다 +10% 씩 증가 → SLO 를 처음 깨는 단계에서 중단 (직전 단계 = Max Goodput)
- 예상 포화 QPS 는 짧은 탐색 실행으로 먼저 추정
- 측정 구간 : 단계당 5 분 이상, 전체는 세션당 평균 8 회 호출을 소화할 때까지
- 시나리오 조합마다 5 회 반복
- 동시 in-flight 요청 = QPS × 체류시간 (예 : 5 QPS × 4.2 s ≈ 21 건). 정하는 값이 아니라 결과로 나온다

동시 세션 수 격자 (16K 컨텍스트, 5.4 GB/ 세션)

세션 수	Baseline 노드	Target 노드
20	HBM	HBM
40	HBM	DRAM 까지
80	HBM	DRAM 까지
160	HBM+DRAM	DRAM 까지
320	SSD 로 밀림	CXL 까지
640	SSD 로 밀림	SSD 로 밀림

수용 한계 (세션): Baseline HBM 81 / +DRAM 271, Target HBM 27 / +DRAM 218 / +CXL 599. 양쪽에 같은 절대 세션 수를 넣는다.

QPS 단계 예시 (예상 포화 5 QPS 인 경우)

단계	1	2	3	4	5	6	...
QPS	0.5	1	1.5	2	2.5	3	...
누적 시간	5 분	10 분	15 분	20 분	25 분	30 분	...

- 단계마다 P99 TTFT·TPOT 을 확인하고, SLO(TTFT ≤ 2 s, TPOT ≤ 50 ms) 를 처음 넘는 단계에서 중단
- 중단 직전 단계의 QPS 를 Max Goodput 으로 기록

가정 : 모델 70B 급 fp16, HBM 사용률 90%, 노드당 KV 용량 = 0.9×HBM − 가중치. 시스템 사양은 'Baseline vs Target 시스템' 장표 기준. 실제 모델 · 세션 크기가 다르면 격자를 다시 계산한다.

QA 평가 시나리오 (2/5) - 워크로드와 KV 재사용 비율

핵심 워크로드는 컨텍스트 길이와 KV 재사용 비율을 skill 로 통제하는 합성 워크로드다 (실제 agent 행동을 그대로 재현한 것은 아님). KV 재사용 비율은 ' 입력 중 이전과 같은 앞부분의 비율 ' 로 , Target 이 지는 구간과 이기는 구간을 모두 보이기 위한 축이다 .

워크로드 3 종 (각각 개별 실행 + 혼합 실행)

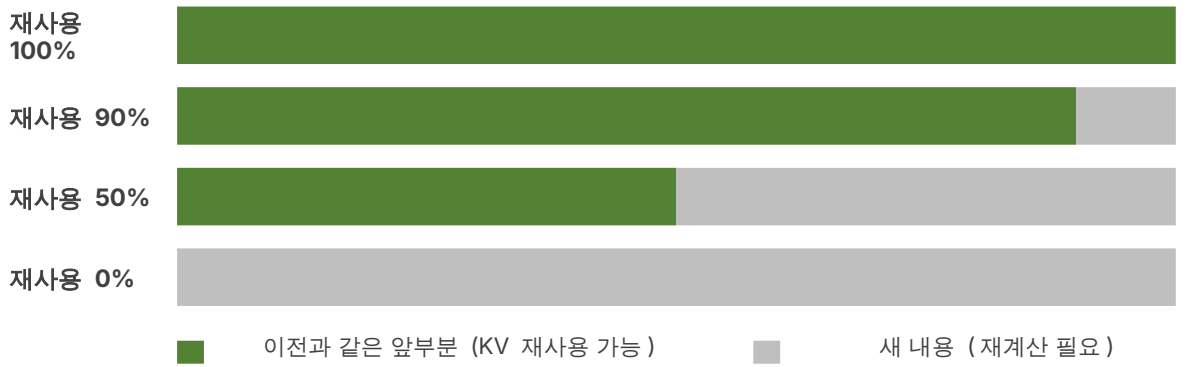
ID	내용	컨텍스트	혼합 비율
W-A	짧은 챗 (대조군)	4K	20%
W-B	멀티턴 agent (주 시나리오)	16K	50%
W-C	긴 컨텍스트 agent· 코딩	32K	30%

혼합 비율은 설계 가정 : 타깃이 agent 중심이라 W-B 를 주력으로 , W-A 는 재사용 이득이 작은 대조군으로 최소 , W-C 는 용량 압박을 보이는 용도로 30%.

생성 방식 (skill 기반 합성 워크로드)

- 컨텍스트 길이 (4K/16K/32K) 와 재사용 비율을 skill 로 통제 . 컨텍스트는 시나리오마다 고정 (단순화)
- 세션당 LLM 호출 (에이전트 내부 루프) 평균 8 회 , 3~20 분포 [가정]
- 호출 1 건 : 신규 입력 ≈ 1K, 출력 ≈ 128 token, tool 대기 1~5 s [가정]
- 세션 호출 쏠림 : Zipf(α=0.8) — 호출 빈도 순위가 높은 소수 세션이 더 자주 호출된다 . agent 가 보이는 특성을 부하 생성기가 흉내 내는 값이며 , 실제 로그가 있으면 α 를 보정 [가정]
- 한계 : 실제 agent 의 컨텍스트 증가 · 편집 패턴은 반영하지 않음 . opencode 실제 세션 로그로 길이 분포를 보정하면 신뢰도가 올라감

KV 재사용 비율 = 입력 중 이전과 같은 앞부분의 비율



- 앞부분이 같으면 KV 를 재사용하고 , 달라진 지점부터는 재계산한다
- 100%: 대화 끝에 이어 붙이기만 하는 경우 (append)
- 50·90%: 컨텍스트 요약 · 편집 , 오래된 tool 결과의 제거 · 교체로 앞부분이 일부만 같아지는 경우
- 0%: 매번 처음부터 계산 (full prefill) — Target 이 지는 구간 (0.49x)
- 실제 hit 은 이 상한 이하이며 캐시 용량에 따라 달라진다
- 범위 밖 : 다른 세션끼리 KV 를 공유하는 재사용 (공통 system prompt 등). 필요하면 별도 축으로 추가

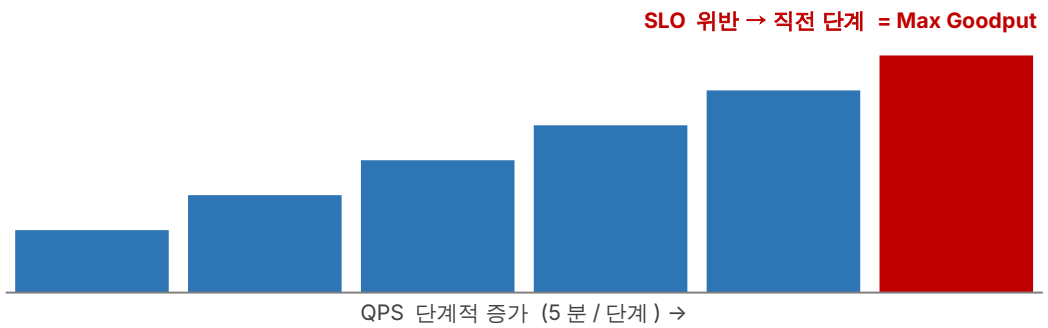
재사용 비율 축의 근거 : 'Baseline vs Target 시스템 ' 장표 분석값 (Full prefill 0.49x, Full KV reuse 1.63x). 호출 횟수 · 입력 크기 ·Zipf α· 혼합 비율은 모두 가정이며 실제 로그로 보정 가능 .

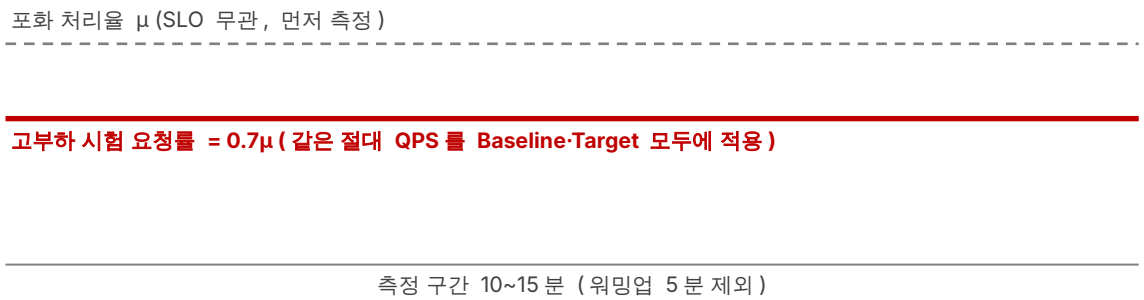
QA-01·02 평가 시나리오 (3/5) - 동시 요청 부하

핵심 QA-01 은 요청률을 올려 SLO 한계까지 밀어 최대 처리량 (QPS) 을 재고 , QA-02 는 포화 처리율의 70% 부하 (고부하) 를 고정해 꼬리 지연을 잰다 . 둘 다 Target 1 노드와 Baseline 8GPU 1 노드를 같은 부하로 비교한다 .

QA-01 처리량 (Max Goodput)	
비교	Target 노드 vs Baseline 8GPU 노드 (노드 단위), 같은 부하
워크로드	W-A/B/C 개별 + 혼합 (20/50/30) × 세션 수 20~640(6 단계) × KV 재사용 0/50/90/100%
부하	Poisson 도착 , 시작 = 예상 포화 QPS 의 10%, 5 분마다 +10%, SLO 위반 직전까지
SLO	P99 TTFT ≤ 2 s, TPOT ≤ 50 ms
측정	SLO 만족 최대 QPS(Goodput), R = Target ÷ Baseline 의 기하평균
보조	Target 에서 CXL 을 끈 4GPU 구성 (CXL 효과만 분리), 5 회 반복

QA-02 꼬리 지연 (P99)	
비교	QA-01 과 같음 . 같은 절대 QPS 에서 후보 vs Baseline
워크로드	W-B/C, 세션 160/320/640, KV 재사용 90/100%
부하	Baseline 포화 처리율 μ 를 먼저 측정 → 요청률을 0.5μ / 0.7μ / 0.9μ 로 각각 고정해 비교 (고부하 기준 70% 의 민감도 확인)
SLO	후보가 SLO 를 만족하는 조건에서만 판정
측정	P99 Elapsed Time(E2E)·TTFT 감소율 r = 1 − P99(후보)/P99(Baseline)
반복	구간 10~15 분 , 5 회 반복 . 고부하 근거는 'QA-02 보충 ' 장표





KV 재사용 비율 · 워크로드 정의는 2/5 장표 참조 . 조합이 많으면 재사용 비율을 0/90/100% 로 줄일 수 있다 .

QA-03 평가 시나리오 (4/5) - 확장성

핵심 Target 은 1 노드뿐이라 노드 간 확장을 직접 잴 수 없다. 노드 안 확장 (Target) 과 노드 간 확장 (Baseline 4 노드) 을 따로 재서 조율 직렬 비중 σ 로 합치고, 16 노드 SE 는 외삽한다 [C].

① 노드 안 확장 — Target 1 노드

- 활성 GPU 를 1 → 2 → 4 개로 증가
- 부하 (요청률) 를 GPU 수에 비례해 증가
- CXL-PNM 4 카드는 GPU 들이 공유
- 얻는 값 : σ_intra (CXL 공유 경합)

② 노드 간 확장 — Baseline 4 노드

- 같은 조율 SW(router· 전역 metadata) 를 DRAM 계층만으로 구동
- 노드를 1 → 2 → 3 → 4 로 증가, 노드당 GPU 4 개만 사용 (Target 과 맞춤)
- 얻는 값 : σ_inter, 요청당 조율 시간 t_coord(ms)

③ 합성 → 16 노드 외삽 [C]

- σ_target ≈ σ_intra + t_coord ÷ t_service (t_service = Target 노드의 요청 처리 시간)
- SE(16) = 1 / (1 + 15σ)
- 별 판정은 σ(와 신뢰구간) 로 한다

별 기준과 σ (N0=1 정의, 제안)

별	SE(16)	σ 상한
★	> 90%	0.74%
★★	> 92.5%	0.54%
★★★	> 95%	0.35%

- Baseline 4 노드는 독립 replica 라 σ≈0(SE≈100%) 이 기대된다 → 측정 방법 검증용으로 실측해 본다
- 반복 측정으로 σ 의 신뢰구간을 내고, 별 경계에 걸치면 '경계 걸침' 으로 표기

한계 · 확인 필요

- Baseline 노드에는 CXL 이 없어 노드 간 공유 tier 경합은 평가하지 못함
- σ 를 더하는 합성은 근사이고, Baseline 노드는 하드웨어가 달라 비율값만 가져옴
- 노드 간 공유 경합 (κ) 을 무시한 값이라 실제 SE(16) 은 더 낮을 수 있음
- 확인 필요 : ① 노드 간 네트워크 ② 조율 SW 를 DRAM 만으로 구동 가능한지 ③ N0=1 정의 동의
- Target 이 노드 간 KV 를 옮기거나 공유하면 그 전송 비용도 σ 에 더한다

SE(N) = 1/(1+σ(N−1)) (USL, N0=1). 기존 장표의 N0=2 정의 대신 Target 1 노드 제약에 맞춘 제안이며, σ 상한은 ★ 0.74% / ★★★ 0.35%.

QA-04·05 평가 시나리오 (5/5) - 변경 용이성 · 정확성

핵심 QA-04 는 변경 5 건을 실제로 구현해 바뀐 소스 파일 수를 세고 , QA-05 는 KV 재사용 경로를 강제로 타게 한 뒤 full recompute 와 F1 을 문항별로 비교한다 .

QA-04 변경 용이성 — 변경 시나리오 5 건

ID	변경 내용	예
S1	신규 메모리 tier 추가	CXL → HBF / ScHBM
S2	이동 · 배치 정책 교체	LRU → hotness 예측
S3	신규 data type 추가	LoRA·MoE expert·RAG 캐시
S4	신규 이벤트 추가	tool-call 종료 시 prefetch
S5	신규 KV 코덱 추가	압축 · 양자화

QA-05 정확성 — F1 비교

항목	내용
데이터	멀티턴 QA 데이터셋 , 500 문항 이상 (가정)
실행	2-pass: 1 회차에 KV 캐시를 채우고 , 2 회차에 재사용 경로를 강제
비교	재사용 경로 vs full recompute, 같은 모델 ·precision, greedy, 고정 seed
판정	문항별 paired bootstrap, F1 하락률 95% CI 상한 < 1% (★), < 0.1% (★★★)
추가 검사	tier 왕복 복사 후 KV 비트 일치 (bit-exact) 확인

- 각 변경을 현행 vLLM 과 제안 구조에서 각각 구현
- 측정 : 수정 · 추가 · 삭제된 소스 파일 수 (테스트 · 문서 제외)
- 판정 : 5 건 평균 ≤ 6 개 (★), ≤ 2 개 (★★★) — vLLM commit 분포 기준
- 조건 : 기존 unit test 통과 (회귀 없음), 서빙 경로 핵심 코드 (scheduler·worker) 수정 최소
- 구현자 · 구현 도구와 소요 시간도 함께 기록 (참고)

- 본 시스템은 압축을 쓰지 않으므로 이동 · 복원 · 재사용 경로만 대상
- 재사용 경로가 다른 kernel·chunk 경계를 타면 비트 차이가 생길 수 있어 F1 로 확인
- 0.1% 는 문항 수가 부족하면 입증이 어려움 → 문항 수를 늘리거나 기준 재검토

QA-04 구현 측정은 아직 수행하지 않았다 (계획). QA-05 데이터셋 크기와 종류는 가정이며 확정이 필요하다 .