QA 평가 시나리오 (1/4) - 평가 환경 · 워크로드 · 부하 규모

핵심 평가 시나리오 = 어떤 워크로드를, 얼마나 많은 동시 세션으로, 얼마나 오래 넣고, 무엇을 재는가. 모든 QA 가 같은 환경과 워크로드를 공유하고, 부하 규모는 '메모리 용량 대비 세션 수' 로 정한다.

평가 시스템

항목	Baseline	Target
노드 수	4 노드	1 노드
GPU / HBM	H100 80GB × 8 / 640 GB	H100 80GB × 4 / 320 GB
DRAM	1,024 GB	1,024 GB
CXL-PNM	—	512 GB × 4 = 2,048 GB
SSD	NVMe 16 TB	NVMe 16 TB + PIM-SSD
비용 / 노드	$283K	$242.7K

모델 : 70B 급 fp16 (가중치 140 GB), KV 320 KB/token [가정]. Baseline 은 HBM+DRAM 단순 offloading.

워크로드 3 종 (에이전트 내부 LLM 호출 루프)

ID	내용	컨텍스트	KV 재사용
W-A	짧은 챗 (대조군)	4K	낮음
W-B	멀티턴 agent (주 시나리오)	16K	높음
W-C	긴 컨텍스트 agent· 코딩	32K	매우 높음

- 세션당 LLM 호출 횟수는 분포로 정한다 : 평균 8 회 (범위 3~20)
- 호출 1 건 : 신규 입력 ≈ 1K token, 출력 ≈ 128 token, tool 대기 1~5 s
- 세션 재방문은 Zipf(α=0.8): 일부 세션이 더 자주 호출됨
- KV 재사용 비율 0 / 50 / 90 / 100% 축을 추가 (Target 은 0% 에서 불리 , 100% 에서 유리)

동시 세션 수 격자 (16K 컨텍스트 , 5.4 GB/ 세션)

세션 수	Baseline 노드	Target 노드
20	HBM	HBM
40	HBM	DRAM 까지
80	HBM	DRAM 까지
160	HBM+DRAM	DRAM 까지
320	SSD 로 밀림	CXL 까지
640	SSD 로 밀림	SSD 로 밀림

수용 한계 (세션): Baseline HBM 81 / +DRAM 271, Target HBM 27 / +DRAM 218 / +CXL 599. 양쪽에 같은 절대 세션 수를 넣는다.

시간 · 반복 규칙

- 워밍업 5 분 (캐시 채움 , 측정 제외)
- 요청률 (QPS) 을 5 분씩 단계적으로 올림 → SLO 를 처음 깨는 단계에서 중단
- 측정 구간 : 15 분 이상 , 그리고 세션당 평균 8 회 호출을 소화할 때까지
- 예 : 640 세션 , 5 QPS → 640×8 ÷ 5 ≈ 17 분
- 시나리오 조합마다 5 회 반복
- 동시 in-flight 요청 = QPS × 체류시간 (예 : 5 QPS × 4.2 s ≈ 21 건). 이 값은 정하는 것이 아니라 결과로 나온다

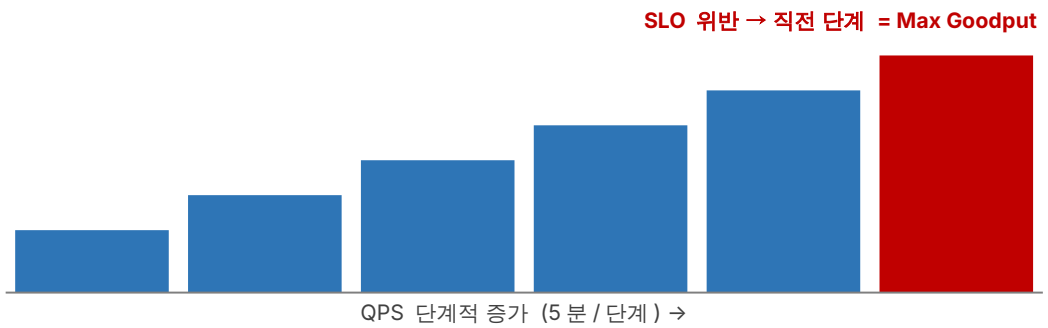
가정 : 모델 70B 급 fp16, HBM 사용률 90%, 노드당 KV 용량 = 0.9×HBM − 가중치 . 시스템 사양은 'Baseline vs Target 시스템 ' 장표 기준 . 실제 모델 · 세션 크기가 다르면 격자를 다시 계산한다 .

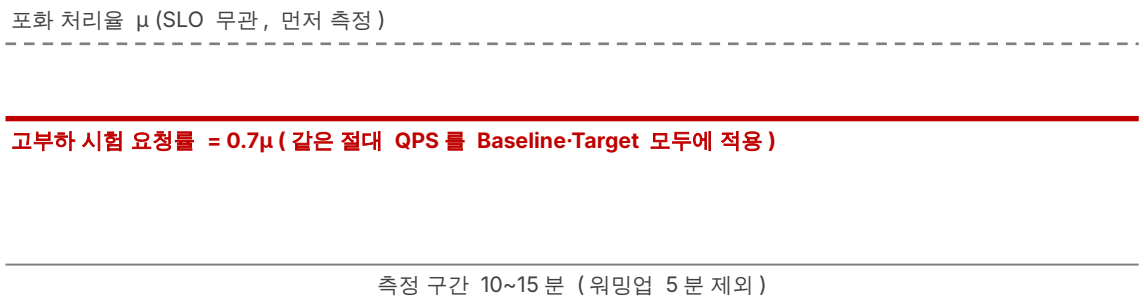
QA-01·02 평가 시나리오 (2/4) - 동시 요청 부하

핵심 QA-01 은 요청률을 올려 SLO 한계까지 밀어 최대 처리량 (QPS) 을 재고 , QA-02 는 한계의 70% 부하 (고부하) 를 고정해 꼬리 지연을 잰다 . 둘 다 Target 1 노드와 Baseline 8GPU 1 노드를 같은 부하로 비교한다 .

QA-01 처리량 (Max Goodput)	
비교	Target 노드 vs Baseline 8GPU 노드 (노드 단위), 같은 부하
워크로드	W-A/B/C × 세션 수 20~640(6 단계) × KV 재사용 0/50/90/100%
부하	Poisson 도착 , QPS 를 5 분씩 올려 SLO 위반 직전까지
SLO	P99 TTFT ≤ 2 s, TPOT ≤ 50 ms
측정	SLO 만족 최대 QPS(Goodput), R = Target ÷ Baseline 의 기하평균
보조	Target 에서 CXL 을 끈 4GPU 구성 (CXL 효과만 분리), 5 회 반복

QA-02 꼬리 지연 (P99)	
비교	QA-01 과 같음 . 같은 절대 QPS 에서 후보 vs Baseline
워크로드	W-B/C, 세션 160/320/640, KV 재사용 90/100%
부하	Baseline 의 포화 처리율 μ 를 먼저 측정 → 요청률 = 0.7μ 고정 (50/90% 도 sweep)
SLO	후보가 SLO 를 만족하는 조건에서만 판정
측정	P99 Elapsed Time(E2E)·TTFT 감소율 r = 1 − P99(후보)/P99(Baseline)
반복	구간 10~15 분 , 5 회 반복 . 고부하 근거는 'QA-02 보충 ' 장표





KV 재사용 비율은 Target 이 지는 구간 (0%: Full prefill 0.49x) 과 이기는 구간 (100%: Full KV reuse 1.63x, 'Baseline vs Target' 장표 분석값) 을 모두 드러내기 위한 축이다 . 조합이 많으면 재사용 비율을 0/90/100% 로 줄일 수 있다 .

QA-03 평가 시나리오 (3/4) - 확장성

핵심 Target 은 1 노드뿐이라 노드 간 확장을 직접 잴 수 없다. 노드 안 확장 (Target) 과 노드 간 확장 (Baseline 4 노드) 을 따로 재서 조율 직렬 비중 σ 로 합치고, 16 노드 SE 는 외삽한다 [C].

① 노드 안 확장 — Target 1 노드

- 활성 GPU 를 1 → 2 → 4 개로 증가
- 부하 (요청률) 를 GPU 수에 비례해 증가
- CXL-PNM 4 카드는 GPU 들이 공유
- 얻는 값 : σ_intra (CXL 공유 경합)

② 노드 간 확장 — Baseline 4 노드

- 같은 조율 SW(router· 전역 metadata) 를 DRAM 계층만으로 구동
- 노드를 1 → 2 → 3 → 4 로 증가, 노드당 GPU 4 개만 사용 (Target 과 맞춤)
- 얻는 값 : σ_inter, 요청당 조율 시간 t_coord(ms)

③ 합성 → 16 노드 외삽 [C]

- σ_target ≈ σ_intra + t_coord ÷ t_service (t_service = Target 노드의 요청 처리 시간)
- SE(16) = 1 / (1 + 15σ)
- 별 판정은 σ(와 신뢰구간) 로 한다

별 기준과 σ (N0=1 정의, 제안)

별	SE(16)	σ 상한
★	> 90%	0.74%
★★	> 92.5%	0.54%
★★★	> 95%	0.35%

- Baseline 4 노드는 독립 replica 라 σ≈0(SE≈100%) 이 기대된다 → 측정 방법 검증용으로 실측해 본다
- 반복 측정으로 σ 의 신뢰구간을 내고, 별 경계에 걸치면 '경계 걸침' 으로 표기

한계 · 확인 필요

- Baseline 노드에는 CXL 이 없어 노드 간 공유 tier 경합은 평가하지 못함
- σ 를 더하는 합성은 근사이고, Baseline 노드는 하드웨어가 달라 비율값만 가져옴
- 노드 간 공유 경합 (κ) 을 무시한 값이라 실제 SE(16) 은 더 낮을 수 있음
- 확인 필요 : ① 노드 간 네트워크 ② 조율 SW 를 DRAM 만으로 구동 가능한지 ③ N0=1 정의 동의
- Target 이 노드 간 KV 를 옮기거나 공유하면 그 전송 비용도 σ 에 더한다

SE(N) = 1/(1+σ(N−1)) (USL, N0=1). 기존 장표의 N0=2 정의 대신 Target 1 노드 제약에 맞춘 제안이며, σ 상한은 ★ 0.74% / ★★★ 0.35%.

QA-04·05 평가 시나리오 (4/4) - 변경 용이성 · 정확성

핵심 QA-04 는 변경 5 건을 실제로 구현해 바뀐 소스 파일 수를 세고 , QA-05 는 KV 재사용 경로를 강제로 타게 한 뒤 full recompute 와 F1 을 문항별로 비교한다 .

QA-04 변경 용이성 — 변경 시나리오 5 건

ID	변경 내용	예
S1	신규 메모리 tier 추가	CXL → HBF / ScHBM
S2	이동 · 배치 정책 교체	LRU → hotness 예측
S3	신규 data type 추가	LoRA·MoE expert·RAG 캐시
S4	신규 이벤트 추가	tool-call 종료 시 prefetch
S5	신규 KV 코덱 추가	압축 · 양자화

QA-05 정확성 — F1 비교

항목	내용
데이터	멀티턴 QA 데이터셋 , 500 문항 이상 (가정)
실행	2-pass: 1 회차에 KV 캐시를 채우고 , 2 회차에 재사용 경로를 강제
비교	재사용 경로 vs full recompute, 같은 모델 ·precision, greedy, 고정 seed
판정	문항별 paired bootstrap, F1 하락률 95% CI 상한 < 1% (★), < 0.1% (★★★)
추가 검사	tier 왕복 복사 후 KV 비트 일치 (bit-exact) 확인

- 각 변경을 현행 vLLM 과 제안 구조에서 각각 구현
- 측정 : 수정 · 추가 · 삭제된 소스 파일 수 (테스트 · 문서 제외)
- 판정 : 5 건 평균 ≤ 6 개 (★), ≤ 2 개 (★★★) — vLLM commit 분포 기준
- 조건 : 기존 unit test 통과 (회귀 없음), 서빙 경로 핵심 코드 (scheduler·worker) 수정 최소
- 구현자 · 구현 도구와 소요 시간도 함께 기록 (참고)

- 본 시스템은 압축을 쓰지 않으므로 이동 · 복원 · 재사용 경로만 대상
- 재사용 경로가 다른 kernel·chunk 경계를 타면 비트 차이가 생길 수 있어 F1 로 확인
- 0.1% 는 문항 수가 부족하면 입증이 어려움 → 문항 수를 늘리거나 기준 재검토

QA-04 구현 측정은 아직 수행하지 않았다 (계획). QA-05 데이터셋 크기와 종류는 가정이며 확정이 필요하다 .