



요구사항

이기종 메모리 LLM 서빙 스케줄링 런타임 (검수용 초안)

요구사항 분석 절차

DP1~DP4 설계·평가 문서와 시나리오에서 FR / QA / C 를 추출하고 , 품질 시나리오의 정량 값은 통합 단계에서 한 번에 정한다



* FR : Functional Requirement * QA : Quality Attribute * C : Constraint
* DP5 는 없고 DP6(CXL shared-memory KV consistency) 은 이번 범위에서 제외한다. 각 DP 의 기존 평가 결과와 임계값은 보류한다.

주요 기능 요구사항 및 제약사항

기능 요구사항 (핵심 11 건 , 전체 26 건은 다음 장)

FR26	메모리 배치와 연산의 동적 스케줄링
FR01	이기종 메모리 데이터 저장
FR02	메모리 간 데이터 복사
FR03	vLLM 연동
FR04	KV cache offload 와 재사용
FR05	LoRA adapter 서빙
FR06	RAG 서빙
FR07	MoE 모델 서빙
FR08	Prefill/Decode disaggregation
FR09	연산 offload 와 GPU fallback
FR10	서버 간 KV 전송

제약사항

C01	차세대 메모리 (HBF, ScHBM 등) 는 인터페이스를 가정하고 스펙에 따라 성능을 시뮬레이션한다
C02	시뮬레이션하는 device runtime 은 정상 동작하며 신뢰성이 보장된다고 가정한다
C03	device runtime 의 오버헤드는 무시한다
C04	실장 환경이 없는 규모 이상으로의 시스템 확장 (노드 증가) 은 시뮬레이션 기반으로 평가한다
C05	추론 엔진은 오픈소스 서빙 프레임워크 vLLM 기반에서 구현한다
C06	대상 모델은 Transformer 기반 모델이다 . 상태 기반 어텐션 (state-based attention) 은 제외한다
C07	대상 워크로드는 agent 워크로드이며 RAG, LoRA, MoE 를 포함한다

요구사항 정제 – 기능 요구사항 [1/2]

정제 요구사항 : 기능 요구사항 26 건 , 품질 요구사항 11 건 , 제약사항 7 건 (합계 44 건)

번호	기능 요구사항	설명
FR-01	이기종 메모리 데이터 저장	HBM 외의 메모리 (Host DRAM, CXL 메모리 , HBF 등) 에 KV cache, LoRA adapter, expert 같은 데이터를 저장하고 읽는다
FR-02	메모리 간 데이터 복사	지정한 데이터를 한 메모리에서 다른 메모리로 복사하거나 이동한다
FR-03	vLLM 연동	vLLM 이 요청을 처리하는 흐름 안에서 동작하며 , KV cache 관리 시점에 데이터 배치와 이동 기능을 호출한다
FR-04	KV cache offload 와 재사용	당장 쓰지 않는 KV cache 를 HBM 밖으로 내려 보관하고 , 다시 필요하면 HBM으로 가져와 재사용한다
FR-05	LoRA adapter 서빙	요청이 지정한 LoRA adapter 를 적재해 응답을 생성하고 , 쓰지 않는 adapter 는 HBM에서 내린다
FR-06	RAG 서빙	검색된 문서가 붙은 요청을 처리하고 , 문서 KV 를 보관했다가 같은 문서의 요청에서 다시 사용한다
FR-07	MoE 모델 서빙	MoE 모델의 expert 를 여러 메모리에 나누어 두고 선택된 expert 로 요청을 처리한다
FR-08	Prefill/Decode disaggregation	요청의 Prefill 과 Decode 를 서로 다른 자원에서 나누어 실행하고 , Prefill 의 KV 를 Decode 쪽으로 전달한다
FR-09	연산 offload 와 GPU fallback	연산 가능 메모리 (PIM/PNM) 가 지원하는 연산은 그 메모리에서 , 지원하지 않는 연산은 GPU에서 수행한다
FR-10	서버 간 KV 전송	한 서버의 KV cache 를 다른 서버로 보내 상대 서버가 쓸 수 있게 한다
FR-11	Multi-turn 세션 서빙	같은 세션의 이전 대화 내용과 KV 를 유지해 후속 요청을 이어서 처리한다
FR-12	Prefix caching	앞부분이 같은 요청들이 이미 계산된 KV 를 공유한다
FR-13	Tool 호출 대기 세션 처리	agent 가 tool 호출로 생성을 멈춘 세션의 KV 를 보관하고 , tool 결과가 오면 이어서 생성한다

요구사항 정제 – 기능 요구사항 [2/2]

정제 요구사항 : 기능 요구사항 26 건 , 품질 요구사항 11 건 , 제약사항 7 건 (합계 44 건)

번호	기능 요구사항	설명
FR-14	HBM 초과 요청 서빙	KV 가 HBM 용량보다 큰 요청도 다른 메모리를 함께 사용해 끝까지 처리한다
FR-15	KV 압축	KV cache 를 압축된 형태로 보관하고 필요할 때 사용한다
FR-16	KV eviction	메모리가 부족하면 정해진 기준에 따라 KV 의 일부를 제거한다
FR-17	KV 재계산	제거되었거나 없는 KV 를 입력 토큰으로부터 다시 계산한다
FR-18	다중 서버 서빙	여러 서버가 하나의 서비스로 묶여 요청을 나누어 처리한다
FR-19	요청 라우팅	들어온 요청을 처리할 서버를 선택해 그 서버로 전달한다
FR-20	메모리 장치 스펙 입력	각 메모리의 대역폭 , 지연 , 용량 같은 스펙을 설정 값으로 받는다
FR-21	메모리 용량 · 사용 현황 조회	각 메모리의 용량과 사용 현황을 조회한다
FR-22	데이터 위치 조회	데이터가 어느 메모리 (서버) 에 있는지 조회한다
FR-23	접근 이력 기록	데이터별 접근 횟수와 최근 접근 시각을 기록한다
FR-24	데이터 prefetch	후속 요청이 오기 전에 데이터를 상위 메모리로 미리 가져온다
FR-25	정책 변경	이동 · 배치 정책을 설정으로 바꾼다
FR-26	메모리 배치와 연산의 동적 스케줄링	서빙 중의 상태 (요청 도착 , 메모리 사용 현황 , 접근 이력) 를 보고 데이터를 어느 메모리에 둘지 , 연산을 어느 장치에서 수행할지 , 이를 언제 어떤 순서로 실행할지를 정해 반영한다

요구사항 정제 – 제약사항

번호	제약 사항	설명
C-01	차세대 메모리 성능 시뮬레이션	차세대 메모리 (HBF, ScHBM 등) 는 인터페이스를 가정하고 스펙에 따라 성능을 시뮬레이션한다
C-02	device runtime 정상 동작	시뮬레이션하는 device runtime 은 정상 동작하며 신뢰성이 보장된다고 가정한다
C-03	device runtime 오버헤드	device runtime 의 오버헤드는 무시한다
C-04	시스템 확장 평가	실장 환경이 없는 규모 이상으로의 시스템 확장 (노드 증가) 은 시뮬레이션 기반으로 평가한다
C-05	추론 엔진	추론 엔진은 오픈소스 서빙 프레임워크 vLLM 기반에서 구현한다
C-06	대상 모델	대상 모델은 Transformer 기반 모델이다 . 상태 기반 어텐션 (state-based attention) 은 제외한다
C-07	대상 워크로드	대상 워크로드는 agent 워크로드이며 RAG, LoRA, MoE 를 포함한다

* 학습, 보안·테넌트 격리, 장애 복구, stale KV 무효화는 제약이 아니라 범위 밖이다 (다음 장 과제 범위 참조)

과제 범위

범위 안 (결정 = 스케줄링)

- 무엇을 · 어디에 · 언제 돌지 / 옮길지 정하는 결정 (placement / migration / prefetch)
- 연산 실행 위치 결정 (GPU vs 연산 가능 메모리 , P/D 분리)
- 요청 배분 결정 (KV 위치 인지 서버 선택 , 전송 vs 재계산)
- 대상 객체 : KV, LoRA adapter, MoE expert, RAG 문서 KV, agent 세션 KV
- 대상 워크로드 : agent (RAG, LoRA, MoE 포함)
- 정상 운영 상태의 서빙 성능

범위 밖 / 주어진 것

- 실행 메커니즘 : 전송 , commit, driver, kernel (입력으로 취급)
- device runtime 내부 기능과 신뢰성
- 학습 / 훈련 , 보안·테넌트 격리 , 장애 복구
- 문서 갱신 시 stale KV 무효화
- DP6 (CXL shared-memory KV consistency)
- 상태 기반 어텐션 모델

DP1

Migration 결정
(evict·promote·prefetch)

DP2

P/D 실행 위치 결정

DP3

KV eviction & reuse


DP4

요청 orchestration

* DP2(노드 안 실행 위치) 와 DP4(노드 간 배분) 의 경계는 별도 논의 중이다. 현재는 각 DP 문서 그대로 반영한다


요구사항 분석 - 기능 요구사항 분석

주요 기능의 Use Case Diagram



* UC-1~9 : doc-mk/Requirements/usecases.md (제안 상태)

Domain Model



요구사항 분석 – 수집 / 정제된 요구사항 전체 [1/4]

번호	요구사항 및 설명	정제 종류
RQ-SC-01	agent 의 tool 호출 대기 중 KV 가 HBM 을 점유하지 않는다	FR-13, FR-04, QA3 Resource utilization
RQ-SC-02	HBM 용량을 넘는 요청을 실패 없이 처리한다	FR-14, QA1 Throughput
RQ-SC-03	같은 RAG 문서 prefix 요청은 KV 위치와 무관하게 재사용한다	FR-06, FR-12, QA2 Latency
RQ-SC-04	HBM 용량을 넘는 수의 LoRA adapter 를 서빙한다	FR-05, QA1 Throughput
RQ-SC-05	MoE expert 를 접근 빈도에 맞게 서로 다른 메모리에 둔다	FR-07, QA2 Latency
RQ-SC-06	연산 가능 메모리에 연산을 맡기되 이득이 없으면 GPU 경로를 쓴다	FR-09, QA2 Latency
RQ-SC-07	KV 위치를 알고 서버를 고르며 전송과 재계산 중 빠른 쪽을 택한다	FR-10, FR-19, QA1, QA5
RQ-SC-08	요청마다 Prefill/Decode 분리 실행 여부를 정한다	FR-08, QA1, QA2
RQ-SC-09	혼합 부하에서 이동 트래픽이 서빙을 잠식하지 않는다	FR-02, QA7 Co-existence

요구사항 분석 – 수집 / 정제된 요구사항 전체 [2/4]

번호	요구사항 및 설명	정제 종류
RQ-DP1-01	이동 · 복원해도 모델 출력이 바뀌지 않는다 (bit-exact)	FR-02, QA6 Correctness
RQ-DP1-02	후속 요청 시점을 예측하거나 도착 즉시 KV 를 HBM 으로 복원한다	FR-04, FR-11, QA2 Latency
RQ-DP1-03	이동 대상 메모리가 부족하면 쓰일 가능성이 낮은 KV 부터 정리한다	FR-16, FR-17
RQ-DP1-04	새 메모리 tier, 객체 유형 , 정책을 쉽게 추가한다	FR-01, FR-20, QA4 Modifiability
RQ-DP2-01	(n_p, n_d) 비용 모델로 P/D 실행 위치를 정한다	FR-08, QA1, QA2
RQ-DP2-02	노드 수가 늘어도 결정 성능과 처리량이 확장된다	FR-18, QA5 Scalability
RQ-DP3-01	중요도 낮은 KV 를 선택적으로 제거하되 허용 정확도 한도 안에서 수행한다	FR-15, FR-16, QA6 Correctness (F1)
RQ-DP3-02	압축 KV 를 재사용하고 필요한 부분만 재계산한다	FR-15, FR-17, QA2 Latency
RQ-DP3-03	Drop 과 재사용으로 HBM KV 점유를 줄인다 (DP1 과 같은 정의)	QA3 Resource utilization

요구사항 분석 – 수집 / 정제된 요구사항 전체 [3/4]

번호	요구사항 및 설명	정제 종류
RQ-DP4-01	서버별 캐시 위치를 알고 라우팅한다	FR-19, QA1 Throughput
RQ-DP4-02	OSS(ilm-d) 확장과 자체 구현 중 목표 QA 를 만족하는 방식을 택한다	FR-19, QA4 Modifiability
RQ-DP4-03	서버 수가 늘어도 orchestrator 결정이 병목이 되지 않는다	FR-18, QA5 Scalability
RQ-DP1-05	데이터 접근 이력과 메모리 사용 현황을 기록하고 조회한다	FR-21, FR-22, FR-23
RQ-DP1-06	후속 요청이 오기 전에 데이터를 미리 가져온다	FR-24, QA2 Latency
RQ-DP1-07	입력 분포가 바뀌면 배치를 다시 맞춰 성능을 회복한다	QA11 Adaptability
RQ-DP2-03	KV 전송이나 offload 가 실패해도 재계산 등으로 요청을 이어간다	QA9 Fault tolerance
RQ-DP4-04	이동·배치·라우팅 결정의 근거를 기록해 원인을 진단한다	QA10 Analysability
RQ-DP4-05	vLLM, ilm-d, NIXL 등과 수정 없이 연동한다	FR-03, QA8 Interoperability

요구사항 분석 – 수집 / 정제된 요구사항 전체 [4/4]

번호	요구사항 및 설명	정제 종류
RQ-SYS-01	결정이 서빙 경로 (forward) 를 막지 않는다	QA2 Latency
RQ-SYS-02	차세대 메모리는 스펙 기반 시뮬레이션으로 평가한다	C-01, C-02, C-03
RQ-SYS-03	실장이 없는 규모의 확장은 시뮬레이션으로 평가한다	C-04
RQ-SYS-04	vLLM 기반으로 구현한다	C-05, FR-03
RQ-SYS-05	대상은 Transformer 모델과 agent 워크로드이다	C-06, C-07
RQ-SYS-06	정책을 설정으로 바꾼다	FR-25, QA4 Modifiability
RQ-SYS-07	메모리 배치와 연산 실행 위치 · 시점 · 순서를 서빙 중 동적으로 정한다	FR-26

품질 요구사항 [1/2]

DP1~DP4 문서의 QA 를 ISO/IEC 25010:2023 하위 특성 기준으로 모은 후보이다 . 같은 QA 는 DP 와 무관하게 같은 조건 (워크로드 , SLO, 환경 , Baseline) 에서 측정한다 .
정량 metric(목표값) 은 모두 공란이며 , 중요도 · 난이도 · 순위는 QAW(검수) 후 확정한다 .

품질 속성 유틸리티 트리 (후보)

	QA	Attribute Refinement	정의 (Scenario 요약)	관련 DP	중요도	난이도	
	QA1	Performance	Throughput	SLO 를 만족하는 최대 처리량 (Max SLO Goodput)	DP1·2·4 (DP3 보조)		
	QA2	Performance	Latency	TTFT / TPOT (별도 지표)	DP1~4		
	QA3	Performance	Resource utilization	HBM 점유율 (모든 DP 동일 조건)	DP1·3 목표 / DP2·4 측정		
	QA4	Modifiability	새 tier· 정책 · 객체 추가	새 tier· 정책 · 객체 추가 시 토큰 비용 · 공수 · 변경 모듈 수	DP1·2·4		
	QA5	Scalability	노드 · 메모리 type 증가	노드 · 메모리 type 증가 시 성능 유지	DP2·4		
	QA6	Correctness	출력 정확성	출력 bit-exact / DP3 는 F1 한도	DP1~4		

품질 요구사항 [2/2]

DP1~DP4 문서의 QA 를 ISO/IEC 25010:2023 하위 특성 기준으로 모은 후보이다 . 같은 QA 는 DP 와 무관하게 같은 조건 (워크로드 , SLO, 환경 , Baseline) 에서 측정한다 .
정량 metric(목표값) 은 모두 공란이며 , 중요도 · 난이도 · 순위는 QAW(점수) 후 확정한다 .

품질 속성 유틸리티 트리 (후보)

		QA	Attribute Refinement	정의 (Scenario 요약)	관련 DP	중요도	난이도
	QA7	Co-existence	이동 트래픽 공존	이동 트래픽과 서버의 동시 동작	DP1·4		
	QA8	Interoperability	외부 구성요소 연동	vLLM, llm-d, NIXL 무수정 연동	DP4		
	QA9	Fault tolerance	전송 ·offload 실패 대체	실패 시 재계산 등으로 처리 지속	DP2·4		
	QA10	Analysability	결정 근거 진단	결정 근거 기록과 원인 진단	DP4· 전체		
	QA11	Adaptability	워크로드 변화 적응	입력 분포 변화 후 배치 재조정	DP1		

요구사항 분석 – 품질 속성 유틸리티 트리 [1/2]

번호	QA	Refinement	Scenario	중요도	난이도	우선순위	선정
QA-01	Performance Throughput	요청 처리량	다수의 agent 세션이 동시에 요청하는 상황에서, 지정한 SLO(TTFT, TPOT) 를 만족하며 처리할 수 있는 최대 요청량이 기준 시스템 (Baseline) 보다 커야 한다. [측정 : SLO 만족 Max Goodput ≥ Baseline 대비 []]	H	M		
QA-02	Performance Latency	응답 지연	정해진 부하에서 요청의 첫 토큰 응답 시간 (TTFT) 과 토큰 간 생성 시간 (TPOT) 이 Baseline 보다 크게 늘지 않아야 한다. [측정 : TTFT, TPOT(P50, P99) < Baseline 대비 []]	H	H		
QA-03	Performance Resource utilization	HBM 점유율	동일한 부하와 SLO 조건에서 KV·adapter·expert 가 차지하는 HBM 점유율이 Baseline 보다 낮아야 한다. [측정 : HBM 점유율 (평균 , 피크) < Baseline 대비 []]	H	M		
QA-04	Modifiability	변경 용이성	새로운 메모리 tier, 이동·배치 정책, 데이터 객체 유형을 추가할 때 서빙 경로를 수정하지 않고 반영할 수 있어야 한다. [측정 : 기준 작업 3 종의 가중 변경 비용 (토큰 비용 50%, 공수 30%, 변경 모듈 수 20%) < Baseline 대비 []]	H	M		
QA-05	Scalability	노드·메모리 type 확장	실장 환경을 넘는 규모로 노드 또는 메모리 type 이 늘어나도 결정이 병목이 되지 않고 성능이 늘어난 자원에 비례해 증가해야 한다 (시뮬레이션 평가). [측정 : Scaling Efficiency > []]	M	H		
QA-06	Correctness	출력 정확성	데이터 이동·복원·재사용을 거친 요청의 출력이 거치지 않은 경우와 같아야 한다. 손실형 KV 압축·제거는 허용 정확도 한도 안이어야 한다. [측정 : 출력 불일치 < 1 건 / F1 하락 상대 < 1%]	H	H		

요구사항 분석 – 품질 속성 유틸리티 트리 [2/2]

번호	QA	Refinement	Scenario	중요도	난이도	우선순위	선정
QA-07	Co-existence	이동 트래픽 공존	데이터 이동·복원 트래픽과 서빙 요청이 같은 자원을 동시에 쓰는 상황에서도 서빙 성능이 유지되어야 한다. [측정 : 서빙 TTFT-TPOT 증가율 < 10%]	M	M		
QA-08	Interoperability	외부 구성요소 연동	vLLM, llm-d, NIXL 같은 외부 구성요소와 연동할 때 해당 구성요소의 소스를 수정하지 않아야 한다. [측정 : 무수정 연동 인터페이스 수 ≥ 3 개]	M	L		
QA-09	Fault tolerance	전송·offload 실패 대체	KV 전송이나 offload 가 실패하거나 시간 초과해도 재계산 등 대체 경로로 요청 처리를 이어가야 한다. [측정 : fallback 성공률 ≥ 99.9%]	M	M		
QA-10	Analysability	결정 근거 진단	이동·배치·라우팅 결정이 기대와 다를 때 결정 입력과 근거 기록으로 원인을 찾을 수 있어야 한다. [측정 : 원인 파악 시간 < 1 시간 (개발자 1인, 결정 1건 기준)]	L	M		
QA-11	Adaptability	워크로드 변화 적응	입력 분포나 접근 패턴이 바뀌어도 접근 통계를 반영해 배치를 다시 맞추고 성능을 회복해야 한다. [측정 : 성능 회복 시간 < 5 분 (변화 전 성능의 90% 기준)]	M	M		

* [] = 공란. QA-01~05 의 측정값은 통합 단계에서 정한다. QA-06~11 의 측정값은 Claude 제안값이며 확정 전이다

* 중요도·난이도는 Claude 제안값이고 우선순위·선정은 확정 후 기입한다 (H/M/L)

QA 검수 : DP 별 적용 현황과 의견

QA	DP1	DP2	DP3	DP4	의견
QA1 Throughput	●	●	○	●	Max SLO Goodput 으로 정의한다 (ISO 매핑 없이 그대로 사용)
QA2 Latency	●	●	●	●	TTFT 와 TPOT 를 별도 지표로 두고 , 부하를 고정해 분포를 잰다
QA3 Resource util.	●	○	●	○	HBM 점유율로 통일한다 . DP2·4 는 같은 조건에서의 측정이다
QA4 Modifiability	●	●	-	●	DP3 에 없다 . 집계 방식 (모듈 수 , man-month) 통일이 필요하다
QA5 Scalability	-	●	-	●	노드 ·메모리 type 증가를 시뮬레이션으로 평가한다 (C-04)
QA6 Correctness	○	○	●	○	DP3 만 능동 QA(F1) 이다 . 나머지는 bit-exact 확인이다
QA7 Co-existence	●	-	-	●	이동 트래픽과 서빙의 간섭을 QA2 조건에서 함께 잰다
QA8 Interoperability	-	-	-	●	DP4(OSS 확장 대 자체 구현) 에서 의미가 크다
QA9 Fault tolerance	-	●	-	●	전송 실패 대체만 다룬다 . 장치 장애 복구는 범위 밖이다
QA10 Analysability	○	○	○	●	DP4 는 결정 근거 기록이 FR 로 있다 . 공통화 여부 검토
QA11 Adaptability	●	-	-	-	DP1 의 hot 객체 변화 대응 (expert, adapter) 만 해당한다

● DP 문서에서 선정 (목표) ○ 측정 · 확인 대상 - 해당 없음

검수 요청 사항

- QA 11 개가 과제 QA 로 충분하고 과하지 않은가
- QA7~11 은 후보이므로 유지할 항목을 고른다
- 중요도 · 난이도 · 순위 확정 (QAW)

ISO 25010:2023 내 미채택 후보

- Functional completeness, Functional appropriateness
- Operability, Availability
- Modularity, Reusability, Testability, Replaceability

아키텍처 드라이버 선정 (초안)

| Functional Requirements

FR26	메모리 배치와 연산의 동적 스케줄링	FR01	이기종 메모리 데이터 저장
FR02	메모리 간 데이터 복사	FR03	vLLM 연동
FR04	KV cache offload 와 재사용	FR05	LoRA adapter 서빙
FR06	RAG 서빙	FR07	MoE 모델 서빙
FR08	Prefill/Decode disaggregation	FR09	연산 offload 와 GPU fallback
FR10	서버 간 KV 전송		

이기종 메모리
LLM 서빙
스케줄링 런타임

| Constraints

C01	차세대 메모리 시뮬레이션
C02	device runtime 정상 동작
C03	runtime 오버헤드 무시
C04	시스템 확장은 시뮬레이션
C05	vLLM 기반 구현
C06	Transformer 모델
C07	agent 워크로드

* 초안이다. 중요도·난이도 기입 후 드라이버를 최종 선정한다.
* 나머지 FR 은 핵심 FR 의 세부 기능이며 드라이버로 올리지 않았다.

| Quality Attributes

QA1	Throughput	QA2	Latency	QA3	HBM 점유율
QA4	Modifiability	QA5	Scalability	QA6	Correctness
QA7	Co-existence	QA8	Interoperability	QA9	Fault tolerance
QA10	Analysability	QA11	Adaptability		