



요구사항

이기종 메모리 LLM 서빙 스케줄링 런타임 (검수용 초안)

요구사항 분석 절차

DP1~DP4 설계·평가 문서와 시나리오에서 FR / QA / C 를 추출하고 , 품질 시나리오의 정량 값은 통합 단계에서 한 번에 정한다



* FR : Functional Requirement * QA : Quality Attribute * C : Constraint
* DP5 는 없고 DP6(CXL shared-memory KV consistency) 은 이번 범위에서 제외한다. 각 DP 의 기존 평가 결과와 임계값은 보류한다.

주요 기능 요구사항 및 제약사항

기능 요구사항 (핵심 10 건 , 추가 10 건은 다음 장)

FR01	이기종 메모리 (HBM, Host DRAM, CXL 메모리 , HBF 등) 를 지원한다
FR02	이기종 메모리 간 데이터 복사 (이동) 를 지원한다
FR03	vLLM 추론 엔진 연동을 지원한다
FR04	KV cache 의 offload 와 재사용을 지원한다
FR05	LoRA adapter 서빙을 지원한다
FR06	RAG 서빙을 지원한다
FR07	MoE 모델 서빙을 지원한다
FR08	Prefill/Decode disaggregation 을 지원한다
FR09	연산 offload 와 GPU fallback 을 지원한다
FR10	서버 간 KV 전송을 지원한다

제약사항

C01	차세대 메모리 (HBF, ScHBM 등) 는 인터페이스를 가정하고 스펙에 따라 성능을 시뮬레이션한다
C02	시뮬레이션하는 device runtime 은 정상 동작하며 신뢰성이 보장된다고 가정한다
C03	device runtime 의 오버헤드는 무시한다
C04	실장 환경이 없는 규모 이상으로의 시스템 확장 (노드 증가) 은 시뮬레이션 기반으로 평가한다
C05	추론 엔진은 오픈소스 서빙 프레임워크 vLLM 기반에서 구현한다
C06	대상 모델은 Transformer 기반 모델이다 . 상태 기반 어텐션 (state-based attention) 은 제외한다
C07	대상 워크로드는 agent 워크로드이며 RAG, LoRA, MoE 를 포함한다

요구사항 정제 – 기능 요구사항

정제 요구사항 : 기능 요구사항 20 건 , 품질 요구사항 6 건 , 제약사항 7 건

번호	기능 요구사항
FR-01	이기종 메모리 (HBM, Host DRAM, CXL 메모리 , HBF 등) 를 지원한다
FR-02	이기종 메모리 간 데이터 복사 (이동) 를 지원한다
FR-03	vLLM 추론 엔진 연동을 지원한다
FR-04	KV cache 의 offload 와 재사용을 지원한다
FR-05	LoRA adapter 서빙을 지원한다
FR-06	RAG 서빙을 지원한다
FR-07	MoE 모델 서빙을 지원한다
FR-08	Prefill/Decode disaggregation 을 지원한다
FR-09	연산 offload 와 GPU fallback 을 지원한다
FR-10	서버 간 KV 전송을 지원한다

번호	기능 요구사항
FR-11	Multi-turn 세션 서빙을 지원한다
FR-12	Prefix caching 을 지원한다
FR-13	Tool 호출 대기 중인 agent 세션의 처리를 지원한다
FR-14	HBM 용량을 넘는 요청의 서빙을 지원한다
FR-15	KV 압축을 지원한다
FR-16	KV eviction 을 지원한다
FR-17	KV 재계산을 지원한다
FR-18	다중 서버 서빙을 지원한다
FR-19	요청 라우팅 (서버 선택) 을 지원한다
FR-20	메모리 장치 스펙 (대역폭 , 지연 , 용량) 입력을 지원한다

* FR-01~10 은 핵심 기능, FR-11~20 은 추가 기능이다. 성능· 정확도· 정책 판단 내용은 FR 이 아니라 QA 또는 DP 설계에서 다룬다

요구사항 정제 – 제약사항

번호	제약 사항	설명
C-01	차세대 메모리 성능 시뮬레이션	차세대 메모리 (HBF, ScHBM 등) 는 인터페이스를 가정하고 스펙에 따라 성능을 시뮬레이션한다
C-02	device runtime 정상 동작	시뮬레이션하는 device runtime 은 정상 동작하며 신뢰성이 보장된다고 가정한다
C-03	device runtime 오버헤드	device runtime 의 오버헤드는 무시한다
C-04	시스템 확장 평가	실장 환경이 없는 규모 이상으로의 시스템 확장 (노드 증가) 은 시뮬레이션 기반으로 평가한다
C-05	추론 엔진	추론 엔진은 오픈소스 서빙 프레임워크 vLLM 기반에서 구현한다
C-06	대상 모델	대상 모델은 Transformer 기반 모델이다 . 상태 기반 어텐션 (state-based attention) 은 제외한다
C-07	대상 워크로드	대상 워크로드는 agent 워크로드이며 RAG, LoRA, MoE 를 포함한다

* 학습, 보안·테넌트 격리, 장애 복구, stale KV 무효화는 제약이 아니라 범위 밖이다 (다음 장 과제 범위 참조)

과제 범위

범위 안 (결정 = 스케줄링)

- 무엇을 · 어디에 · 언제 둘지 / 옮길지 정하는 결정 (placement / migration / prefetch)
- 연산 실행 위치 결정 (GPU vs 연산 가능 메모리 , P/D 분리)
- 요청 배분 결정 (KV 위치 인지 서버 선택 , 전송 vs 재계산)
- 대상 객체 : KV, LoRA adapter, MoE expert, RAG 문서 KV, agent 세션 KV
- 대상 워크로드 : agent (RAG, LoRA, MoE 포함)
- 정상 운영 상태의 서빙 성능

범위 밖 / 주어진 것

- 실행 메커니즘 : 전송 , commit, driver, kernel (입력으로 취급)
- device runtime 내부 기능과 신뢰성
- 학습 / 훈련 , 보안·테넌트 격리 , 장애 복구
- 문서 갱신 시 stale KV 무효화
- DP6 (CXL shared-memory KV consistency)
- 상태 기반 어텐션 모델

DP1

Migration 결정
(evict·promote·prefetch)

DP2

P/D 실행 위치 결정

DP3

KV eviction & reuse


DP4

요청 orchestration

* DP2(노드 안 실행 위치) 와 DP4(노드 간 배분) 의 경계는 별도 논의 중이다. 현재는 각 DP 문서 그대로 반영한다


요구사항 분석 - 기능 요구사항 분석

주요 기능의 Use Case Diagram



* UC-1~9 : doc-mk/Requirements/usecases.md (제안 상태)

Domain Model



요구사항 분석 – 수집 / 정제된 요구사항 전체 [1/3]

번호	요구사항 및 설명	정제 종류
RQ-SC-01	agent 의 tool 호출 대기 중 KV 가 HBM 을 점유하지 않는다	FR-13, FR-04, QA3 Resource utilization
RQ-SC-02	HBM 용량을 넘는 요청을 실패 없이 처리한다	FR-14, QA1 Throughput
RQ-SC-03	같은 RAG 문서 prefix 요청은 KV 위치와 무관하게 재사용한다	FR-06, FR-12, QA2 Latency
RQ-SC-04	HBM 용량을 넘는 수의 LoRA adapter 를 서빙한다	FR-05, QA1 Throughput
RQ-SC-05	MoE expert 를 접근 빈도에 맞게 서로 다른 메모리에 둔다	FR-07, QA2 Latency
RQ-SC-06	연산 가능 메모리에 연산을 맡기되 이득이 없으면 GPU 경로를 쓴다	FR-09, QA2 Latency
RQ-SC-07	KV 위치를 알고 서버를 고르며 전송과 재계산 중 빠른 쪽을 택한다	FR-10, FR-19, QA1, QA5
RQ-SC-08	요청마다 Prefill/Decode 분리 실행 여부를 정한다	FR-08, QA1, QA2
RQ-SC-09	혼합 부하에서 이동 트래픽이 서빙을 잠식하지 않는다	FR-02, QA2 Latency

요구사항 분석 – 수집 / 정제된 요구사항 전체 [2/3]

번호	요구사항 및 설명	정제 종류
RQ-DP1-01	이동 · 복원해도 모델 출력이 바뀌지 않는다 (bit-exact)	FR-02, QA6 Correctness
RQ-DP1-02	후속 요청 시점을 예측하거나 도착 즉시 KV 를 HBM 으로 복원한다	FR-04, FR-11, QA2 Latency
RQ-DP1-03	이동 대상 메모리가 부족하면 쓰일 가능성이 낮은 KV 부터 정리한다	FR-16, FR-17
RQ-DP1-04	새 메모리 tier, 객체 유형 , 정책을 쉽게 추가한다	FR-01, FR-20, QA4 Modifiability
RQ-DP2-01	(n_p, n_d) 비용 모델로 P/D 실행 위치를 정한다	FR-08, QA1, QA2
RQ-DP2-02	노드 수가 늘어도 결정 성능과 처리량이 확장된다	FR-18, QA5 Scalability
RQ-DP3-01	중요도 낮은 KV 를 선택적으로 제거하되 허용 정확도 한도 안에서 수행한다	FR-15, FR-16, QA6 Correctness (F1)
RQ-DP3-02	압축 KV 를 재사용하고 필요한 부분만 재계산한다	FR-15, FR-17, QA2 Latency
RQ-DP3-03	Drop 과 재사용으로 HBM KV 점유를 줄인다 (DP1 과 같은 정의)	QA3 Resource utilization

요구사항 분석 – 수집 / 정제된 요구사항 전체 [3/3]

번호	요구사항 및 설명	정제 종류
RQ-DP4-01	서버별 캐시 위치를 알고 라우팅한다	FR-19, QA1 Throughput
RQ-DP4-02	OSS(IIIm-d) 확장과 자체 구현 중 목표 QA 를 만족하는 방식을 택한다	FR-19, QA4 Modifiability
RQ-DP4-03	서버 수가 늘어도 orchestrator 결정이 병목이 되지 않는다	FR-18, QA5 Scalability
RQ-SYS-01	결정이 서빙 경로 (forward) 를 막지 않는다	QA2 Latency
RQ-SYS-02	차세대 메모리는 스펙 기반 시뮬레이션으로 평가한다	C-01, C-02, C-03
RQ-SYS-03	실장이 없는 규모의 확장은 시뮬레이션으로 평가한다	C-04
RQ-SYS-04	vLLM 기반으로 구현한다	C-05, FR-03
RQ-SYS-05	대상은 Transformer 모델과 agent 워크로드이다	C-06, C-07

품질 요구사항

DP1~DP4 문서의 QA 를 ISO/IEC 25010:2023 하위 특성 기준으로 모은 후보이다 . 같은 QA 는 DP 와 무관하게 같은 조건 (워크로드 , SLO, 환경 , Baseline) 에서 측정한다 .
정량 metric(목표값) 은 모두 공란이며 , 중요도 · 난이도 · 순위는 QAW(검수) 후 확정한다 .

품질 속성 유틸리티 트리 (후보)

		QA	Attribute Refinement	정의 (Scenario 요약)	관련 DP	중요도	난이도
	QA1	Performance	Throughput	SLO 를 만족하는 최대 처리량 (Max SLO Goodput)	DP1·2·4 (DP3 보조)		
	QA2	Performance	Latency	TTFT / TPOT (별도 지표)	DP1~4		
	QA3	Performance	Resource utilization	HBM 점유율 (모든 DP 동일 조건)	DP1·3 목표 / DP2·4 측정		
	QA4	Modifiability	새 tier· 정책 · 객체 추가	새 tier· 정책 · 객체 추가 용이성	DP1·2·4		
	QA5	Scalability	노드 · 메모리 type 증가	노드 · 메모리 type 증가 시 성능 유지	DP2·4		
	QA6	Correctness	출력 정확성	출력 bit-exact / DP3 는 F1 한도	DP1~4		

요구사항 분석 – 품질 속성 유틸리티 트리 [1/2]

Quality Attribute	Attribute Refinement	Scenario	중요도	난이도	순위
Performance Throughput	Max SLO Goodput (Agent 대기 KV)	[DP1-3] 출처는 agent 클라이언트이고 요청이 지속 도착한다. 환경은 tool 대기 중인 idle KV 가 HBM 을 점유한 정상 운영이다. 대상은 이동 결정 스케줄러이고, 응답은 idle KV 를 HBM 밖으로 옮겨 다른 요청을 더 처리하는 것이다. 측정은 SLO 를 만족하는 Max Goodput 이 Baseline 대비 [] 이상이다	H	M	4
Performance Throughput	Max SLO Goodput (P/D 실행 위치)	[DP2] Prefill burst 와 긴 history 가 섞여 도착한다. 대상은 실행 위치 결정 모듈이고, 응답은 요청별 P/D 분리 여부와 (n_p, n_d) 를 정하는 것이다. 측정은 SLO 를 만족하는 Max Goodput 이 Baseline 대비 [] 이상이다	M	H	
Performance Throughput	Max SLO Goodput (요청 배분)	[DP4] KV 캐시가 서버별로 분산된 다중 서버에서 같은 prefix 요청이 도착한다. 대상은 orchestrator 이고, 응답은 KV 위치를 보고 서버를 고르는 것이다. 측정은 SLO 를 만족하는 Max Goodput 이 Baseline 대비 [] 이상이다	M	M	
Performance Latency	TTFT (재개 / 재사용)	[DP1-3-4] 환경은 KV 가 HBM 밖 tier 에 있고 부하가 고정된 상태이다. 같은 세션의 후속 요청 또는 같은 문서 prefix 요청이 도착하고, 응답은 KV 를 찾아 복원하고 재계산을 최소화하는 것이다. 측정은 TTFT(P50, P99) 가 Baseline 대비 [] 이내이다	H	M	5
Performance Latency	TPOT (다계층 attention)	[DP1-2-3] 환경은 KV 일부가 느린 tier 에 있고 부하가 고정된 상태에서 decode 가 진행된다. 응답은 접근 빈도가 높은 KV 를 빠른 tier 에 두는 것이다. 측정은 TPOT(P50, P99) 가 Baseline 대비 [] 이내이다	H	H	1
Performance Resource utilization	HBM 점유율	[전체 DP, 동일 조건] 동일 workload·SLO·Baseline 에서 동일 부하가 유입된다. 응답은 KV·adapter·expert 를 HBM 밖에 두는 것이다. 측정은 HBM 점유율 (평균, 피크) 이 Baseline 대비 [] 이하이다 (DP1-3 목표, DP2-4 측정)	H	M	3

요구사항 분석 – 품질 속성 유틸리티 트리 [2/2]

Quality Attribute	Attribute Refinement	Scenario	중요도	난이도	순위
Modifiability	새 tier 추가	[시스템 개발자] 개발 시점에 새 메모리 tier(HBF, CXL 등) 추가를 요청한다. 대상은 정책·배치 모듈이고, 응답은 인터페이스에 맞춰 tier를 추가하는 것이다. 측정은 변경 모듈이 [] 개, 공수가 [] man-month 이내이다	H	M	
Modifiability	새 정책·객체 추가	[시스템 개발자] 개발 시점에 새 이동·라우팅 정책 또는 객체 유형을 추가한다. 응답은 서빙 경로 수정 없이 반영하는 것이다. 측정은 변경 모듈이 [] 개, 공수가 [] 이내이다	M	L	
Scalability	노드 수 증가	[DP2·4] 환경은 실장이 없는 규모를 포함한 시뮬레이션이다 (C-04). 노드 수를 N에서 2N, 4N으로 늘린다. 응답은 결정이 병목이 되지 않고 처리량이 늘어나는 것이다. 측정은 Scaling Efficiency가 [] 이상이다	M	H	
Scalability	메모리 type 증가 (제안)	환경은 스펙 기반 시뮬레이션이다 (C-01, C-04). 새 type의 메모리를 tier로 추가한다. 응답은 추가 용량을 활용하며 결정 품질을 유지하는 것이다. 측정은 Capacity scaling efficiency가 [] 이상, 결정 지연 증가율이 [] 이내, optimality gap이 [] 이내이다	M	M	
Correctness	출력 bit-exact	[DP1·2·4] 같은 precision에서 이동·복원·offload·재사용을 거친 요청이다. 응답은 거치지 않은 경우와 같은 출력을 내는 것이다. 측정은 출력 불일치가 [] 건 이내이다	H	L	
Correctness	Drop 후 정확도 (DP3)	[DP3] 중요도 기반 Drop·압축 재사용을 적용한다. 환경은 지정 task와 dataset(미정)이다. 응답은 정확도 한도 안에서 Drop하는 것이다. 측정은 압축 전 + full recompute 대비 F1 하락이 상대 [] 이내이다	H	H	2

* [] = 공란. 중요도·난이도·순위는 Claude 제안이며 소유자 확정 전이다 (H/M/L, 순위는 H/H·H/M 중심)

QA 검수 : DP 별 적용 현황과 의견

QA	DP1	DP2	DP3	DP4	의견
QA1 Throughput	●	●	○	●	Max SLO Goodput 으로 정의한다 (ISO 매핑 없이 그대로 사용)
QA2 Latency	●	●	●	●	TTFT 와 TPOT 를 합치지 않고 별도 지표로 둔다 . 부하를 고정하고 분포를 잰다
QA3 Resource util.	●	○	●	○	HBM 점유율로 통일한다 . DP2·4 는 목표가 아니라 같은 조건에서의 측정이다
QA4 Modifiability	●	●	-	●	DP3 에 없다 . 집계 방식 (모듈 수 , man-month, agent 비용) 통일이 필요하다
QA5 Scalability	-	●	-	●	DP2·4 에만 있다 . 노드 ·메모리 type 증가를 시뮬레이션으로 평가한다 (C-04)
QA6 Correctness	○	○	●	○	DP3 만 능동 QA(F1) 이다 . 나머지는 bit-exact 확인이다

● DP 문서에서 선정 (목표) ○ 측정· 확인 대상 - 해당 없음

검수 요청 사항

- QA 6 개가 과제 QA 로 충분한가
- Scalability 를 공통 QA 로 둘지 DP 전용으로 둘지
- 중요도 · 난이도 · 순위 확정 (QAW)

ISO 25010:2023 내 추가 후보 (미채택)

- Compatibility : Co-existence, Interoperability
- Reliability : Fault tolerance, Availability
- Maintainability : Analysability, Testability
- Flexibility : Adaptability, Replaceability
- Functional suitability : Completeness, Appropriateness

아키텍처 드라이버 선정 (초안)

| Functional Requirements

FR01	이기종 메모리	FR02	데이터 복사
FR03	vLLM 연동	FR04	KV offload·재사용
FR05	LoRA 서빙	FR06	RAG 서빙
FR07	MoE 서빙	FR08	P/D disaggregation
FR09	연산 offload·GPU fallback	FR10	서버 간 KV 전송

이기종 메모리
LLM 서빙
스케줄링 런타임

| Constraints

C01	차세대 메모리 시뮬레이션
C02	device runtime 정상 동작
C03	runtime 오버헤드 무시
C04	시스템 확장은 시뮬레이션
C05	vLLM 기반 구현
C06	Transformer 모델
C07	agent 워크로드

* 초안이다. 중요도·난이도 기입 후 드라이버를 최종 선정한다.
* FR-11~20 은 핵심 FR 의 세부 기능이며 드라이버로 올리지 않았다.

| Quality Attributes

QA1	Throughput	QA2	Latency	QA3	HBM 점유율
QA4	Modifiability	QA5	Scalability	QA6	Correctness