



요구사항

(검수용

찾아)

DP1~DP4 설계·평가 문서와 시나리오에서 FR / QA / C 를 추출하고 , 품질 시나리오의 정량 값은 통합 단계에서 한 번에 정한다



* FR : Functional Requirement * QA : Quality Attribute * C : Constraint * QS : Quality Scenario
* DP5 는 없음 , DP6(CXL shared-memory KV consistency) 은 이번 범위에서 제외. 각 DP 의 기존 평가 결과·임계값은 보류하고 통합 단계에서 다시 정한다.

기능 요구사항

FR1	유휴 KV 의 계층 간 이동 · 복원 (evict / promote / prefetch)	DP1 · FR-1~4, 6
FR2	HBM 용량을 넘는 context 처리	DP1.3 · FR-7, 8
FR3	KV 선택적 Drop · 재사용 · 재계산	DP3 · FR-5, 9, 10
FR4	비 -KV 객체 배치 (LoRA · MoE expert · RAG 문서)	DP1 · FR-11, 13~17
FR5	연산 실행 위치 결정	DP2 · FR-18~20, 24, 25
FR6	요청 배분 (서버 선택)	DP4 · FR-21~23
FR7	자원 경합 제어	DP1.4 · FR-26, 27
FR8	스케줄링 결정의 비차단성 · 관측성	공통 · FR-G1, 28

제약사항

C1	차세대 메모리 (HBF, ScHBM, PIM, CXL-PNM) 성능은 시뮬레이션 기반 예상값 (실측 아님) (GC-1)	C5	모델 출력 bit-exact 유지 (단 , DP3 Drop 은 허용 정확도 한도 내 손실 허용) (GC-7)
C2	device runtime 오버헤드 미고려 , 커널 / 컴파일러 등 device runtime 계층은 범위 밖 (GC-2, 5)	C6	서버 간 연결은 PCIe 64GB/s (실장 서버 2 대), 차세대 메모리 서버도 PCIe 기반 가정 (GC-9)
C3	device runtime 의 reliability-availability 는 보장 , 메모리 제품 단위 테스트는 완료되었다고 가정 (GC-3, 4)	C7	과제 초점은 스케줄링 (결정) . 전송 · commit-driver 등 실행 메커니즘은 주어진 것으로 사용 (GC-11)
C4	학습 / 훈련 , 보안 · 테넌트 격리 , 장애 복구 , 문서 갱신 시 stale KV 무효화는 범위 밖 (GC-6, 10)	C8	vLLM 엔진 위에 구현 .ref_cnt>0 블록은 step 중 이동 불가 (이동은 step 경계에서만) (DP1 설계)

ID	기능 요구사항	설명	관련 DP	상세 FR (usecases.md)
FR1	유휴 KV 의 계층 간 이동 · 복원 (evict / promote / prefetch)	tool 대기 등 당장 안 쓰는 KV 를 HBM 밖으로 옮기고, 재방문 시 복원 · 재사용한다. 이동 여부와 무관하게 출력은 bit-exact	DP1	FR-1~4, 6
FR2	HBM 용량을 넘는 context 처리	HBM 초과 KV 를 다계층 메모리를 함께 써서 실패 없이 처리하고, 접근 빈도 기반으로 배치한다	DP1-3	FR-7, 8
FR3	KV 선택적 Drop · 재사용 · 재계산	중요도 낮은 KV 제거, 압축 KV 재사용, 선택적 재계산을 허용 정확도 한도 안에서 수행한다	DP3	FR-5, 9, 10
FR4	비-KV 객체 배치 (LoRA · MoE expert · RAG 문서)	HBM 용량을 넘는 adapter·expert·문서 KV 를 접근 빈도로 hot/cold 배치하고 분포 변화 시 재조정한다	DP1	FR-11, 13~17
FR5	연산 실행 위치 결정	GPU vs 연산 가능 메모리, Prefill/Decode 분리 여부를 정하고, 미지원 연산은 GPU 경로로 대체한다	DP2	FR-18~20, 24, 25
FR6	요청 배분 (서버 선택)	KV 위치를 알고 서버를 선택하며, 전송 vs 재계산 비용을 비교하고 전송 실패 시 재계산으로 대체한다	DP4	FR-21~23
FR7	자원 경합 제어	이동 · 복원 · offload 가 서빙 트래픽을 잠식하는 정도를 제한하고, 과부하 시 대기 · 우선순위 · 거절을 적용한다	DP1-4	FR-26, 27
FR8	스케줄링 결정의 비차단성 · 관측성	결정은 서빙 경로 (forward) 를 막지 않고, 요청 유형별 지연 · 처리량 지표를 제공한다	공통	FR-G1, 28

* 상세 FR-n 번호는 doc-mk/Requirements/usecases.md 기준. FR-12 는 삭제됨. 각 FR 의 우선순위 (Must/Should/Could) 는 usecases.md 참조

범위 안 (결정 = 스케줄링)

- 무엇을 · 어디에 · 언제 둘지 / 옮길지 정하는 결정 (placement / migration / prefetch)
- 연산 실행 위치 결정 (GPU vs 연산 가능 메모리 , P/D 분리)
- 요청 배분 결정 (KV 위치 인지 서버 선택 , 전송 vs 재계산)
- 대상 객체 : KV, LoRA adapter, MoE expert, RAG 문서 KV, Agent 세션 KV
- 대상 워크로드 : agent multi-turn, RAG, long-context, LoRA multi-tenant, MoE
- 정상 운영 상태의 서빙 성능 , 단일 · 다중 노드 (PCIe 64GB/s)

범위 밖 / 주어진 것

- 실행 메커니즘 : 전송 , commit, driver, kernel, device runtime (입력으로 취급)
- device runtime 오버헤드 , 내부 reliability·availability
- 학습 / 훈련 , 보안 · 테넌트 격리 , 장애 복구
- 문서 갱신 시 stale KV 무효화
- DP6 (CXL shared-memory KV consistency) — 이번 정리 대상 아님
- 차세대 메모리 실측 — 시뮬레이션 예상 성능만 사용

DP1

Migration 결정
(evict·promote·prefetch)

DP2

P/D 실행 위치 결정

DP3


KV eviction & reuse

DP4

요청 orchestration


* DP2(노드 안 실행 위치) 와 DP4(노드 간 배분) 의 경계는 별도 논의 중 (memo-dp2-dp4-boundary.md). 현재는 각 DP 문서 그대로 반영

주요 기능의 Use Case Diagram



* UC-1~9 : doc-mk/Requirements/usecases.md (제안 상태). Actor 는 runtime client 와 시스템 개발자 (사용자 확정 관점 : 시스템 개발자 시점)

Domain Model



번호	요구사항 및 설명	정제 종류
RQ-SC-01	agent 요청이 많을 때 tool 호출 중 당장 쓰지 않는 KV 가 HBM 을 차지하지 않도록 해야 한다	FR1 유틸 KV 이동 · 복원 , QA3 Resource utilization
RQ-SC-02	HBM 용량을 넘는 Long-context 요청을 실패 없이 처리해야 한다	FR2 HBM 초과 context, QA1 Throughput
RQ-SC-03	같은 RAG 문서 prefix 를 가진 요청은 KV 가 어느 tier 에 있든 재사용해야 한다	FR2/FR4, QA2 Latency
RQ-SC-04	HBM 용량을 넘는 수의 LoRA adapter 를 서빙해야 한다	FR4 비 -KV 객체 배치 , QA1 Throughput
RQ-SC-05	MoE expert 를 접근 빈도에 맞게 서로 다른 메모리에 배치할 수 있어야 한다	FR4, QA2 Latency (TPOT)
RQ-SC-06	연산 가능 메모리 (PIM/PNM) 에 연산을 맡기되 이득이 없으면 GPU 경로를 써야 한다	FR5 연산 위치 결정 , QA2 Latency
RQ-SC-07	KV 위치를 알고 서버를 고르며 , 전송과 재계산 중 빠른 쪽을 택해야 한다	FR6 요청 배분 , QA1/QA5
RQ-SC-08	요청마다 Prefill/Decode 분리 실행 여부를 정해야 한다	FR5, QA1/QA2
RQ-SC-09	혼합 부하에서 이동 트래픽이 서빙을 잠식하지 않아야 한다	FR7 자원 경합 제어 , QA2
RQ-DP1-01	이동 · 복원해도 모델 출력은 바뀌지 않아야 한다 (bit-exact)	C5, QA6 Correctness
RQ-DP1-02	후속 요청 시점을 예측하거나 도착 즉시 KV 를 HBM 으로 복원해 지연을 줄여야 한다	FR1 (prefetch), QA2 Latency

번호	요구사항 및 설명	정제 종류
RQ-DP1-03	이동 대상 메모리가 부족하면 쓰일 가능성이 낮은 KV 부터 정리해야 한다	FR1/FR3
RQ-DP1-04	새 메모리 tier·객체 유형·정책을 쉽게 추가할 수 있어야 한다	QA4 Modifiability
RQ-DP2-01	(n_p, n_d) 비용 모델로 P/D 실행 위치를 결정하되 결정 시점 (scheduling-time vs pre-planned) 을 비교한다	FR5, QA1/QA2/QA5
RQ-DP2-02	노드 수가 늘어도 결정 성능과 처리량이 선형에 가깝게 늘어야 한다	QA5 Scalability
RQ-DP3-01	중요도 낮은 KV 를 선택적으로 제거하되 허용 정확도 저하 한도 안에서만 수행해야 한다	FR3, QA6 Correctness (F1)
RQ-DP3-02	압축 KV 를 재사용하고 필요한 부분만 선택 재계산해야 한다	FR3, QA2 Latency, QA3 HBM
RQ-DP3-03	Drop/ 재사용으로 HBM KV 점유를 줄여야 한다 (DP1 과 같은 정의)	QA3 Resource utilization
RQ-DP4-01	KV 이벤트 (medium 포함) 로 서버별 캐시 위치를 알고 라우팅해야 한다	FR6, QA1 Throughput
RQ-DP4-02	OSS(ilm-d) 확장과 자체 구현 중 목표 QA 를 만족하는 방식을 택해야 한다	FR6, QA4 Modifiability
RQ-DP4-03	정책 (P1~P5) 과 결정 근거를 기록·관측할 수 있어야 한다	FR8 관측성 (후보 QA: Analysability)
RQ-DP4-04	서버 수가 늘어도 orchestrator 결정이 병목이 되지 않아야 한다	QA5 Scalability

번호	요구사항 및 설명	정제 종류
RQ-SYS-01	결정은 서빙 경로 (forward) 를 막지 않아야 한다	FR8, QA2 Latency
RQ-SYS-02	차세대 메모리는 시뮬레이션 기반 예상 성능으로 평가한다	C1
RQ-SYS-03	device runtime 오버헤드와 내부 신뢰성은 고려하지 않는다	C2, C3
RQ-SYS-04	학습 , 보안 · 테넌트 격리 , 장애 복구 , stale KV 무효화는 다루지 않는다	C4
RQ-SYS-05	서버 간 연결은 PCIe 64GB/s (실장 서버 2 대)	C6
RQ-SYS-06	vLLM 기반으로 구현하며 ref_cnt>0 블록은 step 중 이동할 수 없다	C8
RQ-SYS-07	과제 초점은 스케줄링 결정이며 실행 메커니즘은 주어진 것으로 쓴다	C7
RQ-SYS-08	문서 prefix 조회 빈도에 따라 문서 KV 위치를 조정해야 한다	FR4, QA2

DP1~DP4 문서의 QA 를 ISO/IEC 25010:2023 하위 특성으로 모아 정리한 후보이다. 같은 QA 는 DP 와 무관하게 같은 조건 (워크로드 , SLO, 환경 , Baseline) 에서 측정한다. 정량 metric(목표값) 은 모두 공란이며 , 중요도 · 난이도 · 순위는 QAW(검수) 후 기입한다.

품질 속성 유틸리티 트리 (후보)

		QA	Attribute Refinement	정의 (Scenario 요약)	관련 DP	중요도	난이도
	QA1	Performance efficiency	Throughput	SLO 를 만족하는 최대 처리량 (Max SLO Goodput)	DP1·2·4 (DP3 보조)		
	QA2	Performance efficiency	Latency	TTFT / TPOT (별도 지표)	DP1~4		
	QA3	Performance efficiency	Resource utilization	HBM 점유율 (모든 DP 동일 조건)	DP1·3 목표 / DP2·4 측정		
	QA4	Maintainability	Modifiability	새 tier· 정책 · 객체 추가 용이성	DP1·2·4		
	QA5	Flexibility	Scalability	노드 / 세션 / 객체 수 증가 시 성능 유지	DP2·4		
	QA6	Functional suitability	Correctness	출력 bit-exact / DP3 는 F1 한도	DP1~4		

Quality Attribute	Attribute Refinement	Scenario (환경 · 자극 · 대상 · 응답 · 측정)	중요도	난이도	순위
QA1 Throughput	Max SLO Goodput (Agent 대기 KV)	[DP1·3] Agent 세션이 많아 tool 대기 중 idle KV 가 HBM 을 차지하는 상태에서 , 요청이 지속 도착할 때 , 시스템이 idle KV 를 HBM 밖으로 옮겨 다른 요청을 더 처리하여 , SLO(TTFT·TPOT) 를 만족하는 최대 처리량이 Baseline 대비 [] 이상이어야 한다			
QA1 Throughput	Max SLO Goodput (P/D 실행 위치)	[DP2] Prefill burst 와 긴 history 가 섞인 부하에서 , 스케줄러가 요청별 P/D 분리 여부와 (n_p, n_d) 를 정해 , SLO 를 만족하는 최대 처리량이 Baseline 대비 [] 이상이어야 한다			
QA1 Throughput	Max SLO Goodput (요청 배분)	[DP4] KV 캐시가 서버별로 흩어진 다중 서버에서 , orchestrator 가 KV 위치를 보고 서버를 골라 , SLO 를 만족하는 최대 처리량이 Baseline 대비 [] 이상이어야 한다			
QA2 Latency	TTFT (재개 / 재사용)	[DP1·3·4] 동일 세션의 후속 요청 또는 같은 문서 prefix 요청이 도착할 때 , 옮겨 둔 KV 를 찾아 복원 · 재사용하여 , 재계산을 줄이고 TTFT 가 Baseline 대비 [] 이내여야 한다			
QA2 Latency	TPOT (다계층 attention)	[DP1·2·3] KV 일부가 HBM 밖 (느린 tier) 에 있는 상태에서 decode 가 진행될 때 , 접근 빈도가 높은 KV 를 빠른 tier 에 두어 , TPOT 가 Baseline 대비 [] 이내여야 한다			
QA3 Resource utilization	HBM 점유율	[전체 DP, 동일 조건] 동일 부하 · 동일 SLO 충족 조건에서 , 시스템이 KV·adapter·expert 를 HBM 밖으로 배치하여 , 서빙 중 HBM 점유율 (평균 / 피크) 이 Baseline 대비 [] 이하여야 한다 (DP1·3 목표 , DP2·4 측정)			

Quality Attribute	Attribute Refinement	Scenario (환경 · 자극 · 대상 · 응답 · 측정)	중요도	난이도	순위
QA4 Modifiability	새 tier 추가	[시스템 개발자] 새 메모리 tier(HBF, CXL 등)를 추가할 때, 정책·배치 모듈의 변경 범위가 [] 모듈, 공수 [] man-month 이내여야 한다			
QA4 Modifiability	새 정책 / 객체 추가	[시스템 개발자] 새 이동·라우팅 정책 또는 새 객체 유형(예 : 새 캐시 객체)을 추가할 때, 기존 서빙 경로 수정 없이 [] 모듈, 공수 [] 이내로 반영되어야 한다			
QA5 Scalability	노드 수 증가	[DP2·4] 서버(노드) 수가 N에서 2N, 4N으로 늘어날 때, 결정 모듈이 병목이 되지 않고 처리량 Scaling Efficiency가 [] 이상이어야 한다			
QA5 Scalability	세션·객체 수 증가 (제안)	[DP1 등] 관리 대상 세션 / 객체(KV block, adapter, expert) 수가 증가할 때, 결정 지연이 [] 이내로 유지되어야 한다 (현재 DP 문서에는 없음, 신규 제안)			
QA6 Correctness	출력 bit-exact	[DP1·2·4] 이동·복원·offload·재사용 경로를 거친 요청의 출력이, 같은 precision에서 거치지 않은 경우와 [] 다름 없이 bit-exact 여야 한다			
QA6 Correctness	Drop 후 정확도 (DP3)	[DP3] 중요도 기반 KV 제거와 압축 재사용을 적용할 때, 압축 전 + full recompute 대비 F1 하락이 상대 [] 이내여야 한다 (현 DP3 문서 값 1% 보류 중)			

* [] = 공란. 6 요소 (자극원 · 자극 · 환경 · 대상 · 응답 · 측정) 상세와 DP 별 값은 DP1~4-requirements.md 의 QS 표 참조 (그 안의 수치는 통합 단계에서 재정의)

QA	DP1	DP2	DP3	DP4	의견
QA1 Throughput	●	●	○	●	공통 . DP 별 시나리오는 다르지만 Max SLO Goodput 정의는 하나로 통일 가능
QA2 Latency	●	●	●	●	TTFT·TPOT 를 합치지 않고 별도 지표로 유지 (DP4 문서는 TTFT 중심)
QA3 Resource util.	●	○	●	○	HBM 점유율로 통일 . DP2·4 는 목표가 아니라 부수 효과로 같은 조건에서 측정
QA4 Modifiability	●	●	-	●	DP3 에 없음 → 추가 여부 확인 필요 . 집계 방식 (모듈 수 / man-month / agent 비용) 통일 필요
QA5 Scalability	-	●	-	●	DP2·4 에만 존재 . 과제 공통 QA 로 올릴지 DP 전용으로 둘지 결정 필요
QA6 Correctness	○	○	●	○	DP3 만 능동 QA(F1), 나머지는 bit-exact 제약 확인 . QA 보다 C5(제약) 로 두는 안도 가능

● DP 문서에서 선정 (목표) ○ 측정· 확인 대상 - 해당 없음

검수 요청 사항

- Throughput / Latency / Resource util. / Modifiability / Scalability 5 개가 과제 QA 로 충분한가
- Correctness 를 QA 로 둘지 제약 (C5) 으로 둘지
- Scalability 를 공통 QA 로 올릴지
- 중요도·난이도·순위 기입 (QAW)

ISO 25010:2023 내 추가 후보 (미채택)

- Compatibility > Interoperability : vLLM·llm-d·NIXL 연동 (DP4 후보)
- Reliability > Fault tolerance : 전송 실패 시 재계산 fallback (FR 로 이미 반영)
- Maintainability > Analysability : 결정 근거 기록·진단 (DP4 후보 , FR8 과 연결)
- 장애 복구 전반은 C4 로 범위 밖

| Functional Requirements

FR1	유휴 KV 이동 · 복원	FR2	HBM 초과 context
FR3	KV Drop · 재사용 · 재계산	FR4	비 -KV 객체 배치
FR5	연산 실행 위치 결정	FR6	요청 배분
FR7	자원 경합 제어		

이기종 메모리
LLM 서빙
스케줄링 런타임

| Constraints

C1	차세대 메모리는 시뮬레이션 값
C2	device runtime 범위 밖
C5	출력 bit-exact (DP3 예외)
C6	서버 간 PCIe 64GB/s
C7	결정 중심, 실행은 주어진 것
C8	vLLM, ref_cnt>0 이동 불가

* 초안 : 중요도 · 난이도 기입 후 드라이버를 최종 선정한다.

* 제외한 FR8(비차단성 · 관측성), C3, C4 는 드라이버가 아닌 공통 전제로 둔다.

| Quality Attributes

QA1	Throughput	QA2	Latency	QA3	HBM 점유율
QA4	Modifiability	QA5	Scalability	QA6	Correctness